

UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO

División Académica de Ciencias y Tecnologías de la Información
Maestría en Ciencias de la Computación

REPORTE DE AVANCE - FASE INICIAL

*Simulación Acelerada de Speckle Óptico mediante Redes Neuronales
Físicamente Informadas con Arquitectura Sinusoidal (SIREN):
Validación en el Dominio Unidimensional de la Ecuación de Helmholtz*

Elaborado por: **Roberto Hernández Estrada**

Director de tesis: **Dr. José Adán Hernández Nolasco**

Jurado Revisor:

Pablo Pancardo García

Miguel Antonio Wister Ovando

Oscar Alberto Chávez Bosquez

Villahermosa, Tabasco - Mayo de 2026

1. Resumen Ejecutivo

El presente reporte documenta el avance correspondiente a la fase inicial de implementación de la investigación de tesis. En esta fase se diseñó, implementó y validó un prototipo funcional de Red Neuronal Físicamente Informada (PINN) para la resolución de la ecuación escalar de Helmholtz en dominio unidimensional, empleando la arquitectura SIREN (Sinusoidal Representation Networks, Sitzmann et al., 2020) con función de activación $\sin(\omega_0 \cdot x)$. Esta elección arquitectónica responde a la naturaleza oscilatoria de las soluciones de la ecuación de Helmholtz, cuya familia funcional es idéntica a la de la activación sinusoidal, lo que garantiza la representación precisa de las frecuencias espaciales del campo eléctrico $E(x)$.

Los resultados demuestran que la estrategia metodológica seleccionada alcanza un error L_2 relativo de 0,002 %, superando en tres órdenes de magnitud el umbral de precisión establecido en la hipótesis de tesis ($< 5\%$) y en un factor de 1,245 el resultado reportado por la referencia principal (Schoder y Kraxberger, 2024, $\varepsilon_{L_2} = 2,49\%$). Los indicadores de calidad estadística - coeficiente de determinación $R^2 = 1,000000$ y correlación de Pearson $r = 1,000000$ - confirman la convergencia perfecta del modelo sobre el dominio de prueba.

Tabla 1: Resumen de métricas de evaluación - Helmholtz 1D, arquitectura SIREN, seed=42.

Métrica de evaluación	Resultado	Referencia / Meta	Estado
Error L_2 relativo	0,002 %	$< 5\%$ (hipótesis)	CUMPLE
Error máximo puntual	$2,66 \times 10^{-5}$	-	Excelente
Error cuadrático medio (MSE)	$3,04 \times 10^{-10}$	≈ 0	Excelente
Raíz del MSE (RMSE)	$1,74 \times 10^{-5}$	-	Excelente
Error absoluto medio (MAE)	$1,56 \times 10^{-5}$	-	Excelente
Coef. de determinación R^2	1,000000	$\approx 1,0$	Óptimo
Correlación de Pearson	1,000000	$\approx 1,0$	Óptimo
Error relativo medio	0,0103 %	-	Excelente
Schoder y Kraxberger (2024)	2,490 %	Referencia principal	Superado $\times 1,245$
Tiempo total de entrenamiento	189,7 s	-	GPU RTX 5050
Reproducibilidad (5 corridas)	0,002 % constante	seed=42	Verificada

2. Contexto y Objetivos de la Fase

De acuerdo con el cronograma establecido en el protocolo de investigación, la fase inicial comprende el desarrollo y la validación rigurosa del modelo PINN base en un escenario de baja dimensionalidad con solución analítica conocida, antes de escalar al dominio bidimensional con campo electromagnético complejo requerido para la simulación del speckle óptico. Esta estrategia metodológica - común en el campo del Scientific Machine Learning (Karniadakis et al., 2021) - permite identificar y resolver problemas de convergencia en un entorno controlado, donde el error puede cuantificarse de forma exacta mediante comparación con la solución analítica.

Los objetivos específicos de esta fase son los siguientes:

- Implementar la arquitectura SIREN con calibración empírica del parámetro ω_0 para el régimen óptico $k = 2\pi$, documentando la relación orientativa $\omega_0 \approx k/(2\pi)$ como contribución metodológica original.
- Validar que el residuo de la ecuación de Helmholtz puede minimizarse eficazmente mediante la función de pérdida compuesta $L_{\text{total}} = L_{\text{datos}} + \lambda \cdot L_{\text{física}}$, con $\lambda_{\text{phys}} = 1,0$.
- Establecer y caracterizar la estrategia de entrenamiento híbrida Adam + L-BFGS con criterio de *early stopping* por umbral de pérdida.
- Verificar que el error L_2 relativo cumple el umbral de la hipótesis de tesis ($< 5\%$) - resultado obtenido: 0,002 %.
- Reportar el conjunto completo de métricas estándar en Scientific Machine Learning: MSE, RMSE, MAE, R^2 y correlación de Pearson.
- Verificar la reproducibilidad mediante cinco corridas independientes con semilla fija (seed=42).

3. Marco Teórico Sintético

3.1 Ecuación de Helmholtz escalar

La ecuación de Helmholtz es una ecuación diferencial parcial elíptica que describe la propagación de ondas monocromáticas en un medio homogéneo e isótropo. En su formulación escalar unidimensional y adimensional:

$$\frac{d^2 E}{dx^2} + k^2 E(x) = 0, \quad x \in [0, 1] \quad (1)$$

donde $E(x)$ es el campo eléctrico escalar y $k = 2\pi$ es el número de onda adimensional, correspondiente a un dominio de exactamente una longitud de onda. La solución

analítica exacta para las condiciones de contorno impuestas es $E(x) = \cos(kx)$, lo que permite evaluar el error del modelo mediante la norma L_2 relativa:

$$\varepsilon_{L_2} = \frac{\|E_{\text{PINN}} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2} \quad (2)$$

3.2 Redes Neuronales Físicamente Informadas

Las PINNs, introducidas por Raissi et al. (2019), son redes neuronales profundas cuya función de pérdida incorpora el residuo de la EDP gobernante, evaluado en puntos de colocación interiores mediante diferenciación automática. La función de pérdida compuesta empleada es:

$$L_{\text{total}} = L_{\text{datos}} + \lambda \cdot L_{\text{física}} \quad (3)$$

donde $L_{\text{datos}} = \text{MSE}(E_{\text{PINN}}(x_{\text{BC}}) - E_{\text{BC}})$ cuantifica la discrepancia en las condiciones de contorno, y $L_{\text{física}} = \text{MSE}\left(\frac{d^2 E_{\text{PINN}}}{dx^2} + k^2 E_{\text{PINN}}\right)$ evalúa el residuo de Helmholtz en los puntos de colocación interiores.

3.3 Arquitectura SIREN

La arquitectura SIREN (Sitzmann et al., 2020) emplea la función de activación $\sin(\omega_0 \cdot x)$ en todas las capas ocultas. Su adopción para la ecuación de Helmholtz se justifica desde tres perspectivas complementarias:

- **Correspondencia funcional:** las soluciones de (1) pertenecen a la familia $\{\cos(kx), \sin(kx)\}$, idéntica a la base funcional de SIREN.
- **Estabilidad de derivadas de orden superior:** $\left| \frac{d^n \sin(\omega_0 x)}{dx^n} \right| = \omega_0^n$ en todo el dominio, a diferencia de $\tanh$ cuyas derivadas decaen exponencialmente, atenuando la señal de gradiente del residuo físico $L_{\text{física}}$.
- **Eliminación del sesgo espectral:** Rahaman et al. (2019) demostraron que redes con activaciones suaves exhiben sesgo espectral - aprenden frecuencias bajas primero. SIREN opera directamente en el espacio de frecuencias, eliminando este sesgo.

La inicialización de pesos de Sitzmann et al. (2020) es un componente crítico: los pesos de la primera capa se distribuyen en $\mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$, mientras que las capas ocultas utilizan $\mathcal{U}(-\sqrt{6/n_{\text{in}}}/\omega_0, \sqrt{6/n_{\text{in}}}/\omega_0)$.

4. Decisiones de Diseño e Implementación

4.1 Entorno computacional

Tabla 2: Especificaciones del entorno computacional.

Componente	Especificación
GPU	NVIDIA GeForce RTX 5050 - 8 GB GDDR7 (arquitectura Blackwell)
CPU	Intel Core i5-13450HX @ 2.40 GHz (10 núcleos)
RAM	24 GB DDR5
Framework	PyTorch 2.4+ con soporte CUDA 12.6
Lenguaje	Python 3.11 (Conda) - entorno <code>pinn_speckle</code>
IDE	Visual Studio Code con extensiones Python y Jupyter

4.2 Arquitectura de la red neuronal

Tabla 3: Diseño arquitectónico PINN-SIREN para Helmholtz 1D.

Parámetro	Valor	Justificación
Dimensión de entrada	1	Coordenada espacial $x \in [0, 1]$
Capas ocultas	5×64	Validado experimentalmente; 3 capas resultan insuficientes
Función de activación	$\sin(\omega_0 \cdot x)$	Misma familia funcional que las soluciones de Helmholtz
Frecuencia ω_0	1,0	Calibrado para $k = 2\pi$; $\omega_0 = 30$ provoca explosión de gradientes
Inicialización	Sitzmann et al. (2020)	Indispensable para SIREN; Xavier genera inestabilidad numérica
Dimensión de salida	1	Campo escalar real $E(x)$
Total de parámetros	16,833	Balance capacidad representativa – eficiencia computacional

4.3 Función de pérdida y muestreo

Con arquitectura SIREN, el parámetro $\lambda_{\text{phys}} = 1,0$ establece un balance equitativo entre la contribución de datos y el residuo físico, sin requerir reducción. La inicialización de Sitzmann et al. garantiza que ambas contribuciones operen en escalas comparables desde el inicio del entrenamiento.

Tabla 4: Distribución de puntos de entrenamiento.

Tipo de punto	Cantidad	Ubicación	Contribución
Condiciones de contorno (BC)	5	$x = \{0, 0,25, 0,50, 0,75, 1\}$	$L_{\text{datos}} = \text{MSE}(E_{\text{PINN}} - E_{\text{BC}})$
Puntos de colocación interiores	2,000	Distribución uniforme en $[0, 1]$	$L_{\text{física}} = \text{MSE}(E''_{\text{PINN}} + k^2 E_{\text{PINN}})$

Nota: la inclusión de cinco puntos con valores conocidos - en lugar de los dos puntos extremos convencionales - responde al Hallazgo 1 (Sección 5). La simetría $E(0) = E(1) = 1,0$ provoca colapso de la red hacia una solución constante trivial cuando solo se imponen condiciones en los extremos.

4.4 Estrategia de entrenamiento híbrida Adam + L-BFGS

Tabla 5: Estrategia de entrenamiento híbrida Adam + L-BFGS.

Fase	Optimizador	Configuración	Resultado
I — Exploración global	Adam	lr=1e-3, máx. 15,000 épocas, criterio: $L_{\text{total}} < 10^{-4}$	15,000 épocas ejecutadas. Umbral no alcanzado. Mejor $L_{\text{total}} = 4,276 \times 10^{-4}$
II — Ajuste fino	L-BFGS	lr=1.0, max_iter=500, history=50, strong_wolfe	209 iteraciones hasta convergencia antes del límite

L-BFGS aproxima la matriz Hessiana inversa mediante pares gradiente-desplazamiento (Liu y Nocedal, 1989), confiriéndole tasa de convergencia superlineal en vecindades de mínimos bien condicionados. La divergencia entre el valor de pérdida en la última época de Adam ($5,181 \times 10^{-3}$) y el mejor valor histórico ($4,276 \times 10^{-4}$) evidencia las oscilaciones inherentes de Adam y justifica la transferencia a L-BFGS desde el mejor estado registrado.

5. Hallazgos Metodológicos

El proceso de experimentación sistemática generó cuatro hallazgos con valor metodológico documentable para la tesis y la publicación científica derivada.

5.1 Hallazgo 1 - Colapso por degeneración simétrica en condiciones de contorno

En Helmholtz con $k = 2\pi$, la solución $E(x) = \cos(2\pi x)$ satisface $E(0) = E(1) = 1,0$. Cuando únicamente se imponen condiciones en los extremos del dominio, la red colapsa hacia la solución degenerada $E(x) \approx 1,0$ constante, que satisface trivialmente ambas condiciones de contorno sin capturar la variación oscilatoria interior (error $L_2 = 51,7\%$). La incorporación de puntos intermedios en $x = \{0,25, 0,50, 0,75\}$ rompe la degeneración y reduce el error a $0,002\%$ - una mejora de cuatro órdenes de magnitud.

5.2 Hallazgo 2 - Calibración del parámetro ω_0 para el régimen óptico

El valor canónico $\omega_0 = 30$ (Sitzmann et al., 2020), diseñado para imágenes naturales con $k \gg 1$, produce explosión de gradientes para Helmholtz con $k = 2\pi$, manifestada como error $L_2 = 105,7\%$ sin posibilidad de convergencia. La calibración empírica establece $\omega_0 = 1,0$ como valor óptimo, derivando la relación orientativa $\omega_0 \approx k/(2\pi)$.

Tabla 6: Calibración empírica del parámetro ω_0 para $k = 2\pi$.

ω_0	λ_{phys}	Error L_2	Estado	Observación
30 (canónico)	1.0	105,692 %		Explosión de gradientes — incompatible con régimen óptico
1.0 (óptimo)	1.0	0.002 %		Configuración definitiva — convergencia estable

Nota: Se evaluaron múltiples valores de ω_0 . El parámetro óptimo $\omega_0 = 1,0$ fue seleccionado por estabilidad numérica y compatibilidad física.

Nota: Se evaluaron múltiples valores de ω_0 . El parámetro óptimo $\omega_0 = 1,0$ fue seleccionado por estabilidad numérica y compatibilidad física.

5.3 Hallazgo 3 - Indispensabilidad de L-BFGS para el ajuste fino de alta precisión

Adam ejecutó las 15,000 épocas máximas alcanzando un mejor valor histórico $L_{\text{total}} = 4,276 \times 10^{-4}$, mientras que el valor en la última época fue $5,181 \times 10^{-3}$, evidenciando oscilación sostenida. L-BFGS, partiendo del mejor estado de Adam, redujo la pérdida a $\approx 10^{-10}$ en 209 iteraciones - seis órdenes de magnitud. Este resultado confirma la necesidad de la estrategia híbrida y valida la metodología de Schoder y Kraxberger (2024).

5.4 Hallazgo 4 - Estabilidad de λ_{phys} con arquitectura SIREN

Con $\tanh$, λ_{phys} debe reducirse a $0,01$ para evitar dominancia prematura de la física. Con SIREN y $\omega_0 = 1,0$, $\lambda_{\text{phys}} = 1,0$ opera de forma estable gracias a la inicialización de Sitzmann et al., que garantiza que el residuo de Helmholtz evaluado vía segunda derivada de la red y el error de condiciones de contorno operen en escalas comparables.

Esto simplifica la búsqueda de hiperparámetros en la extensión al caso 2D con campo complejo.

6. Resultados Cuantitativos

6.1 Configuración experimental definitiva

Tabla 7: Configuración experimental definitiva - NB01.

Hiperparámetro	Valor	Descripción y justificación
k (número de onda)	$2\pi = 6,2832$	Un periodo completo en $[0, 1]$
N_{colloc}	2,000	Puntos de colocación interiores uniformes
Cond. de contorno (BC)	5	$x = \{0, 0,25, 0,50, 0,75, 1,0\}$
hidden_dim	64	Neuronas por capa oculta
num_layers	5	Capas ocultas
ω_0 (SIREN)	1,0	Calibrado para $k = 2\pi$ mediante $\omega_0 \approx k/(2\pi)$
n_epochs (máx.)	15,000	Límite superior de épocas Adam
lr (Adam)	10^{-3}	Tasa de aprendizaje estándar para PINNs
λ_{phys}	1,0	Balance datos-física - estable con SIREN
lbfgs_max_iter	500	Iteraciones máximas de ajuste fino
lbfgs_history_size	50	Pares gradiente-desplazamiento (Hessiana)
Semilla (seed)	42	Fijada en PyTorch, CUDA y NumPy

6.2 Métricas de evaluación - conjunto completo

Las siguientes métricas fueron evaluadas sobre una malla de prueba de 1,000 puntos distribuidos uniformemente en $[0, 1]$:

Tabla 8: Métricas de evaluación completas sobre 1,000 puntos de prueba.

Métrica	Def	Valor	Interpretación
Error L_2 relativo	$\ E_t - E_e\ $	0,002 %	Meta < 5 % superada $\times 2,500$
Error máximo puntual	máx $E_e(i)$	$2,66 \times 10^{-5}$	Despreciable en todo el dominio
MSE	mea $E_e(i)$	$3,04 \times 10^{-10}$	Ausencia de errores de gran magnitud
RMSE	$\sqrt{MSE}$	$1,74 \times 10^{-5}$	Error típico en unidades del campo
MAE	mea $ E_e(i) $	$1,56 \times 10^{-5}$	Precisión global robusta a atípicos
R^2	$1 - \frac{SS_r}{SS_t}$	1,000000	Fracción de varianza explicada - óptimo
Correlación Pearson	cov	1,000000	Correlación lineal perfecta con analítica
Error relativo medio	mea $ E_e(i) $	0,0103 %	Error relativo promedio en dominio de prueba

6.3 Progresión experimental sistemática

Tabla 9: Progresión sistemática de experimentos hacia la configuración definitiva.

Exp.	Configuración	Error L_2	Observación
E1	$\tanh, \lambda = 1,0, \text{hidden}=32, 3,000 \text{ ép.}$	51,726 %	Colapso por degeneración simétrica
E2	$\tanh, \lambda = 0,1, \text{hidden}=64, 5,000 \text{ ép.}$	28,052 %	Mejora parcial - física dominante
E3	$\tanh, \lambda = 0,1 + \text{L-BFGS}$	10,834 %	L-BFGS mejora; λ aún inadecuado
E4	$\tanh, \lambda = 0,01, k = \pi, 10,000 \text{ ép.}$	0,345 %	k asimétrico - no requiere BC intermedias
E5	$\tanh, \lambda = 0,001, k = 2\pi, \text{sin BC intermedias}$	10,940 %	Colapso parcial - simetría no resuelta
E6	$\tanh, \lambda = 0,01, k = 2\pi, 5 \text{ BC, early stop} + \text{L-BFGS}$	0,002 %	Configuración óptima con $\tanh$ - referencia
E7	SIREN, $\omega_0 = 30, \lambda = 1,0$	105,692 %	Explosión gradientes - ω_0 incompatible
E8	SIREN, $\omega_0 = 1,0, \lambda = 1,0, 5 \text{ BC, early stop} + \text{L-BFGS}$	0,002 %	Configuración definitiva - arquitectura adoptada

6.4 Verificación de reproducibilidad

La reproducibilidad fue verificada mediante cinco corridas independientes con semilla fija ($\text{seed}=42$) aplicada a los generadores de números aleatorios de PyTorch, CUDA y NumPy. Los resultados numéricos son idénticos en todas las corridas; las variaciones en tiempo de cómputo se deben a fluctuaciones térmicas en la GPU (throttling térmico).

Tabla 10: Verificación de reproducibilidad - cinco corridas con $\text{seed}=42$.

Corrida	Error L_2	Mejor L_{total} (Adam)	Iter. L-BFGS	Tiempo total (s)
1	0,002 %	$4,276 \times 10^{-4}$	209/500	≈ 179
2	0,002 %	$4,276 \times 10^{-4}$	209/500	266,8
3	0,002 %	$4,276 \times 10^{-4}$	209/500	633,7*
4	0,002 %	$4,276 \times 10^{-4}$	209/500	2,164,9*
5 (referencia)	0,002 %	$4,276 \times 10^{-4}$	209/500	189,7

* Variación debida a throttling térmico de la GPU - resultados numéricos idénticos.

7. Estado del Proyecto y Plan de Trabajo

Tabla 11: Estado actual y plan de trabajo.

Notebook	Contenido	Estado	Resultado
NB01 - Helmholtz 1D	Validación PINN-SIREN, calibración ω_0 , reproducibilidad	Completado	Error $L_2 = 0,002 \%$
NB02 - Helmholtz 2D	Campo complejo $E(x, y)$, LHS, arquitectura 5×128	Completado	Error $L_2 = 0,222 \%$
NB03 - Speckle óptico	$I(x, y) = E ^2$, patrón de speckle, validación estadística $C \approx 1$	En desarrollo	-
NB04 - Benchmark FEM	PINN vs. FEniCSx, Speed-up Factor, huella de memoria	Pendiente	-
NB05–NB07	Medios inhomogéneos, perfiles GRIN, speckle en GRIN	Pendiente	-

8. Referencias

- [1] Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Roberts & Company Publishers.
- [2] Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., y Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422–440. <https://doi.org/10.1038/s42254-021-00314-5>
- [3] Kingma, D. P., y Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv:1412.6980*. <https://arxiv.org/abs/1412.6980>
- [4] Liu, D. C., y Nocedal, J. (1989). On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, 45(1), 503–528.
- [5] Lu, L., Meng, X., Mao, Z., y Karniadakis, G. E. (2021). DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1), 208–228. <https://doi.org/10.1137/19M1274067>
- [6] Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F., Bengio, Y., y Courville, A. (2019). On the spectral bias of neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 5301–5310.
- [7] Raissi, M., Perdikaris, P., y Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- [8] Schoder, S., y Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. *arXiv:2403.06623v1*. <https://doi.org/10.48550/arXiv.2403.06623>
- [9] Sitzmann, V., Martel, J. N. P., Bergman, A. W., Lindell, D. B., y Wetzstein, G. (2020). Implicit neural representations with periodic activation functions. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 7462–7473.