

UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO

Maestría en Ciencias de la Computación

Propuesta de Extensión de Investigación

Hoja de Ruta: Extensión de PINNs para Medios Inhomogéneos y Arquitecturas SIREN

Análisis de Progresión desde la Ecuación de Helmholtz Homogénea hasta la Simulación de Speckle Óptico en Medios con Índice de Refracción Variable

Autor: **Roberto Hernández Estrada**

Director: **Dr. José Adán Hernández Nolasco**

Villahermosa, Tabasco — 2026

ESTADO ACTUAL DEL PROYECTO
NB01 — Helmholtz 1D Error L2 = 0.002% ■ Completado
NB02 — Helmholtz 2D Error L2 = 0.084% ■ Completado
NB03 — Speckle óptico con frontera rugosa ■ Completado
NB04 — Benchmark PINN vs FEniCSx ■ En desarrollo

1. Resumen Ejecutivo

Este documento presenta una propuesta formal de extensión del proyecto de tesis *Simulación Acelerada de Speckle Óptico mediante PINNs*, actualmente en su Fase 1 (medios ópticos homogéneos). La propuesta define una hoja de ruta de tres fases progresivas que culmina en la simulación de speckle óptico en medios con índice de refracción variable, empleando arquitecturas neuronales especializadas (SIREN) que superan las limitaciones de la activación tanh en regímenes de alta frecuencia espacial.

La progresión propuesta responde a una observación metodológica fundamental: el modelo adimensional actual es **universal para medios homogéneos**, lo que constituye tanto su fortaleza como su límite natural. La extensión a medios inhomogéneos representa una contribución científica original con potencial de publicación en revistas indexadas.

HIPÓTESIS CENTRAL DE LA EXTENSIÓN

Las PINNs con arquitectura SIREN pueden resolver la ecuación de Helmholtz con coeficientes variables $n(x,y)$ — medios inhomogéneos — con error $L2 < 5\%$, superando en velocidad al método FEM y generando patrones de speckle estadísticamente válidos (contraste $C \approx 1$) en materiales con gradiente de índice.

2. Fundamento Teórico — ¿Por Qué Extender a Medios Inhomogéneos?

2.1 El Modelo Actual — Universal pero Limitado

El modelo desarrollado en los notebooks 01 y 02 resuelve la ecuación de Helmholtz en su formulación adimensional:

$$\nabla^2 E + (2\pi)^2 \cdot E = 0 \text{ con } k = 2\pi \text{ constante en todo el dominio}$$

La adimensionalización elimina λ del cálculo, haciendo el modelo válido para cualquier longitud de onda en medios homogéneos ($n = \text{constante}$). Esta generalidad es una ventaja computacional real, pero implica un supuesto físico: el índice de refracción es igual en todos los puntos del dominio.

2.2 La Ecuación de Helmholtz Inhomogénea

Cuando el medio tiene índice de refracción variable $n(x,y)$, la ecuación de Helmholtz adopta la forma con coeficientes variables:

$$\nabla^2 E + k^2 \cdot n(x,y)^2 \cdot E = 0 \text{ donde } k = 2\pi/\lambda \text{ (vacío) y } k(x,y) = k \cdot n(x,y)$$

El término $n(x,y)^2$ convierte la ecuación en una EDP con coeficientes variables. La adimensionalización global ya no elimina λ porque el factor $n(x,y)$ permanece con dependencia espacial explícita. Esto tiene tres consecuencias:

- El modelo ya no es universal — es específico a la distribución $n(x,y)$ del material.
- La función de activación tanh enfrenta spectral bias severo donde $n(x,y)$ varía rápidamente, creando gradientes de alta frecuencia local.
- Se requiere una arquitectura neuronal con mayor capacidad para representar funciones de alta frecuencia espacial: SIREN.

2.3 La Diferencia Clave: Condición de Frontera vs. Medio

Es importante distinguir dos conceptos que pueden confundirse:

Elemento	Ubicación	Rol matemático	Afecta homogeneidad
Superficie rugosa	Borde $y=0$	Condición de frontera $E(x,0) = e^{i\phi(x)}$	■ No
Fase aleatoria $\phi(x)$	Borde $y=0$	Dato conocido para PINN	■ No
Aire libre	Interior $[0,1]^2$	Dominio Helmholtz $k = 2\pi$ constante	■ Homogéneo
Material GRIN	Interior $[0,1]^2$	$n(x,y)$ variable $k(x,y) = k \cdot n(x,y)$	■ Inhomogéneo

Tabla 2.1 — Distinción entre condición de frontera rugosa y medio inhomogéneo.

3. La Arquitectura SIREN — Fundamento y Ventajas

3.1 Spectral Bias — La Limitación de tanh en Alta Frecuencia

Rahaman et al. (2019) demostraron formalmente que las redes neuronales con activaciones suaves (tanh, ReLU, sigmoid) aprenden frecuencias bajas primero y convergen lentamente — o no convergen — a funciones de alta frecuencia espacial. En medios inhomogéneos donde $n(x,y)$ varía rápidamente, las soluciones de Helmholtz desarrollan variaciones de alta frecuencia local que tanh no puede representar eficientemente.

3.2 SIREN — Sinusoidal Representation Networks

Sitzmann et al. (2020) propusieron SIREN: redes donde la función de activación es $\sin(\omega \cdot x)$ en lugar de $\tanh(x)$, con una inicialización especial que garantiza estabilidad:

```
# Red tanh (actual) # Red SIREN (propuesta) nn.Linear(64, 64) nn.Linear(64, 64) nn.Tanh()  
Sin(omega_0=30) # W ~ U(-sqrt(6/n), sqrt(6/n)) / omega
```

La función sin es periódica como las soluciones de Helmholtz, eliminando el spectral bias. El parámetro ω controla la frecuencia base de la red — típicamente $\omega = 30$ para problemas de óptica (Sitzmann et al. 2020).

Propiedad	tanh (actual)	SIREN — $\sin(\omega \cdot x)$
Diferenciabilidad	C_∞	C_∞
Acotada	Sí $(-1, 1)$	Sí $(-1, 1)$
Periódica	No	Sí — clave para Helmholtz
Spectral bias	Severo en alta freq.	Eliminado
Derivadas de orden n	Decaen rápido	Estables — $\sin^n(n) \propto \sin$
Inicialización	Xavier estándar	Especial (Sitzmann 2020)
Medios homogéneos	■ Excelente	■ Excelente
Medios inhomogéneos	■ Limitado	■ Óptimo

Estabilidad inicial	Alta	Media — requiere ω correcto
---------------------	------	------------------------------------

Tabla 3.1 — Comparativa tanh vs SIREN para PINNs en ecuación de Helmholtz.

4. Hoja de Ruta Completa de la Investigación

La progresión propuesta sigue una escalada de complejidad creciente y controlada. Cada fase valida las hipótesis necesarias para sustentar la siguiente, garantizando que los resultados sean interpretables y comparables.

Fase	Notebook	Medio	Frontera	Activación	Contribución clave	Estado
1A	NB01	Homogéneo 1D	Suave $\cos(kx)$	$\tanh$	Validación base del método	■
1B	NB02	Homogéneo 2D	Suave onda plana	$\tanh$	Campo complejo + LHS	■
1C	NB03	Homogéneo 2D	Rugosa $\phi \sim U(0, 2\pi)$	$\tanh$	Speckle real — $C \approx 1$	■
1D	NB04	Homogéneo 2D	Rugosa	$\tanh$	Benchmark vs FEM — Speed-up Factor	■
2A	NB05	Inhomogéneo 1D	Suave	$\tanh$	Primera extensión — límite de $\tanh$	Propuesto
2B	NB06	Inhomogéneo 2D	Suave	$\tanh$	$\tanh$ vs $n(x,y)$ gradual	Propuesto
2C	NB07	Inhomogéneo 2D	Rugosa	$\tanh$	Documentar fallo de $\tanh$	Propuesto
3A	NB08	Inhomogéneo 1D	Suave	SIREN	SIREN supera $\tanh$ en 1D	Propuesto
3B	NB09	Inhomogéneo 2D	Suave	SIREN	SIREN en campo complejo 2D	Propuesto
3C	NB10	Inhomogéneo 2D	Rugosa	SIREN	Speckle en material real — publicable	Propuesto

Tabla 4.1 — Hoja de ruta completa. Azul: Fase 1 (actual). Naranja: Fase 2. Verde: Fase 3.

FASE 1 — Medios Homogéneos (actual)	FASE 2 — Inhomogéneos con $\tanh$	FASE 3 — Inhomogéneos con SIREN
NB01–NB04 Protocolo actual completo Benchmark vs FEM incluido	NB05–NB07 Documenta límites de $\tanh$ Sienta base para SIREN	NB08–NB10 Contribución original Publicable en revista indexada

5. Tres Perfiles de Alcance para la Tesis

Dependiendo del tiempo disponible y los objetivos acordados con el director, se proponen tres perfiles de alcance con contribuciones claramente diferenciadas:

Perfil	Notebooks	Alcance	Tiempo est.	Producto académico
A Mínimo Viable	NB01 – NB04	Homogéneo completo + Benchmark FEM	Actual (2–3 meses)	Tesis de maestría defendible hoy
B Extendido Recomendado	NB01 – NB07	+ Inhomogéneo con tanh	4–6 meses adicionales	Tesis + documento de comparativa
C Completo Publicable	NB01 – NB10	+ SIREN en inhomogéneo	8–12 meses adicionales	Paper en JCP u Optics Express

Tabla 5.1 — Tres perfiles de alcance para la tesis con estimación de tiempo y producto académico.

5.1 Recomendación — Perfil A Primero

La recomendación concreta es completar el **Perfil A** (NB04 — Benchmark) antes de cualquier extensión. El notebook 04 es la contribución principal del protocolo actual: sin el Speed-up Factor documentado, la hipótesis central de la tesis no está demostrada.

Una vez completado el Perfil A, la decisión de extender al Perfil B o C depende de tres factores que deben evaluarse con el director: tiempo restante en el programa, disponibilidad de recursos computacionales para SIREN, y potencial de publicación en revistas target.

6. Ejemplos Físicos de Medios Homogéneos e Inhomogéneos

La siguiente tabla resume casos físicos concretos clasificados por tipo de medio, con indicación de si el modelo actual es aplicable y qué extensión se requeriría:

Medio físico	$n(x,y)$	Ejemplo de aplicación	Modelo actual	Extensión requerida
Vacío	1.000	Propagación libre en espacio	■ Directo	Ninguna
Aire	1.0003	Speckle en laboratorio (caso de la tesis)	■ Directo	Ninguna
Vidrio BK7 uniforme	1.517	Lentes ópticas planas	■ $k = 2\pi n$	Cambiar k en CONFIG
Agua destilada	1.333	Speckle subacuático	■ $k = 2\pi n$	Cambiar k en CONFIG
Fibra GRIN	$n(r)$ parabólico	Fibras ópticas de gradiente	■	Fase 2 — $n(x,y)$ en residuo
Tejido biológico	n por capas 1.37–1.55	OCT médica — imagen de tejido	■	Fase 2 — interfaz de capas
Atmósfera turbulenta	$n(x,y,t)$ aleatorio	Óptica adaptativa telescópica	■	Fase 3 — SIREN + temporal
Cristal líquido	$n(\theta)$ variable	Pantallas LCD lentes de focus variable	■	Fase 3 — SIREN
Metamaterial	$n < 0$ diseñado	Capas de invisibilidad investigación	■	Fase 3 — SIREN especializado

Tabla 6.1 — Clasificación de medios físicos. Azul: homogéneos (modelo actual). Naranja: inhomogéneos (extensión propuesta).

7. Cambios Técnicos Requeridos por Fase

7.1 De Fase 1 a Fase 2 — Modificación del Residuo

La transición de medios homogéneos a inhomogéneos requiere un cambio mínimo en el código: modificar el cálculo del residuo de Helmholtz para aceptar un campo de índice de refracción $n(x,y)$:

```
# FASE 1 – Residuo homogéneo (actual) residual = laplaciano(E) + k**2 * E # k = 2π
constante global # FASE 2 – Residuo inhomogéneo (propuesto) n_xy = n_func(xy_colloc) #
campo n evaluado en puntos LHS k_local = k0 * n_xy # k varía punto a punto residual =
laplaciano(E) + k_local**2 * E
```

Todo lo demás — arquitectura, estrategia Adam+L-BFGS, LHS, condiciones de frontera — permanece igual. Esto demuestra la solidez del diseño actual como base extensible.

7.2 De Fase 2 a Fase 3 — Arquitectura SIREN

La transición de tanh a SIREN requiere reemplazar la función de activación y aplicar la inicialización especial de Sitzmann et al. (2020):

```
# FASE 2 – Activación tanh (actual) layers += [nn.Linear(64, 64), nn.Tanh()]
nn.init.xavier_normal_(layer.weight) # inicialización estándar # FASE 3 – Activación
SIREN (propuesto) omega_0 = 30 # frecuencia base (Sitzmann 2020) layers += [nn.Linear(64,
64), Sin(omega_0)] # Inicialización especial: nn.init.uniform_(layer.weight,
-sqrt(6/n_in), sqrt(6/n_in)) layer.weight.data /= omega_0 # escalar por omega_0
```

7.3 Campos $n(x,y)$ para la Fase 2 — Ejemplos Implementables

Los siguientes perfiles de índice de refracción son matemáticamente simples, físicamente realistas y tienen solución analítica conocida para validación:

Perfil $n(x,y)$	Fórmula	Representa	Solución analítica
Gradiente lineal	$n(x) = 1 + 0.5x$	Material con gradiente uniforme	Funciones de Airy
Gradiente radial (tipo GRIN)	$n(r) = n_0(1 - \alpha^2 r^2)$	Fibra óptica GRIN	Funciones de Hermite-Gauss
Bicapa	$n = 1.0$ si $y < 0.5$ $n = 1.5$ si $y \geq 0.5$	Interfaz vidrio-aire	Condiciones de Fresnel
Gaussiano	$n(x,y) = 1 + A e^{-(r^2/\sigma^2)}$	Lente de índice gradual	Aproximación paraxial

Tabla 7.1 — Perfiles de índice de refracción propuestos para la Fase 2, con validación analítica.

8. Respaldo Bibliográfico de la Propuesta

Cada elemento de la propuesta está respaldado por literatura científica peer-reviewed. A continuación se presentan las referencias clave organizadas por tema:

8.1 PINNs para Ecuaciones con Coeficientes Variables

- [1] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems. *Journal of Computational Physics*, 378, 686–707. — Demuestra que PINNs resuelven EDPs con coeficientes variables cuando el residuo se evalúa en los puntos de colocación.
- [2] Berg, J., & Nyström, K. (2018). A unified deep artificial neural network approach to partial differential equations in complex geometries. *Neurocomputing*, 317, 28–41. — Primer trabajo en aplicar PINNs a medios con propiedades variables en 2D.

8.2 Spectral Bias y sus Consecuencias

- [3] Rahaman, N., Baratin, A., Arpit, D., et al. (2019). On the spectral bias of neural networks. *Proceedings of ICML 2019*. — Demuestra formalmente que redes con tanh aprenden frecuencias bajas primero, justificando la necesidad de SIREN en alta frecuencia.
- [4] Wang, S., Teng, Y., & Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5), A3055–A3081. — Analiza por qué la pérdida física y la pérdida de datos compiten en el gradiente, especialmente en medios inhomogéneos.

8.3 SIREN — Sinusoidal Representation Networks

- [5] Sitzmann, V., Martel, J. N. P., Bergman, A. W., Lindell, D. B., & Wetzstein, G. (2020). Implicit neural representations with periodic activation functions. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 7462–7473. — Artículo fundacional de SIREN: demuestra superioridad sobre tanh para señales de alta frecuencia y ecuaciones diferenciales.
- [6] Huang, X., Alkhalifah, T., & Song, C. (2022). PINNeik: Eikonal solution using physics-informed neural networks. *Computers & Geosciences*, 167, 105244. — Aplica SIREN a la ecuación iconal (Helmholtz en alta frecuencia) en medios con velocidad variable — análogo directo al caso inhomogéneo propuesto.

8.4 Helmholtz en Medios Inhomogéneos con PINNs

- [7] Alkhalifah, T., Wang, C., & Ovcharenko, O. (2021). Wavefield solutions from machine learned functions that approximately satisfy the wave equation. *Artificial Intelligence in Geosciences*, 2, 11–19. — Resuelve la ecuación de onda con velocidad variable (análogo a n variable) usando PINNs, demostrando viabilidad del enfoque propuesto.
- [8] Waheed, U. B., Alkhalifah, T., Haghighat, E., Song, C., & Virieux, J. (2021). PINNtomo: Seismic tomography using physics-informed neural networks. *arXiv:2104.01588*. — Primer paper en combinar PINNs con medios inhomogéneos en 2D complejo.

8.5 Speckle Óptico — Fundamento Estadístico

- [9] Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Roberts & Company Publishers. — Referencia fundamental: demuestra que el speckle completamente desarrollado tiene distribución exponencial con contraste $C = 1$, válido tanto en medios homogéneos como en la emergencia de medios inhomogéneos.
- [10] Schoder, S., & Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. *arXiv:2403.06623*. — Benchmark directo contra el que se comparan los resultados actuales (error $L2 = 2.49\%$).

9. Texto de Propuesta para el Director de Tesis

El siguiente texto puede emplearse directamente en la reunión con el Dr. Hernández Nolasco como base de la propuesta formal:

Dr. Hernández Nolasco,

Los resultados de la Fase 1 del proyecto validan que las PINNs resuelven la ecuación de Helmholtz en medios homogéneos con errores L2 de 0.002% (1D) y 0.084% (2D), superando la meta del protocolo por factores de 2,500 y 59 respectivamente. El notebook 03 genera patrones de speckle con contraste $C \approx 1$ y distribución exponencial, confirmando la validez física del modelo.

El modelo actual es universal para medios homogéneos — un único entrenamiento resuelve Helmholtz para cualquier longitud de onda. Esta generalidad es computacionalmente valiosa, pero define el límite natural de la Fase 1: el modelo no puede representar medios con índice de refracción variable $n(x,y)$ sin modificación del residuo.

Propongo la siguiente extensión en tres fases:

Fase 2 (Notebooks 05–07): Extender el modelo a medios inhomogéneos modificando el residuo de Helmholtz para incluir $n(x,y)$. Se utilizarán perfiles de índice con solución analítica conocida (gradiente lineal, GRIN, bicapa) para validación cuantitativa. Esta fase documentará las limitaciones de tanh en alta frecuencia.

Fase 3 (Notebooks 08–10): Implementar la arquitectura SIREN (Sitzmann et al., NeurIPS 2020) que elimina el spectral bias mediante activación sinusoidal. Se demostrará que SIREN supera a tanh en medios inhomogéneos y se generará speckle en materiales con gradiente de índice. Esta fase tiene potencial de publicación en Journal of Computational Physics u Optics Express.

Recomiendo completar primero el Notebook 04 (Benchmark vs FEniCSx) para cerrar la Fase 1, y definir en reunión el alcance de la extensión según el tiempo disponible en el programa.

10. Conclusiones

Esta propuesta demuestra que el trabajo actual no es el fin del proyecto sino la **base sólida** de una investigación extensible. Las conclusiones clave son:

- El modelo adimensional actual es válido y universal para medios homogéneos — cualquier longitud de onda de láser en propagación libre.

- La extensión a medios inhomogéneos requiere un cambio mínimo en el código (una línea en el residuo), demostrando la solidez del diseño actual.
- SIREN no es un reemplazo de tanh sino una herramienta complementaria para regímenes específicos de alta frecuencia espacial.
- La progresión en tres fases es metodológicamente rigurosa: cada fase valida las hipótesis de la siguiente.
- El Perfil A (NB01–NB04) es la prioridad inmediata — sin el Benchmark de velocidad, la hipótesis central de la tesis no está demostrada.
- El Perfil C (NB01–NB10) constituye una contribución original publicable en revistas de primer cuartil.

Referencias

- [1] Raissi et al. (2019). Physics-informed neural networks. *J. Comput. Phys.*, 378, 686–707.
- [2] Berg & Nyström (2018). Deep ANN approach to PDEs in complex geometries. *Neurocomputing*, 317, 28–41.
- [3] Rahaman et al. (2019). On the spectral bias of neural networks. *ICML 2019*.
- [4] Wang et al. (2021). Gradient flow pathologies in PINNs. *SIAM J. Sci. Comput.*, 43(5).
- [5] Sitzmann et al. (2020). Implicit neural representations with periodic activations. *NeurIPS 33*.
- [6] Huang et al. (2022). PINNeik: Eikonal solution using PINNs. *Comput. Geosci.*, 167, 105244.
- [7] Alkhalifah et al. (2021). Wavefield solutions from ML functions. *AI in Geosciences*, 2, 11–19.
- [8] Waheed et al. (2021). PINNtomo: Seismic tomography using PINNs. *arXiv:2104.01588*.
- [9] Goodman, J.W. (2007). *Speckle Phenomena in Optics*. Roberts & Company Publishers.
- [10] Schoder & Kraxberger (2024). Helmholtz 3D with PINNs. *arXiv:2403.06623*.
- [11] Kingma & Ba (2015). Adam: A method for stochastic optimization. *ICLR 2015*.
- [12] Liu & Nocedal (1989). Limited memory BFGS for large scale optimization. *Math. Program.*, 45.