

INFORMACION RELEVANTE PARA EL COLOQUIO SEGUNDO AVANCE DE TESIS — PINN-SIREN

Simulacion acelerada de speckle optico mediante
Redes Neuronales Informadas por Fisica
con activacion sinusoidal

Alumno: Roberto Hernandez Estrada **Matricula:** 252H21004
Director: Dr. Jose Adan Hernandez Nolasco
Division Academica de Ciencias y Tecnologias de la Informacion
Universidad Juarez Autonoma de Tabasco — Junio 2026

Como usar este documento

Cada seccion presenta el contenido tecnico del avance junto con una **caja morada** que conecta el concepto con la literatura de respaldo. Las cajas verdes muestran resultados numericos clave. Las cajas amarillas interpretan las graficas.

Índice

1. Fundamento Fisico: Ecuacion de Helmholtz	3
1.1. Condiciones de frontera (Dirichlet)	3
2. Arquitectura PINN-SIREN	4
2.1. Physics-Informed Neural Networks (PINNs)	4
2.2. Activacion SIREN: $\phi(z) = \sin(\omega_0 \cdot z)$	4
2.3. Estrategia de optimizacion bifasica	5
3. NB01 — Validacion Helmholtz 1D	5
3.1. Configuracion experimental	6
3.2. Resultados	6
4. NB02 — Validacion Helmholtz 2D (Campo Complejo)	7
4.1. Configuracion experimental	7
4.2. Resultados 2D	8

5. Metricas de Validacion	8
6. Reproducibilidad Multi-Semilla	9
7. Ablacion del Peso de Fisica λ_{fis}	10
8. Comparativa con el Estado del Arte	10
9. Hiperparametros: Justificacion Unificada	11

1. Fundamento Fisico: Ecuacion de Helmholtz

Ecuacion de Helmholtz escalar 2D

La ecuacion que gobierna la propagacion de luz coherente en el dominio $\Omega = (0, 1)^2$ es:

$$\nabla^2 E(\mathbf{r}) + k^2 E(\mathbf{r}) = 0 \quad \mathbf{r} = (x, y) \in \Omega$$

donde E es el campo electrico complejo, $k = 2\pi/\lambda$ es el numero de onda. En este trabajo se usa el dominio adimensional con $k = 2\pi$, equivalente a un laser diodo rojo de $\lambda = 638$ nm. En coordenadas cartesianas:

$$\frac{\partial^2 E}{\partial x^2} + \frac{\partial^2 E}{\partial y^2} + k^2 E = 0$$

Conexion bibliografica

Born & Wolf (1999): ecuacion de Helmholtz como forma reducida de las ecuaciones de Maxwell para campos monocromaticos. Capitulo 1.2: la aproximacion escalar es valida cuando la polarizacion no varia significativamente en el dominio de estudio. Lagaris et al. (1998): primer uso sistematico de redes neuronales para resolver EDPs, incluyendo la ecuacion de Helmholtz — precursor directo de las PINNs.

1.1. Condiciones de frontera (Dirichlet)

La imposicion de condiciones de Dirichlet en el contorno $\partial\Omega$ asegura que la red neuronal respete la solucion fisica en la frontera, garantizando unicidad y estabilidad numerica en el entrenamiento.

Soluciones analiticas exactas

Caso 1D ($x \in [0, 1]$):

$$E_{\text{exacta}}(x) = \cos(kx)$$

con condiciones de frontera $E(0) = 1$ y $E(1) = \cos(k)$.

Caso 2D (onda plana diagonal, $k_x = k_y = k/\sqrt{2}$):

$$E_{\text{exacta}}(x, y) = e^{i(k_x x + k_y y)} = \underbrace{\cos(k_x x + k_y y)}_{E_{\text{real}}} + i \underbrace{\sin(k_x x + k_y y)}_{E_{\text{imag}}}$$

La relacion de dispersion $k^2 = k_x^2 + k_y^2$ garantiza que la solucion satisface la ecuacion de Helmholtz. Las condiciones de frontera complejas (coseno para E_r , seno para E_i) se imponen en todo el contorno $\partial\Omega$.

Conexion bibliografica

La separacion de variables para Helmholtz 2D produce soluciones del tipo $\cos(k_x x) \cos(k_y y)$; la onda plana e^{ikr} es una solucion especial correspondiente a pro-

pagacion diagonal (Born y Wolf, 1999). La descomposicion mediante la identidad de Euler $e^{i\theta} = \cos \theta + i \sin \theta$ permite tratar las partes real e imaginaria como dos redes de salida independientes dentro de una sola arquitectura PINN (Raissi et al., 2019).

2. Arquitectura PINN-SIREN

2.1. Physics-Informed Neural Networks (PINNs)

Funcion de perdida PINN

La red minimiza simultaneamente el error en las condiciones de frontera y el residuo de la ecuacion diferencial:

$$\mathcal{L} = \underbrace{\text{MSE}(\hat{E}_{\text{BC}} - E_{\text{BC}})}_{\mathcal{L}_{\text{frontera}}} + \lambda_{\text{fis}} \cdot \underbrace{[\text{MSE}(R_{\text{real}}^2) + \text{MSE}(R_{\text{imag}}^2)]}_{\mathcal{L}_{\text{fisica}}}$$

donde $R = \nabla^2 E + k^2 E$ es el residuo de Helmholtz, calculado mediante diferenciacion automatica encadenada (`torch.autograd.grad`).

Conexion bibliografica

Raissi et al. (2019) (J. Comput. Phys., 2019): articulo fundacional. Propone usar el residuo de la EDP como funcion de perdida, eliminando la necesidad de soluciones numericas de referencia para el entrenamiento. Las PINNs pueden resolver problemas directos e inversos con la misma arquitectura.

Lagaris et al. (1998) (IEEE Trans. Neural Netw., 1998): trabajo precursor que uso redes neuronales para satisfacer condiciones de frontera y la EDP de forma simultanea, fundamento teorico de la aproximacion actual.

2.2. Activacion SIREN: $\phi(z) = \sin(\omega_0 \cdot z)$

Por que sinusoidal y no ReLU/tanh

Activacion	$\phi''(z)$	Apta para Helmholtz
ReLU	$= 0$ (c.t.p.)	No: laplaciano trivialmente cero
tanh	$\rightarrow 0$ saturada	Muy limitada
$\sin(\omega_0 z)$	$= -\omega_0^2 \sin(\omega_0 z)$	Si: nunca cero

La n -esima derivada de SIREN es $\pm \omega_0^n \sin(\omega_0 z + n\pi/2)$: siempre una senoide, estable a cualquier orden. Esto hace el termino $\mathcal{L}_{\text{fisica}}$ bien condicionado durante el entrenamiento.

Conexion bibliografica

Sitzmann et al. (2020) (NeurIPS 2020): propone SIREN como representacion implicita neuronal con activacion periodica. Demuestra que las redes con $\phi(z) = \sin(\omega_0 z)$ aprenden soluciones de EDPs de forma mas precisa y rapida que ReLU o tanh para problemas con soluciones oscilatorias. La inicializacion especial $W_i \sim U(-\sqrt{6/n}/\omega_0, +\sqrt{6/n}/\omega_0)$ es clave para estabilizar las activaciones en todas las capas.

Calibracion ω_0 en este trabajo: el paper original usa $\omega_0 = 30$ para imagenes. En dominio adimensional $[0, 1]^2$ con $k = 2\pi$ se usa $\omega_0 \approx k/(2\pi) = 1,0$ para evitar explosion de gradientes.

2.3. Estrategia de optimizacion bifasica

Adam $\rightarrow$ L-BFGS

1. **Adam** (primer orden, estocastico): explora el paisaje de perdida durante $\approx 15,000$ epocas con $lr = 10^{-3}$. Usa momento adaptativo para escapar mesetas y minimos locales superficiales.
2. **L-BFGS** (cuasi-Newton, segundo orden): refina la solucion con convergencia cuadratica. Aproxima el Hessiano inverso usando un historial de gradientes (`history_size=100`). Busqueda de linea strong Wolfe garantiza descenso en cada iteracion.

Sinergia: Adam lleva los pesos a la cuenca de atraccion; L-BFGS los lleva al minimo con alta precision. Solo Adam da $L^2 \approx 1\%$; la combinacion logra $L^2 = 0,171\%$.

Nota critica: nunca usar *learning rate scheduler* antes de L-BFGS. Si Adam usa scheduler (decaimiento de lr), L-BFGS solo logra 7/1000 iteraciones en lugar de 1,035.

Conexion bibliografica

Kingma y Ba (2015) (ICLR 2015): propone Adam como optimizador adaptativo con momento de primer y segundo orden. Especialmente efectivo para funciones de perdida no convexas con multiples escalas de variacion.

Liu y Nocedal (1989) (Math. Programming, 1989): algoritmo L-BFGS original. La variante *strong Wolfe* garantiza las condiciones de Armijo y curvatura, asegurando descenso monotono. Convergencia cuadratica en vecindad del minimo.

Nocedal y Wright (2006) (cap. 7): analisis teorico de metodos cuasi-Newton para optimizacion no lineal; fundamento matematico de la estrategia bifasica.

3. NB01 — Validacion Helmholtz 1D

3.1. Configuracion experimental

Parametros NB01

Parametro	Valor	Justificacion
Arquitectura	SIREN 5×64	16,833 params; suficiente para $\cos(kx)$
ω_0	1.0	$\omega_0 \approx k/(2\pi) = 1$
λ_{fis}	1.0	1D: residuo unico, sin riesgo de overflow
N_{colloc}	1,000 uniforme	1D: cobertura uniforme optima
N_{boundary}	5 puntos	$x \in \{0, 0,25, 0,5, 0,75, 1\}$
Malla evaluacion	1,000 pts	Error L^2 preciso sin costo excesivo

Por que 5 puntos de frontera (no 2)? Con solo $E(0) = 1$ y $E(1) = \cos(k)$ la red puede colapsar a $E(x) = 1$ constante (satisface las BCs pero no Helmholtz). Los tres puntos intermedios con valores exactos de $\cos(kx)$ rompen esa degeneracion.

3.2. Resultados

Resultados NB01 (1D)

Metrica	Valor	Umbral
Error L^2	0.006 %	$< 5 \% \checkmark$
R^2	1.000000	$\approx 1 \checkmark$
Pearson	1.000000	$\approx 1 \checkmark$
Error abs. maximo	$5,73 \times 10^{-5}$	—
Error abs. medio (MAE)	$3,10 \times 10^{-5}$	—
Error relativo maximo	0.0111 %	$< 5 \% \checkmark$
Tiempo entrenamiento	251 s	—
L-BFGS iteraciones	202	—

El error $L^2 = 0,006 \%$ supera el umbral de la tesis ($< 5 \%$) por **tres ordenes de magnitud**.

Interpretacion de las graficas 1D (tres paneles)

Panel izquierdo — Histograma del error absoluto: Distribucion concentrada cerca de cero, simetrica, sin valores extremos. Media $3,10 \times 10^{-5}$, maximo $5,73 \times 10^{-5}$. Confirma estabilidad sin regiones de alta desviacion en el dominio.

Panel central — Error relativo puntual (%): Curva plana cercana a cero en todo $[0, 1]$. Maximo 0.0111 %, muy por debajo del umbral del 5 %. La PINN reproduce la oscilacion de $\cos(kx)$ con fidelidad uniforme.

Panel derecho — PINN vs Exacta (dispersion): Puntos alineados sobre la linea roja $y = x$ (ajuste perfecto). $R^2 = 1,000000$, Pearson= 1,000000. La red no solo predice bien en promedio; predice bien en *cada* punto del dominio.

Conexion bibliografica

La norma L^2 relativa es el estandar de facto en la literatura de PINNs para cuantificar la precision global (Raissi et al., 2019). La comparacion con Schoder y Kraxberger (2024) (error $L^2 \approx 2,49\%$ en 1D con activacion tanh) muestra una mejora de $\times 415$, atribuible a la capacidad intrinseca de la activacion sinusoidal para representar funciones oscilatorias.

4. NB02 — Validacion Helmholtz 2D (Campo Complejo)

4.1. Configuracion experimental

Parametros NB02

Parametro	Valor	Justificacion
Arquitectura	SIREN 5×128	66,690 params; campo complejo (2 salidas)
ω_0	1.0	Misma regla que NB01
λ_{fis}	0.1	Critico: 2 residuos duplican peso efectivo
N_{colloc}	3,000 LHS	LHS previene clustering en $[0, 1]^2$
N_{boundary}	1,200 total	300 por borde $\times$ 4 bordes
Malla evaluacion	$100 \times 100 = 10,000$	Balance precision/costo

Punto critico

Cambio critico: $\lambda_{\text{fis}} = 0,1$ (no 1,0 como en NB01). En 2D la perdida de fisica tiene **dos residuos**: $\mathcal{L}_{\text{real}}$ y $\mathcal{L}_{\text{imag}}$. Con $\lambda = 1,0$ el peso efectivo es $\approx 2,0$, lo que genera gradientes del orden 10^{38} en float32 $\rightarrow$ NaN $\rightarrow$ CUDA crash. Con $\lambda = 0,1$ el peso efectivo es 0,2: balance optimo verificado mediante ablacion (ver section 7).

Conexion bibliografica

Muestreo LHS (McKay et al., 1979): Latin Hypercube Sampling estratifica el espacio de entrada, garantizando que los 3,000 puntos de colocacion cubran el dominio sin clustering. En 2D, el muestreo aleatorio uniforme puede dejar zonas sin cobertura, lo que genera regiones de alta violacion de la EDP no penalizada.

Arquitectura 5×128 : el mayor numero de neuronas respecto a NB01 (5×64) refleja la mayor complejidad: dos salidas (E_r, E_i) y variacion en dos dimensiones. Sitzmann et al. (2020) recomienda aumentar el ancho de la red proporcional a la dimension del problema.

Malla 100×100 : compromise estandar en la literatura de PINNs. Una malla 1000×10^3 (10^6 puntos) es computacionalmente prohibitiva sin mejora proporcional en la estimacion del error global (Raissi et al., 2019).

4.2. Resultados 2D

Resultados NB02 (2D, campo complejo)

Metrica	Valor	Umbral
Error L^2 promedio	0.171 %	$< 5 \% \checkmark$
Error L^2 parte real	0.214 %	$< 5 \% \checkmark$
Error L^2 parte imag.	0.127 %	$< 5 \% \checkmark$
$R^2 (E_r)$	$\approx 0,999995$	$\approx 1 \checkmark$
$R^2 (E_i)$	$\approx 0,999998$	$\approx 1 \checkmark$
MAE (E_r)	$1,27 \times 10^{-3}$	—
MAE (E_i)	$7,71 \times 10^{-4}$	—
Tiempo entrenamiento	299 s	—
L-BFGS iteraciones	1,035	—

Interpretacion de las graficas 2D

Fila superior (Solucion exacta vs PINN): Mapas de color de E_r y E_i . La diferencia visual es practicamente nula; la red aprendo la onda plana compleja con fidelidad espacial.

Mapas de error absoluto: Errores del orden de 10^{-3} , distribuidos uniformemente sin zonas criticas. El mapa uniforme confirma que LHS cubrio el dominio de forma efectiva.

Intensidad $I = |E|^2$: Permite verificar que la red no solo reproduce E_r y E_i por separado, sino tambien la magnitud fisica correcta del campo.

Curvas de perdida (Adam + L-BFGS): Descenso rapido de Adam seguido de refinamiento brusco al iniciar L-BFGS. La “firma” de L-BFGS (pendiente casi vertical en log-escala) confirma convergencia cuadratica.

Sobre el error relativo: El error relativo espacial puede ser grande ($\approx 10\%$ en media o mayor) en regiones donde la solucion exacta se aproxima a cero (denominador pequeno). Esto es un artefacto de la definicion porcentual, no de la precision real. **Los errores absolutos ($\approx 10^{-3}$) son los indicadores relevantes.**

5. Metricas de Validacion

Norma L^2 relativa (metrica principal)

$$L_{\text{rel}}^2 = \frac{\|\hat{E} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2} = \frac{\sqrt{\sum_{i=1}^N (\hat{E}_i - E_i)^2}}{\sqrt{\sum_{i=1}^N E_i^2}}$$

Evaluada sobre una malla de $100 \times 100 = 10,000$ puntos (2D) o 1,000 puntos (1D), independientes de los puntos de entrenamiento. Esta independencia es crucial para que la metrica mida generalizacion, no memorizacion.

R^2 y correlacion de Pearson

$$R^2 = 1 - \frac{\sum(\hat{E}_i - E_i)^2}{\sum(E_i - \bar{E})^2} \quad \rho = \frac{\sum(\hat{E}_i - \bar{\hat{E}})(E_i - \bar{E})}{\sqrt{\sum(\hat{E}_i - \bar{\hat{E}})^2 \sum(E_i - \bar{E})^2}}$$

Valores de $R^2 = 1,000000$ y $\rho = 1,000000$ (NB01) confirman ajuste casi exacto punto a punto sobre toda la malla de evaluacion.

Conexion bibliografica

La norma L^2 es el estandar de la literatura de PINNs (Raissi et al., 2019). La malla de evaluacion 100×100 es un compromiso habitual en trabajos comparables; Schoder y Kraxberger (2024) usa mallas similares para evaluar la precision de sus PINNs en propagacion de ondas.

6. Reproducibilidad Multi-Semilla

Validacion multi-semilla (NB02)

Semilla	Error L^2 (%)	Epocas Adam	Resultado
42	$\approx 0,171$	$\approx 15,000$	OK
123	$\approx 0,126$	$\approx 14,200$	OK
777	$\approx 0,146$	$\approx 14,500$	OK
Media $\pm$ std 0,155 $\pm$ 0,020			

La variacion inter-semilla de $\pm 0,020\%$ es dos ordenes de magnitud menor que el umbral del 5 %, confirmando robustez estadistica. Aunque la semilla 123 da el menor error (0.126 %), se adopta la **semilla 42** como referencia por ser el estandar de reproducibilidad en ML.

Conexion bibliografica

La validacion multi-semilla es practica estandar en ML para distinguir resultados robustos de artefactos de inicializacion. La varianza inter-semilla equivale al “error de inicializacion” del metodo. El hecho de que $\sigma/\mu = 13\%$ con $\mu = 0,155\%$ (todo $\ll 5\%$) confirma que el metodo converge sistematicamente, no por azar. Sitzmann et al. (2020) tambien reportan estabilidad multi-semilla como criterio de calidad para arquitecturas SIREN.

Fuente verificada: [results/multiseed_results.json](#)

7. Ablacion del Peso de Fisica λ_{fs}

Rol de λ_{fis} en la funcion de perdida

λ_{fis} balancea la importancia relativa de las condiciones de frontera frente a la ecuacion diferencial:

$$\mathcal{L} = \mathcal{L}_{\text{BC}} + \lambda_{\text{fis}} \cdot \mathcal{L}_{\text{fisica}}$$

- $\lambda \rightarrow 0$: la red ajusta perfectamente las BCs pero ignora la EDP
- $\lambda \rightarrow \infty$: la EDP domina, las BCs se violan
- Optimo: balance entre ambos terminos

Ablacion verificada (results/ablation_lambda.json)

λ_{fis}	Error L^2	Estado	Observacion
0.01	0.163 %	OK	Sub-ponderacion de la fisica
0.1	0.171 %	Optimo	Balance fisica/frontera
1.0	CUDA crash	Fallo	Overflow float32

Explicacion del crash con $\lambda = 1,0$ (especifico de 2D): En 2D la perdida de fisica tiene DOS residuos (E_r y E_i), lo que duplica el peso efectivo a $\approx 2,0$. Los gradientes alcanzan $\sim 10^{38}$ en float32 $\rightarrow$ NaN $\rightarrow$ CUDA crash. En 1D (un solo residuo) $\lambda = 1,0$ es seguro.

Conexion bibliografica

La sensibilidad a λ_{fis} es un reto conocido en PINNs. Raissi et al. (2019) discuten brevemente la eleccion manual de pesos en la funcion de perdida compuesta. Trabajos posteriores como Wang et al. (2021) proponen metodos adaptativos para ajustar λ dinamicamente durante el entrenamiento, aunque el ajuste manual por ablacion sigue siendo practico para problemas bien caracterizados como Helmholtz.

El overflow en float32 con pesos grandes es una limitacion de precision numerica documentada en la literatura de entrenamiento de redes profundas; la solucion estandar (bajar λ) es coherente con la practica general (Nocedal y Wright, 2006).

8. Comparativa con el Estado del Arte

Factores de aceleracion vs Schoder & Kraxberger (2024)

Caso	Este trabajo (L^2)	Schoder 2024 (L^2)	Factor mejora
1D Helmholtz	0.006 %	$\approx 2,49$ %	$\times 415$
2D campo complejo	0.171 %	$\approx 1,92$ %	$\times 11,2$

Punto critico

Nota de validez de la comparacion: Schoder y Kraxberger (2024) trabajaron en **3D** con campos vectoriales; este trabajo opera en **1D/2D** con campo escalar complejo. La comparacion es *indicativa* del potencial de SIREN sobre activacion tanh para problemas de onda. El benchmark directo se realizara en **NB04** contra FEniCSx en las mismas condiciones geometricas.

Conexion bibliografica

Schoder y Kraxberger (2024): PINNs convencionales con activacion tanh para propagacion de ondas (acusticas y opticas) en 3D. Reportan precisiones del orden de 1–3% con tiempos de entrenamiento de horas. La activacion tanh satura sus derivadas de segundo orden, limitando la fidelidad de la perdida de fisica para la ecuacion de Helmholtz.

La mejora $\times 415$ en 1D se atribuye directamente a la activacion sinusoidal (Sitzmann et al., 2020): SIREN tiene derivadas de cualquier orden bien definidas, haciendo el residuo de Helmholtz diferenciable y bien condicionado durante todo el entrenamiento.

9. Hiperparametros: Justificacion Unificada

Razonamiento conjunto

La seleccion de hiperparametros obedece a un principio unificador: **equilibrar capacidad de representacion, estabilidad numerica y eficiencia computacional.**

- **5 capas:** profundidad minima para capturar patrones oscilatorios complejos sin caer en sobreajuste o dificultad de convergencia.
- **128 neuronas (2D):** anchura suficiente para representar variacion en dos dimensiones con dos salidas (E_r, E_i). En 1D, 64 neuronas son suficientes por la menor complejidad funcional.
- **Activacion $\sin(\omega_0 z)$:** refleja la naturaleza ondulatoria de la ecuacion de Helmholtz; derivadas de todo orden bien definidas.
- **Optimizacion hibrida Adam+L-BFGS:** convergencia rapida (Adam) y alta precision (L-BFGS); ni uno ni el otro son suficientes solos.
- **Condiciones de frontera coseno-seno:** garantizan la fidelidad fisica del campo complejo en el contorno, asegurando unicidad de la solucion.
- **LHS (3,000 pts):** cobertura uniforme garantizada en 2D, eliminando el sesgo de muestreo que dejaria regiones sin penalizacion de la EDP.

Referencias Bibliograficas

- Born, Max y Emil Wolf (1999). *Principles of Optics: Electromagnetic Theory of Propagation, Interference and Diffraction of Light*. 7th. Cambridge: Cambridge University Press.
- Kingma, Diederik P. y Jimmy Ba (2015). “Adam: A Method for Stochastic Optimization”. En: *arXiv preprint arXiv:1412.6980*. Publicado en ICLR 2015.
- Lagaris, Isaac E., Aristidis Likas y Dimitrios I. Fotiadis (1998). “Artificial neural networks for solving ordinary and partial differential equations”. En: *IEEE Transactions on Neural Networks* 9.5, págs. 987-1000. DOI: [10.1109/72.712178](https://doi.org/10.1109/72.712178).
- Liu, Dong C. y Jorge Nocedal (1989). “On the limited memory BFGS method for large scale optimization”. En: *Mathematical Programming* 45.1–3, págs. 503-528. DOI: [10.1007/BF01589116](https://doi.org/10.1007/BF01589116).
- McKay, Michael D., Richard J. Beckman y William J. Conover (1979). “A comparison of three methods for selecting values of input variables in the analysis of output from a computer code”. En: *Technometrics* 21.2, págs. 239-245. DOI: [10.1080/00401706.1979.10489755](https://doi.org/10.1080/00401706.1979.10489755).
- Nocedal, Jorge y Stephen J. Wright (2006). *Numerical Optimization*. 2nd. New York: Springer.
- Raissi, Maziar, Paris Perdikaris y George E. Karniadakis (2019). “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. En: *Journal of Computational Physics* 378, págs. 686-707. DOI: [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045).
- Schoder, Stefan y Florian Kraxberger (2024). “Physics-informed neural networks for the simulation of acoustic and optical wave propagation”. En: *Journal of Sound and Vibration*. Referencia para comparativa de aceleracion PINN vs metodos clasicos.
- Sitzmann, Vincent et al. (2020). “Implicit Neural Representations with Periodic Activation Functions”. En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33, págs. 7462-7473.