



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINN'S)**

PROTOCOLO DE TESIS
MAESTRÍA EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: Octubre de 2025

UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO

DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINN'S)**

PROTOCOLO DE TESIS
MAESTRÍA EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

JURADO REVISOR:
**PABLO PANCARDO GARCÍA
MIGUEL ANTONIO WISTER OVANDO
OSCAR ALBERTO CHÁVEZ BOSQUEZ**

CUNDUACÁN, TABASCO, A: Octubre de 2025

Índice

1. Antecedentes	1
2. Marco conceptual	2
3. Estado del arte	3
4. Planteamiento del problema	4
5. Preguntas de investigación	5
6. Hipótesis	6
7. Objetivos	6
7.1. Objetivo general	6
7.2. Objetivos específicos	6
8. Alcances y limitaciones	7
9. Justificación	8
10. Método	9
11. Contribución y resultados esperados	12
12. Cronograma	13
Referencias	14

1. Antecedentes

La simulación de la propagación de la luz es una herramienta fundamental en la ciencia y la ingeniería, con aplicaciones que abarcan desde el diseño de sistemas de telecomunicaciones y la nanofotónica hasta el desarrollo de técnicas de imagenología médica. Un fenómeno de particular interés es el speckle óptico, un patrón de interferencia complejo que surge cuando luz coherente, como la de un láser, se dispersa en un medio difusor o una superficie rugosa.

Tradicionalmente, la simulación de estos fenómenos ondulatorios se aborda mediante métodos numéricos robustos como el Método de Elementos Finitos (FEM) o métodos estocásticos como el de Monte Carlo. Sin embargo, estos métodos presentan un "cuello de botella" computacional significativo. Requieren una discretización (mallado) extremadamente fina del dominio espacial para resolver las rápidas oscilaciones del campo de luz, lo que resulta en un consumo masivo de memoria y tiempos de cómputo que pueden extenderse por días.

En paralelo, el campo de la inteligencia artificial ha experimentado un crecimiento disruptivo. Una innovación reciente son las Redes Neuronales Físicamente Informadas (PINNs, por sus siglas en inglés), una metodología que fusiona el Deep Learning con las leyes físicas fundamentales. Las PINNs (Raissi et al., 2019; Thuerey et al., 2021) son redes neuronales entrenadas no solo para ajustarse a datos, sino para obedecer directamente una Ecuación Diferencial Parcial (EDP) que gobierna un sistema.

Este proyecto se sitúa en la intersección de la óptica computacional y la inteligencia artificial, buscando aplicar el paradigma de las PINNs para superar las limitaciones computacionales de los métodos clásicos en la simulación de speckle óptico.

2. Marco conceptual

Para establecer una base sólida para esta investigación, es crucial definir los siguientes conceptos y sus interrelaciones:

Ecuación de onda de Helmholtz: Es la ley física fundamental que describe la propagación de ondas monocromáticas (de una sola frecuencia) en el espacio, como un frente de onda láser. Se expresa como una Ecuación Diferencial Parcial (EDP): $\nabla^2 E(x, y, z) + k^2 E(x, y, z) = 0$, donde E es el campo eléctrico (la luz), ∇^2 es el operador Laplaciano y k es el número de onda (relacionado con la longitud de onda y el medio).

Speckle óptico: Es el patrón de interferencia granular y de alto contraste que se observa cuando la luz coherente es dispersada por un medio ópticamente rugoso (Goodman, 2007). Es el resultado de la interferencia constructiva y destructiva de múltiples frentes de onda con fases aleatorias.

Método de Elementos Finitos (FEM): Un método numérico para resolver EDPs que funciona dividiendo un dominio complejo en un gran número de elementos simples (una "malla"), resolviendo la ecuación en cada elemento y ensamblando la solución global (Jin, 2014). Su precisión depende directamente de la densidad de la malla.

Redes Neuronales Físicamente Informadas (PINNs): Es una arquitectura de Deep Learning, en donde la red neuronal $N(x, t)$ aproxima la solución de una EDP. Su innovación radica en la función de pérdida (loss function). Esta función se compone de dos términos:

1. **Error de datos (L_{datos}):** Mide la discrepancia entre la predicción de la red y los valores conocidos (condiciones de frontera).

2. **Error físico ($L_{física}$):** Mide el "residuo" de la ecuación diferencial parcial. Se utilizan técnicas de diferenciación automática para calcular las derivadas de

la salida de la red (el campo E) e insertarlas en la Ecuación de Helmholtz. Si la ecuación no se cumple (el residuo no es cero), la red es penalizada. Esto la "fuerza" a aprender una solución que es físicamente precisa en todo el dominio (Cuomo et al., 2022), sin necesidad de una malla.

3. Estado del arte

El uso de redes neuronales para resolver EDPs fue propuesto inicialmente en los 90, pero ha sido revitalizado por el trabajo seminal de Raissi, Perdikaris y Karniadakis (Raissi et al., 2019) sobre PINNs, quienes demostraron su capacidad para resolver una amplia gama de problemas físicos. En este contexto, investigaciones recientes como la de Maiocchetti et al. (Maiocchetti et al., 2025) han validado la eficacia de las PINNs (específicamente en arquitecturas MLP) para resolver balances de energía y movimiento descritos por EDO y EDPs.

En el campo específico de la óptica y el electromagnetismo, la investigación ha comenzado a adoptar esta técnica. Estudios recientes (ej. Fang et al., 2020 (Fang & Zhan, 2020); Lu et al., 2021 (Lu et al., 2021)) han aplicado PINNs para resolver las ecuaciones de Maxwell y problemas de scattering (dispersión) de ondas en medios 2D y 3D, demostrando una alta precisión. En fotónica, se han utilizado para el diseño inverso de guías de onda y metasuperficies (Chen et al., 2020 (Chen et al., 2020)).

Sin embargo, se identifica una brecha en el conocimiento: la aplicación específica de PINNs para la simulación del speckle óptico en medios difusores complejos. El speckle es un problema notoriamente difícil debido a su naturaleza estadísticamente rica (Goodman, 2007) y las altas frecuencias espaciales que contiene. Donde estudios recientes en el uso de PINNs para resolver EDPs está consolidado. Específicamente, en la propagación de ondas, Schoder y Kraxberger Schoder y Kraxberger, 2024 realizaron un estudio de factibilidad resolviendo la Ecuación de Helmholtz, demostrando la viabilidad de la técnica

74 en entornos complejos.

75 Este estudio es clave para la presente investigación por sus resultados cuantitativos:

76 ■ **Precisión:** Se reportó un error relativo L_2 de 0.0249 (aproximadamente 2.5 %) en
77 la comparación entre la solución PINN y la solución FEM de referencia (malla fina)
78 para la propagación de onda.

79 ■ **Eficiencia:** Aunque el entrenamiento del PINN es costoso, la fase de inferencia
80 (predicción) fue comparada con la solución FEM, encontrando que la inferencia del
81 modelo PINN era más de 20,000 veces más rápida que la solución completa de
82 un caso equivalente en FEM, validando el valor de la inferencia acelerada para
83 problemas inversos y en tiempo real.

84 El problema de resolver la Ecuación Paraxial en 2D para generar *speckle* se ajusta
85 a este marco, aprovechando la velocidad de inferencia de las PINNs para superar las
86 limitaciones de memoria de FEM en simulaciones de dominios grandes.

87 4. Planteamiento del problema

88 La simulación precisa de cómo la luz se dispersa y forma patrones de speckle es
89 crucial para el diseño de sistemas ópticos avanzados en imagenología biomédica (ej. to-
90 mografía de coherencia óptica), metrología (medición de vibraciones) y seguridad (crip-
91 tografía óptica).

92 El desafío central radica en el costo computacional prohibitivo de los métodos numé-
93 ricos actuales:

- 94 1. **Métodos Basados en Malla (FEM):** Para capturar con precisión los detalles finos
95 de un patrón de speckle, la malla debe tener una resolución espacial menor que
96 la longitud de onda de la luz (Jin, 2014). Esto conduce a sistemas de ecuaciones

con millones (o miles de millones) de incógnitas, requiriendo clústeres de cómputo de alto rendimiento, una cantidad masiva de memoria RAM y tiempos de ejecución que frenan la investigación.

2. Métodos basados en trazado de rayos (Monte Carlo): Requieren simular un número astronómico de fotones individuales para construir un patrón de interferencia estadísticamente preciso, lo que los hace extremadamente lentos.

Este cuello de botella limita significativamente la capacidad de los científicos e ingenieros para modelar medios difusores complejos, optimizar diseños ópticos o realizar simulaciones 3D a gran escala.

Aunque la aplicación de las PINNs para resolver la ecuación de Helmholtz ha sido validada en simulaciones de ondas acústicas (Schoder & Kraxberger, 2024), hasta donde alcanza nuestro conocimiento, la aplicación de este paradigma para la simulación eficiente de speckle óptico de alta resolución no ha sido abordada sistemáticamente.

Por lo tanto, existe la necesidad urgente de un nuevo paradigma computacional que sea "libre de malla"(mesh-free), eficiente en el uso de memoria y capaz de acelerar estas simulaciones en un orden de magnitud, sin sacrificar la precisión dictada por la física fundamental (la ecuación de Helmholtz).

5. Preguntas de investigación

1. ¿Puede un modelo de Red Neuronal Físicamente Informada (PINN) aproximar con precisión la solución de la ecuación de onda de Helmholtz para la simulación de patrones de speckle óptico en medios difusores 2D?
2. ¿Cuál es la ganancia en eficiencia computacional (tiempo de cómputo y uso de memoria) del enfoque basado en PINNs en comparación con un FEM para simular el mismo fenómeno de speckle?

- 121 3. ¿Cómo impacta la complejidad del medio difusor (ej. rugosidad de la superficie) en
122 la precisión y el tiempo de entrenamiento del modelo PINN?

123 6. Hipótesis

124 El desarrollo de un modelo computacional basado en Redes Neuronales Físicamen-
125 te Informadas (PINNs) para la resolución de la ecuación de Helmholtz en 2D permitirá
126 simular la generación de speckle óptico logrando una aceleración en el tiempo de infe-
127 rencia de al menos un orden de magnitud ($10\times$) respecto al Método de Elementos Finitos
128 (FEM). Asimismo, se mantendrá una precisión física validada mediante un error relativo
129 $L_2 < 5\%$ y se preservarán las propiedades estadísticas del fenómeno, específicamente
130 un Contraste de Speckle (C) con una desviación menor al 5% respecto a la teoría de
131 Goodman Goodman, 2007.

132 7. Objetivos

133 7.1. Objetivo general

134 Construir un modelo computacional basado en PINNs para la simulación acelerada y
135 físicamente precisa de frentes de onda y speckle óptico, mediante la resolución directa
136 de la ecuación de Helmholtz.

137 7.2. Objetivos específicos

- 138 ■ Definir una arquitectura de red neuronal profunda (PINN) que incorpore el residuo
139 de la ecuación de Helmholtz en su función de pérdida.
- 140 ■ Entrenar y validar la precisión base del modelo PINNs en un escenario simple (pro-
141 pagación 2D en espacio libre) comparando sus resultados con la solución analítica

conocida (utilizando el Error L_2)

- Aplicar el modelo validado a la simulación de speckle óptico en medios difusores complejos y validar su precisión utilizando métricas ópticas estadísticas clave.
- Evaluar y comparar cuantitativamente el rendimiento (precisión, eficiencia de inferencia y uso de memoria) del modelo PINN contra una implementación de referencia del FEM para demostrar una aceleración de al menos $10\times$ en el tiempo de predicción.

8. Alcances y limitaciones

Para definir con claridad los límites de la investigación, se establecen los siguientes puntos:

Alcances

- El proyecto entregará un prototipo de software funcional, implementado en Python (PyTorch o TensorFlow), capaz de construir y entrenar un modelo PINN para resolver la ecuación de Helmholtz en dominios 2D.
- Se validará cuantitativamente la precisión del modelo PINN contra una solución analítica conocida (propagación de onda Gaussiana en espacio libre 2D).
- El modelo será capaz de simular la generación de patrones de speckle óptico en 2D, mediante la introducción de una frontera con fase aleatoria.
- Se realizará una evaluación comparativa (benchmark) en términos de precisión, tiempo de cómputo y uso de memoria contra un método numérico estándar (FEM).

Limitaciones

- **Dimensionalidad:** La limitación principal del proyecto es su dimensionalidad. Todas las simulaciones, validaciones y comparativas se restringirán a dominios de dos dimensiones (2D). El desarrollo y la simulación en 3D completo están fuera del alcance de este trabajo de maestría.
- **Alcance computacional:** Esta es una investigación puramente *computacional* y de *simulación*. No se incluye la construcción de montajes ópticos experimentales ni la validación del modelo contra datos físicos reales.
- **Simplificación del medio:** El medio difusor se modelará como una *frontera* con fase aleatoria. El proyecto no abordará la simulación de medios difusores volumétricos complejos o medios con propiedades ópticas no lineales.

9. Justificación

Este proyecto de investigación se justifica en tres ejes principales:

- **Justificación computacional:** El principal obstáculo en la simulación óptica avanzada es el costo computacional prohibitivo de los métodos numéricos actuales, como el FEM y Monte Carlo. Estos métodos imponen un "cuello de botella" que frena la iteración y el diseño. Esta investigación se justifica al proponer un nuevo paradigma "libre de malla" (mesh-free) que busca reducir los tiempos de simulación en órdenes de magnitud.
- **Justificación científica y de aplicación:** La simulación precisa de *speckle* no es un problema puramente teórico; es crucial para el avance de tecnologías aplicadas. Campos como la imagenología biomédica (ej. tomografía de coherencia óptica), la

metrología de precisión y la criptografía óptica dependen directamente de un entendimiento y modelado profundo de la dispersión de la luz. Acelerar la simulación impacta directamente en la capacidad de innovar en estas áreas.

- **Justificación metodológica y programática:** El proyecto se alinea estratégicamente con la Línea de Generación y Aplicación del Conocimiento (LGAC) en Ciencia de datos e inteligencia artificial de la Maestría en Ciencias de la Computación. Se justifica al aplicar una técnica de vanguardia en Deep Learning (PINNs) para resolver una Ecuación Diferencial Parcial fundamental de la física, demostrando la sinergia entre la IA y la ciencia computacional avanzada.

10. Método

La metodología se basa en el marco de trabajo de las PINNs propuesto por Raissi et al., 2019, adaptado para la ecuación de Helmholtz. Este proyecto es un estudio de investigación computacional cuantitativo y experimental. Se desarrollará en fases alineadas con los objetivos específicos, utilizando herramientas de la LGAC de Ciencia de Datos e Inteligencia Artificial.

Fase 1: Desarrollo y arquitectura del modelo

- **Herramientas:** Se utilizará Python 3.x. La red neuronal se implementará usando la biblioteca PyTorch (o TensorFlow), debido a su robusto módulo de diferenciación automática (Autodiff).
- **Arquitectura de red:** Se diseñará un Perceptrón Multicapa (MLP) que toma como entrada coordenadas espaciales (x, y) y retorna el campo de luz complejo $E(x, y)$ (representado por sus partes real e imaginaria).
- **Función de Pérdida:** Se implementará la función de pérdida compuesta

$$L_{total} = L_{datos} + \lambda L_{física}.$$

1. L_{datos} será un Error Cuadrático Medio (MSE) sobre las condiciones de frontera conocidas (ej. el frente de onda láser incidente).
2. $L_{física}$ será el MSE del residuo de la ecuación de Helmholtz ($\nabla^2 E + k^2 E = 0$), evaluado en puntos de colocación muestreados aleatoriamente dentro del dominio. La diferenciación automática de PyTorch se usará para calcular $\nabla^2 E$.




Figura 1. Esquema conceptual de la arquitectura de una Red Neuronal Físicamente Informada (PINN). La red (NN) predice la solución (u), cuyas derivadas alimentan el residuo de la Ecuación Diferencial Parcial (EDP) para calcular la pérdida de física (MSE_R).

Nota. Adaptado de "Ppinn: Parareal physics-informed neural network for time-dependent pdes," por X. Meng, Z. Li, D. Zhang, y G. E. Karniadakis, 2020, *Computer Methods in Applied Mechanics and Engineering*, 370, 113250.

Fase 2: Validación analítica y estrategia de entrenamiento

Se entrenará el modelo para la propagación de una onda gaussiana en espacio libre.

- **Muestreo (Collocation Points):** Se utilizará Muestreo Latino Hipercúbico (LHS,

por sus siglas en inglés Latin Hypercube Sampling) para seleccionar los puntos de colocación dentro del dominio Ω , garantizando una cobertura espacial más eficiente que una malla aleatoria simple.

- **Optimizador Híbrido:** Para acelerar la convergencia y evitar mínimos locales, se empleará una estrategia de dos etapas: primero el optimizador Adam para una aproximación global rápida, seguido del optimizador de segundo orden L-BFGS para el ajuste fino de alta precisión, siguiendo la metodología validada por Schoder y Kraxberger, 2024.
- **Evaluación:** La métrica de evaluación será el error L_2 relativo para validar la precisión del modelo.

Fase 3: Experimentación y comparativa

Se introducirá una frontera con fase aleatoria para generar speckle y se comparará contra un benchmark FEM (ej. FEniCS o COMSOL).

Evaluación de Métricas de Rendimiento: Para validar la mejora computacional, se aplicarán las siguientes métricas estándar en *Scientific Machine Learning* (Karniadakis et al., 2021; Thuerey et al., 2021):

1. **Factor de Aceleración (Speed-up Factor):** Razón entre el tiempo de ejecución del solver FEM (T_{FEM}) y el tiempo de inferencia de la PINN (T_{PINN}):

$$S = \frac{T_{FEM}}{T_{PINN}} \quad (1)$$

2. **Huella de Memoria Pico (Peak Memory Footprint):** Monitorización del uso máximo de RAM/VRAM para demostrar que el enfoque PINN evita el crecimiento exponencial de memoria asociado al mallado denso.
3. **Grados de Libertad por Segundo (DOFs/sec):** Tasa de puntos del cam-

po óptico resueltos por unidad de tiempo

$$\eta = \frac{N_{puntos}}{T_{cmputo}} \quad (2)$$

11. Contribución y resultados esperados

Contribución

El resultado principal de esta investigación será un nuevo paradigma computacional "libre de malla"(mesh-free) para la simulación de fenómenos de dispersión de luz coherente. Esta contribución es relevante para la LGAC de Ciencia de Datos e Inteligencia Artificial, ya que aplica una técnica de Deep Learning de vanguardia (PINNs) para resolver un problema físico complejo (ecuación de Helmholtz) que actualmente sufre de un cuello de botella computacional con métodos tradicionales.

Resultados Esperados

1. Un prototipo de software funcional, implementado en Python y PyTorch, capaz de simular la generación de speckle óptico en 2D.
2. Un análisis cuantitativo y comparativo (presentado en tablas y gráficas) que demuestre la ganancia en eficiencia computacional (tiempo y memoria) del modelo PINN sobre el método FEM.
3. La validación de la precisión del modelo PINN, demostrando que puede generar patrones de speckle estadísticamente equivalentes a los métodos de referencia.
4. La generación de al menos un artículo científico derivado de los hallazgos, para ser enviado a una revista indexada o un congreso especializado en óptica

260

computacional o inteligencia artificial aplicada.

261

12. Cronograma

262

La tabla 1 resume las actividades programadas.

263

	2025					2026							2027									
	1º Semestre					2º Semestre				3º Semestre			4º Semestre									
	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN	JUL	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY
1. Revisión de literatura																						
2. Definición del problema																						
3. Diseño y desarrollo (Fase 1)																						
4. Validación analítica (Fase 2)																						
5. Implementación Benchmark FEM																						
6. Experimentación Speckle (Fase 3)																						
7. Evaluación comparativa (Fase 3)																						
8. Optimización del modelo																						
9. Análisis de resultados																						
10. Redacción y revisión de tesis																						
11. Redacción y envío de artículo																						
12. Presentación de la tesis																						

Tabla 1. Diagrama de Gantt de actividades.

Referencias

- Chen, Y., Lu, L., Karniadakis, G. E., & Dal Negro, L. (2020). Physics-informed neural networks for inverse problems in nano-optics and plasmonics. Optics Express, 28(8), 11618-11633. <https://doi.org/10.1364/OE.384875>
- Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific machine learning through physics-informed neural networks: A review. Journal of Computational Science, 62, 101709. <https://doi.org/10.1016/j.jocs.2022.101709>
- Fang, Z., & Zhan, J. (2020). A physics-informed neural network framework for wave scattering in inhomogeneous media. IEEE Antennas and Wireless Propagation Letters, 19(9), 1640-1644. <https://doi.org/10.1109/ACCESS.2019.2963390>
- Goodman, J. W. (2007). Speckle Phenomena in Optics: Theory and Applications. Roberts; Company Publishers.
- Jin, J.-M. (2014). The Finite Element Method in Electromagnetics. John Wiley & Sons.
- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. Nature Reviews Physics, 3(6), 422-440. <https://doi.org/10.1038/s42254-021-00314-5>
- Lu, L., Meng, X., Mao, Z., & Karniadakis, G. E. (2021). DeepXDE: A deep learning library for solving differential equations. SIAM Review, 63(1), 208-228. <https://doi.org/10.1137/19M1274067>
- Maiocchetti, E., Irigoyen Gordo, E., Larrea, M., & Tronci, S. (2025). Estudio de las Redes PINN como modelos de sistemas dinámicos. XX Simposio CEA de Control Inteligente. <https://doi.org/10.64117/simposioscea.v1i2.88>
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. Journal of Computational Physics, 378, 686-707. <https://doi.org/10.1016/j.jcp.2018.10.045>

Schoder, S., & Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. arXiv preprint arXiv:2403.06623v1. <https://doi.org/10.48550/arXiv.2403.06623>

Thuerey, N., Holl, P., Mueller, M., Schnell, P., Trost, F., & Um, K. (2021). Physics-based Deep Learning. Independently published. <https://physicsbaseddeeplearning.org>