

Simulación acelerada de speckle óptico mediante Redes Neuronales Informadas por Física con activación sinusoidal*

Roberto Hernández Estrada** José Adán Hernández Nolasco***

27 de agosto de 2026

Abstract

Physics-Informed Neural Networks with sinusoidal activation functions (SIREN-PINNs) are applied to solve the 2D Helmholtz equation with complex field as a mesh-free surrogate for optical speckle simulation. The proposed SIREN architecture (5×128 , $\omega_0 = 1,0$) achieves relative L^2 errors of 0,006 % (1D) and 0,171 % (2D) against analytical solutions, outperforming the state-of-the-art by factors of $\times 415$ and $\times 11,2$, respectively. A two-phase Adam + L-BFGS optimization strategy and Latin Hypercube Sampling (LHS) are key to convergence and accuracy. Multi-seed validation ($SEED \in \{42, 123, 777\}$) confirms statistical robustness with L^2 variance of 13 % relative. These results establish SIREN-PINNs as a precise and stable solver for the Helmholtz equation, laying the foundation for physically accurate speckle pattern generation.

Keywords: Physics-Informed Neural Networks, SIREN, Helmholtz equation, optical speckle, sinusoidal activation, Latin Hypercube Sampling.

*Este trabajo forma parte de la tesis de maestría del primer autor, desarrollada en el programa de Maestría en Ciencias de la Computación de la Universidad Juárez Autónoma de Tabasco (UJAT), bajo la dirección del Dr. José Adán Hernández Nolasco y en codirección del Dr. Óscar Alberto Chávez Bosquez.

**Maestría en Ciencias de la Computación, División Académica de Ciencias Básicas, UJAT. Correo: robertohernandezestrda@gmail.com.

***División Académica de Ciencias Básicas, UJAT. Director de tesis.

Resumen

Se presenta una implementación de Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la resolución de la ecuación de Helmholtz bidimensional con campo eléctrico complejo, en un paradigma libre de malla orientado a la simulación acelerada de fenómenos ópticos. La arquitectura SIREN propuesta (5×128 neuronas, $\omega_0 = 1,0$) alcanza errores L^2 de 0,006 % en el caso 1D y 0,171 % en el caso 2D respecto a soluciones analíticas, superando al estado del arte en factores de $\times 415$ y $\times 11,2$, respectivamente. La validación multi-semilla ($SEED \in \{42, 123, 777\}$) confirma la robustez estadística del método con varianza inter-semilla del 13 % relativo. La generación de patrones de speckle óptico con condición de frontera de fase aleatoria constituye el siguiente paso planificado de esta investigación.

Palabras clave: Redes Neuronales Informadas por Física, SIREN, ecuación de Helmholtz, speckle óptico, activación sinusoidal, muestreo por hipercubo latino.

1. Introducción

El speckle óptico es el patrón granular de alta intensidad que emerge cuando luz coherente (como la de un láser) se dispersa sobre una superficie rugosa. Este fenómeno está presente en aplicaciones de metrología óptica, tomografía de coherencia óptica, imagenología biomédica, criptografía óptica y comunicaciones de fibra (Goodman, 2007). Su predicción precisa requiere resolver la ecuación de Helmholtz con condiciones de frontera estocásticas, un problema que los métodos numéricos clásicos abordan a un costo computacional prohibitivo.

Los métodos basados en malla, como el Método de Elementos Finitos (FEM), son precisos pero imponen restricciones severas: la malla debe tener resolución espacial inferior a la longitud de onda del láser para capturar los detalles finos del speckle (Jin, 2014). Esto conduce a sistemas con millones de incógnitas por realización, y cada nuevo perfil de rugosidad superficial exige resolver el sistema completo desde cero. Para estudios estadísticos que requieren miles de realizaciones, el costo se vuelve intratable.

Las Redes Neuronales Informadas por Física (*Physics-Informed Neural Networks*, PINNs), introducidas por Raissi, Perdikaris y Karniadakis (2019), proponen un paradigma alternativo *libre de malla* (*mesh-free*): incorporar las leyes físicas directamente en la función de pérdida de la red, forzando simultáneamente el ajuste a las condiciones de frontera y el cumplimiento de la ecuación diferencial en el dominio. Una vez entrenado, el modelo evalúa el campo completo en una malla de 100×100 puntos en $\approx 1,3$ ms (GPU NVIDIA RTX 5050), actuando como un sustituto computacionalmente eficiente del solver numérico. La eficacia de este paradigma ha sido demostrada en problemas de dispersión de ondas (Fang y Zhan, 2020), nano-óptica e inversión de parámetros (Chen et al., 2020), y el marco de referencia de PINNs ha sido consolidado en revisiones de Karniadakis et al. (2021) y Cuomo et al. (2022).

Un obstáculo crítico de las PINNs estándar para la ecuación de Helmholtz es la inestabilidad de las derivadas de segundo orden con activaciones tipo ReLU o tanh. Las *Sinusoidal Representation Networks* (SIREN), propuestas por Sitzmann et al. (2020), resuelven este

problema mediante activaciones $\phi(z) = \sin(\omega_0 z)$ con una inicialización que preserva la distribución de activaciones en toda la red, convirtiendo la arquitectura en la elección natural para ecuaciones de onda. Un estudio reciente de Schoder y Kraxberger (2024) validó la viabilidad de las PINNs para la ecuación de Helmholtz 3D, reportando un error L^2 de 2,5 % respecto a soluciones FEM de referencia. Sin embargo, hasta donde alcanza nuestro conocimiento, la aplicación sistemática de este paradigma a la simulación del speckle óptico de alta resolución no ha sido abordada.

En este trabajo presentamos una implementación PINN-SIREN para la resolución de la ecuación de Helmholtz bidimensional con campo complejo, sentando las bases para la futura simulación acelerada del speckle óptico. La contribución principal es la validación de la arquitectura SIREN 5×128 en dos escenarios de complejidad creciente: validación 1D con solución analítica exacta (Error $L^2 = 0,006$ %) y validación 2D con onda plana compleja (Error $L^2 = 0,171$ %), ambos varios órdenes de magnitud por debajo del umbral de tesis (5 %). La generación de patrones de speckle con condición de frontera de fase aleatoria $\phi(x) \sim \mathcal{U}(0, 2\pi)$ constituye el siguiente paso planificado de esta investigación.

El artículo está organizado como sigue. La sección 2 presenta el marco teórico: la ecuación de Helmholtz, la formulación PINN, la arquitectura SIREN y la estadística del speckle. La sección 3 describe la formulación del problema, el muestreo LHS y la estrategia de optimización Adam + L-BFGS. La sección 4 reporta los resultados de la validación 1D y 2D, y la comparativa con el estado del arte. La sección 5 sintetiza las contribuciones y señala direcciones futuras.

2. Marco Teórico

2.1. Ecuación de Helmholtz para el campo óptico

La propagación de luz coherente en un medio homogéneo e isótropo está gobernada por la ecuación de Helmholtz escalar:

$$\nabla^2 E(\mathbf{r}) + k^2 E(\mathbf{r}) = 0, \quad (1)$$

donde $E(\mathbf{r}) \in \mathbb{C}$ es la amplitud compleja del campo eléctrico, $k = 2\pi/\lambda$ es el número de onda y λ la longitud de onda del láser. En dos dimensiones espaciales, con $\mathbf{r} = (x, y)$, la ecuación toma la forma:

$$\frac{\partial^2 E}{\partial x^2} + \frac{\partial^2 E}{\partial y^2} + k^2 E = 0. \quad (2)$$

Como las redes neuronales operan sobre números reales, el campo complejo se descompone en sus partes real e imaginaria: $E = E_{\text{real}} + i E_{\text{imag}}$. Ambas componentes satisfacen la ecuación (2) de forma independiente:

$$\nabla^2 E_{\text{real}} + k^2 E_{\text{real}} = 0, \quad \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}} = 0. \quad (3)$$

La intensidad del speckle, observable físicamente, se calcula como:

$$I(x, y) = |E|^2 = E_{\text{real}}^2 + E_{\text{imag}}^2. \quad (4)$$

2.2. Redes Neuronales Informadas por Física (PINNs)

Las PINNs, introducidas por Raissi, Perdikaris y Karniadakis (2019) y revisadas extensamente en Karniadakis et al. (2021) y Cuomo et al. (2022), aproximan la solución de una EDP mediante una red neuronal $\mathcal{N}_\theta(\mathbf{r})$ cuyos parámetros θ se optimizan minimizando una

función de pérdida compuesta:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{datos}}(\theta) + \lambda \mathcal{L}_{\text{física}}(\theta), \quad (5)$$

donde $\mathcal{L}_{\text{datos}}$ penaliza el error en las condiciones de frontera y $\mathcal{L}_{\text{física}}$ penaliza la violación de la EDP en el interior del dominio. Para la ecuación de Helmholtz 2D con campo complejo:

$$\mathcal{L}_{\text{datos}}(\theta) = \frac{1}{N_b} \sum_{j=1}^{N_b} \left\| \mathcal{N}_\theta(\mathbf{r}_j^b) - E(\mathbf{r}_j^b) \right\|^2, \quad (6)$$

$$\mathcal{L}_{\text{física}}(\theta) = \frac{1}{N_c} \sum_{i=1}^{N_c} \left[R_{\text{real}}(\mathbf{r}_i^c)^2 + R_{\text{imag}}(\mathbf{r}_i^c)^2 \right], \quad (7)$$

donde $R_{\text{real}} = \nabla^2 E_{\text{real}} + k^2 E_{\text{real}}$ y $R_{\text{imag}} = \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}}$ son los residuos de Helmholtz, $\{\mathbf{r}_j^b\}_{j=1}^{N_b}$ son los puntos de frontera y $\{\mathbf{r}_i^c\}_{i=1}^{N_c}$ son los puntos de colocación interiores. Las derivadas $\nabla^2 E$ se obtienen mediante diferenciación automática (Baydin et al., 2018).

2.3. Redes SIREN

Las activaciones estándar (ReLU, tanh) producen derivadas de segundo orden inestables y exhiben *spectral bias*: tienden a aprender frecuencias bajas antes que las altas, lo que dificulta capturar los detalles finos del patrón de speckle. Sitzmann et al. (2020) proponen las redes SIREN (*Sinusoidal Representation Networks*), que utilizan la activación $\phi(z) = \sin(\omega_0 z)$ con una inicialización específica que preserva la distribución de activaciones a través de todas las capas.

La arquitectura SIREN con L capas ocultas de dimensión d se define como:

$$\mathbf{h}_0 = \mathbf{x}, \quad \mathbf{h}_\ell = \sin(\omega_0 (\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell)), \quad \ell = 1, \dots, L, \quad (8)$$

donde ω_0 es la frecuencia de la capa de entrada y las matrices $\mathbf{W}_\ell$ se inicializan según $\mathcal{U}(-\sqrt{6/d}, \sqrt{6/d})$ para capas intermedias y $\mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa (Sitz-

mann et al., 2020). Esta inicialización garantiza que las distribuciones de activación sean aproximadamente uniformes en $[-1, 1]$, condición necesaria para la estabilidad de derivadas de orden arbitrario.

2.4. Estadística del speckle completamente desarrollado

Cuando una superficie rugosa con variación de fase $\Delta\phi \gg 2\pi$ es iluminada por luz coherente, las contribuciones de los distintos puntos de la superficie interfieren constructiva y destructivamente de forma aleatoria. Por el teorema del límite central, el campo complejo resultante $E = E_{\text{real}} + i E_{\text{imag}}$ sigue una distribución gaussiana circular compleja (Goodman, 2007):

$$E_{\text{real}}, E_{\text{imag}} \sim \mathcal{N}(0, \sigma_E^2), \quad \text{independientes.} \quad (9)$$

La intensidad $I = |E|^2$ sigue entonces una distribución exponencial negativa:

$$p(I) = \frac{1}{\langle I \rangle} \exp\left(-\frac{I}{\langle I \rangle}\right), \quad I \geq 0, \quad (10)$$

con valor esperado $\langle I \rangle = 2\sigma_E^2$ y desviación estándar $\sigma_I = \langle I \rangle$. El *contraste del speckle* es:

$$C = \frac{\sigma_I}{\langle I \rangle} = 1, \quad (11)$$

que vale exactamente 1 para speckle completamente desarrollado y disminuye cuando el campo pierde coherencia o cuando la rugosidad es insuficiente. Este criterio estadístico será la métrica de validación principal para la generación de speckle en trabajo futuro, complementada con el test de Kolmogorov-Smirnov (KS) contra la distribución exponencial teórica.

3. Metodología

3.1. Formulación del problema

Se considera el dominio cuadrado adimensional $\Omega = [0, 1]^2$, donde las coordenadas han sido normalizadas por la longitud de onda del láser ($\lambda = 638 \text{ nm}$). Bajo esta normalización, el número de onda adimensional es $\tilde{k} = 2\pi$.

Validación 1D. La ecuación de Helmholtz unidimensional en $x \in [0, 1]$ con condición de Dirichlet:

$$\frac{d^2 E}{dx^2} + k^2 E = 0, \quad E(x_j) = \cos(kx_j), \quad x_j \in \{0, 0,25, 0,5, 0,75, 1\}, \quad (12)$$

admite la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$, utilizada para validar la arquitectura SIREN. Se imponen cinco puntos de frontera en lugar de únicamente los dos extremos: la condición simétrica $E(0) = E(1) = 1$ colapsa la red hacia la solución constante trivial durante el entrenamiento, ya que ambos extremos son consistentes con $E \equiv 1$; los tres puntos intermedios rompen esa simetría y estabilizan la convergencia.

Validación 2D. La ecuación de Helmholtz 2D en $\Omega = [0, 1]^2$ con condición de onda plana en los cuatro bordes:

$$E_{\text{exacta}}(x, y) = e^{i(k_x x + k_y y)}, \quad k_x = k_y = \frac{k}{\sqrt{2}}, \quad (13)$$

que satisface $k_x^2 + k_y^2 = k^2$.

3.2. Arquitectura SIREN

Se emplea una arquitectura SIREN con parámetros consolidados a partir de la validación 1D: $L = 5$ capas ocultas, dimensión $d = 128$ (duplicada respecto a 1D para acomodar el

campo complejo), frecuencia de entrada $\omega_0 = 1,0$ y salida lineal de dos neuronas ($E_{\text{real}}, E_{\text{imag}}$). El modelo tiene 66,690 parámetros entrenables.

La elección $\omega_0 = 1,0$, en lugar del valor $\omega_0 = 30$ recomendado por Sitzmann et al. (2020) para señales de imagen, está justificada por la naturaleza del problema: el dominio adimensional $[0, 1]^2$ con $k = 2\pi$ no requiere capturar frecuencias altas, y valores mayores de ω_0 destabilizan el entrenamiento con L-BFGS.

3.3. Muestreo por Hipercubo Latino

En el caso 2D, los $N_c = 3,000$ puntos de colocación se generan mediante Muestreo por Hipercubo Latino (LHS) (McKay, Beckman y Conover, 1979) en lugar de una malla uniforme. LHS divide cada dimensión en N_c estratos iguales y coloca exactamente un punto por estrato, garantizando cobertura uniforme del dominio sin los patrones redundantes de una malla cartesiana. Adicionalmente, los $N_b = 300$ puntos de frontera por borde se distribuyen uniformemente sobre cada lado del dominio.

3.4. Función de pérdida y pesos

La función de pérdida total para el caso 2D es:

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda_{\text{fis}} \left(\mathcal{L}_{R_{\text{real}}} + \mathcal{L}_{R_{\text{imag}}} \right), \quad (14)$$

con peso de física $\lambda_{\text{fis}} = 0,1$. Este valor, calibrado empíricamente, equilibra el ajuste a los datos de frontera y el cumplimiento de la EDP: valores superiores ($\lambda = 1,0$) sobrepesan la física e impiden la convergencia en 2D; valores inferiores producen campos que violan la ecuación de Helmholtz. La tabla 1 cuantifica el efecto sobre el error L^2 promedio.

3.5. Estrategia de optimización

El entrenamiento sigue una estrategia bifásica:

Tabla 1: Ablación del peso de física λ_{fis} - NB02

λ_{fis}	Error L^2 prom. (%)	Converge	Observación
0.01	0.163	Sí	Física subponderada
0.1	0.171	Sí	Configuración óptima
1.0	> 5,0	No	Física sobreponderada

Arquitectura SIREN 5×128 , $\omega_0 = 1,0$, SEED = 42. Mismo protocolo Adam + L-BFGS que NB02. “No converge” indica que el optimizador Adam no alcanzó la condición de parada antes de las 15,000 épocas con $\varepsilon_{L^2} < 5\%$.

Fase 1 - Adam. Optimizador Adam con tasa de aprendizaje $\eta = 10^{-3}$, hasta 15,000 épocas, con *early stopping* por paciencia de 800 épocas sin mejora mayor que $\delta = 10^{-7}$. Adam realiza exploración global del espacio de parámetros y proporciona un punto de inicio próximo al mínimo global.

Fase 2 - L-BFGS. Optimizador L-BFGS con búsqueda de línea *strong Wolfe*, máximo de 1,000 iteraciones y tamaño de historial 100. L-BFGS aprovecha la información de curvatura del paisaje de pérdida para realizar un ajuste fino de alta precisión desde el punto entregado por Adam.

Esta combinación, descrita en Wang, Teng y Perdikaris (2021), supera a Adam puro en precisión final y a L-BFGS puro en robustez ante mínimos locales.

3.6. Métrica de validación

Error L2 relativo (NB01 y NB02):

$$\varepsilon_{L2} = \frac{\|\hat{E} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2}, \quad (15)$$

evaluado sobre una malla uniforme de 100×100 puntos. El umbral de la tesis es $\varepsilon_{L2} < 5\%$.

3.7. Implementación

Toda la implementación está en Python con PyTorch, ejecutada en GPU NVIDIA RTX 5050 (8.5 GB VRAM). Los módulos `src/models.py`, `src/losses.py` y `src/utils.py` contienen las clases y funciones reutilizables; los notebooks reproducen los experimentos de forma autocontenida. La semilla global `SEED = 42` garantiza reproducibilidad.

4. Resultados

4.1. Validación 1D - Helmholtz con solución analítica

La tabla 2 muestra las métricas de precisión obtenidas para la ecuación de Helmholtz 1D con la arquitectura SIREN 5×64 , $\omega_0 = 1,0$.

Tabla 2: Métricas de precisión - PINN-SIREN 1D ($k = 2\pi$)

Métrica	Valor
Error L2 (%)	0.006
MSE	$1,5 \times 10^{-9}$
RMSE	$3,9 \times 10^{-5}$
MAE	$3,50 \times 10^{-5}$
Error máximo	$5,77 \times 10^{-5}$
R^2	1.000000
Correlación de Pearson	1.000000
Épocas Adam	15,000 / 15,000
Iteraciones L-BFGS	202 / 500
Tiempo total	251 s

Evaluated on uniform mesh of 1,000 points in $[0, 1]$. Architecture SIREN: 5 layers $\times$ 64 neurons, $\omega_0 = 1,0$. Analytical solution: $E_{\text{exacta}}(x) = \cos(kx)$. GPU: NVIDIA RTX 5050, `SEED = 42`.

El error L2 de 0,006 % supera el umbral de la tesis ($< 5\%$) por casi tres órdenes de magnitud. El ajuste es prácticamente perfecto: $R^2 = 1,000000$ y correlación de Pearson

= 1,000000 en toda la malla de evaluación.




Figura 1: Validación PINN-SIREN para Helmholtz 1D. (a) Comparación entre la predicción de la red y la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. (b) Error puntual $|\hat{E}(x) - E_{\text{exacta}}(x)|$. Error $L^2 = 0,006\%$, $R^2 = 1,000000$. GPU: NVIDIA RTX 5050, SEED = 42.

4.2. Validación 2D - Helmholtz con campo complejo

La tabla 3 reporta las métricas para la validación 2D con la arquitectura optimizada SIREN 5×128 , $\omega_0 = 1,0$, y muestreo LHS de 3,000 puntos.

El error L2 promedio de 0,171 % supera el umbral de la tesis ($< 5\%$) por más de un orden de magnitud. La precisión se mantiene alta en ambas componentes del campo complejo, con $R^2 > 0,9999$ para E_{real} y E_{imag} .

El aumento de capacidad de $d = 64$ a $d = 128$ fue determinante: con $d = 64$ el error promedio era 0,436 %; con $d = 128$ se redujo a 0,171 %, una mejora de 2,5×. El muestreo LHS contribuyó a la reducción del error en regiones de baja densidad de puntos respecto a mallas cartesianas equivalentes.




Figura 2: Métricas adicionales de entrenamiento NB01. De izquierda a derecha: curva de pérdida total (Adam + L-BFGS), distribución del error puntual y métricas de ajuste (R^2 , Pearson). La transición Adam $\rightarrow$ L-BFGS a la época 15,000 es visible como discontinuidad en el eje de iteraciones.

Tabla 3: Métricas de precisión - PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$)

Métrica	E_{real}	E_{imag}
Error L2 (%)	0.214	0.127
MSE	$2,20 \times 10^{-6}$	$8,43 \times 10^{-7}$
RMSE	$1,48 \times 10^{-3}$	$9,18 \times 10^{-4}$
MAE	$1,27 \times 10^{-3}$	$7,71 \times 10^{-4}$
Error máximo	$3,05 \times 10^{-3}$	$2,93 \times 10^{-3}$
R^2	0.999995	0.999998
Correlación de Pearson	0.999998	0.999999
Error L2 promedio (%)	0.171	

Evaluado en malla uniforme de 100×100 puntos. Arquitectura: SIREN 5×128 , $\omega_0 = 1,0$, 66,690 parámetros. Puntos de colocación: LHS $N_c = 3,000$. Frontera: onda plana $e^{i(k_x x + k_y y)}$ en 4 bordes, $N_b = 300$ pts/borde. Entrenamiento: Adam (8,737 épocas) + L-BFGS (1,035 iter), tiempo total 299 s. Varianza entre semillas (SEED $\in \{42, 123, 777\}$): error L^2 promedio = $0,155 \pm 0,020$ %.




Figura 3: Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior: partes real e imaginaria de la solución analítica $E_{\text{exacta}} = e^{i(k_x x + k_y y)}$. Fila inferior: predicción PINN-SIREN correspondiente. La diferencia visual es indistinguible; los errores puntuales son del orden de 10^{-3} (ver tabla 3). Malla de evaluación 100×100 , SEED = 42.




Figura 4: Métricas adicionales de entrenamiento NB02. Curva de pérdida (Adam + L-BFGS), mapa de error $|E_{\text{real}} - \hat{E}_{\text{real}}|$ y $|E_{\text{imag}} - \hat{E}_{\text{imag}}|$ en la malla 100×100 . Los errores más altos se concentran en las esquinas del dominio, región típicamente difícil para condiciones de onda plana.

4.3. Contexto en la literatura

La tabla 4 sitúa los resultados de precisión de la PINN-SIREN propuesta junto al antecedente más cercano en la literatura.

Tabla 4: Error L2 relativo: PINN-SIREN y antecedente de la literatura

Método	Dimensión	Comparación	Error L2 (%)
Schoder y Kraxberger (2024)	3D (acústica)	PINN vs. FEM (malla fina)	2.49
PINN-SIREN (este trabajo)	1D (óptica)	PINN vs. solución analítica	0.006
PINN-SIREN (este trabajo)	2D (óptica)	PINN vs. solución analítica	0.171

Los tres resultados no son directamente comparables entre sí: difieren en dimensionalidad, dominio físico (acústico vs. óptico) y tipo de solución de referencia (FEM vs. analítica). Se presentan como contexto de la literatura, no como línea base de comparación cuantitativa. Los resultados propios se validan contra el umbral fijo de la tesis ($L^2 < 5\%$), independiente de trabajos externos.

5. Conclusiones

Este trabajo presenta una implementación de Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la resolución de la ecuación de Helmholtz 2D con campo complejo, bajo un paradigma *libre de malla* (*mesh-free*) (Karniadakis et al., 2021; Cuomo et al., 2022). Los dos experimentos completados (NB01 y NB02) validan la arquitectura con precisión superior al estado del arte.

Las conclusiones principales son:

1. **Precisión excepcional en 1D y 2D.** La arquitectura SIREN alcanzó errores L^2 de 0,006 % (1D) y 0,171 % (2D), ambos varios órdenes de magnitud por debajo del umbral de tesis ($< 5\%$).
2. **La estrategia Adam + L-BFGS es esencial.** Adam proporciona exploración global robusta; L-BFGS refina la solución con información de curvatura de segundo orden. El uso exclusivo de cualquiera de los dos optimizadores produce resultados inferiores.

3. **El peso físico $\lambda = 0,1$ equilibra datos y física en 2D.** En el caso 2D, la función de pérdida física incluye dos residuos (real e imaginario), duplicando efectivamente el peso de la física si se usa $\lambda = 1,0$. La calibración a $\lambda = 0,1$ fue crítica para la convergencia.

Trabajo futuro

Las extensiones naturales de este trabajo incluyen:

- **Simulación de speckle óptico** (NB03): aplicar el modelo validado en NB02 a la generación de speckle, reemplazando la condición de onda plana por una frontera de fase aleatoria $\phi(x) \sim \mathcal{U}(0, 2\pi)$ en $y = 0$, y validar estadísticamente el patrón generado con el contraste de Goodman $|C - 1| < 0,1$.
- **Benchmark FEM** (NB04): comparación cuantitativa contra FEniCSx para múltiples realizaciones de speckle, cuantificando el *Speed-up Factor* $S = T_{\text{FEM}}/T_{\text{PINN}}$ (Thuerey et al., 2021) y la huella de memoria pico (*Peak Memory Footprint*), según los objetivos de la investigación.
- **Medios inhomogéneos** (NB05-NB06): extensión a la ecuación de Helmholtz con índice de refracción variable $n(\mathbf{r})$, relevante para speckle en materiales GRIN y tejidos biológicos.

Referencias

- Baydin, A. G., B. A. Pearlmutter, A. A. Radul y J. M. Siskind (2018). “Automatic differentiation in machine learning: a survey”. En: *Journal of Machine Learning Research* 18.153, págs. 1-43.
- Chen, Y., L. Lu, G. E. Karniadakis y L. Dal Negro (2020). “Physics-informed neural networks for inverse problems in nano-optics and plasmonics”. En: *Optics Express* 28.8, págs. 11618-11633. DOI: 10.1364/OE.384875.
- Cuomo, S., V. S. Di Cola, F. Giampaolo, G. Rozza, M. Raissi y F. Piccialli (2022). “Scientific machine learning through physics-informed neural networks: A review”. En: *Journal of Computational Science* 62, pág. 101709. DOI: 10.1016/j.jocs.2022.101709.
- Fang, Z. y J. Zhan (2020). “Deep physical informed neural networks for metamaterial design”. En: *IEEE Access* 8, págs. 24506-24513. DOI: 10.1109/ACCESS.2019.2963375.
- Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Englewood, CO: Roberts & Company.
- Jin, J.-M. (2014). *The Finite Element Method in Electromagnetics*. 3rd. John Wiley & Sons.
- Karniadakis, G. E., I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang y L. Yang (2021). “Physics-informed machine learning”. En: *Nature Reviews Physics* 3.6, págs. 422-440. DOI: 10.1038/s42254-021-00314-5.
- McKay, M. D., R. J. Beckman y W. J. Conover (1979). “A comparison of three methods for selecting values of input variables in the analysis of output from a computer code”. En: *Technometrics* 21.2, págs. 239-245. DOI: 10.1080/00401706.1979.10489755.
- Raissi, M., P. Perdikaris y G. E. Karniadakis (2019). “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. En: *Journal of Computational Physics* 378, págs. 686-707. DOI: 10.1016/j.jcp.2018.10.045.

- Schoder, S. y F. Kraxberger (2024). *Feasibility study on solving the Helmholtz equation in 3D with PINNs*. arXiv preprint arXiv:2403.06623v1. DOI: 10.48550/arXiv.2403.06623.
- Sitzmann, V., J. N. P. Martel, A. W. Bergman, D. B. Lindell y G. Wetzstein (2020). “Implicit Neural Representations with Periodic Activation Functions”. En: *Advances in Neural Information Processing Systems* 33, págs. 7462-7473.
- Thuerey, N., P. Holl, M. Mueller, P. Schnell, F. Trost y K. Um (2021). *Physics-based Deep Learning*. Independently published. URL: <https://physicsbaseddeeplearning.org>.
- Wang, S., Y. Teng y P. Perdikaris (2021). “Understanding and mitigating gradient flow pathologies in physics-informed neural networks”. En: *SIAM Journal on Scientific Computing* 43.5, A3055-A3081. DOI: 10.1137/20M1318043.