



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO EN REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINNS)**

TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: JUNIO 2026



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO EN REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINNS)**

TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: JUNIO 2026

Declaración de Autoría y Originalidad

En la Ciudad de Cunduacán el día Siete del mes de Junio del año 2026, el que suscribe **Roberto Hernández Estrada**, alumno del Programa de la **Maestría en Ciencias de la Computación** con número de matrícula **252H21004**, adscrito a la **División Académica de Ciencias y Tecnologías de la Información**, de la Universidad Juárez Autónoma de Tabasco, como autor de la Tesis presentada para la obtención del Grado de Maestría y titulada **Simulación acelerada de speckle óptico: Un enfoque basado en redes neuronales físicamente informadas (PINNs)**, dirigida por el Dr. José Adán Hernández Nolasco.

DECLARO QUE: La Tesis es una obra original que no infringe los derechos de propiedad intelectual ni los derechos de propiedad industrial u otros, de acuerdo con el ordenamiento jurídico vigente, en particular, la LEY FEDERAL DEL DERECHO DE AUTOR (Decreto por el que se reforman y adicionan diversas disposiciones de la Ley Federal del Derecho de Autor del 01 de Julio de 2020 regularizando, aclarando y armonizando las disposiciones legales vigentes sobre la materia), en particular, las disposiciones referidas al derecho de cita. Del mismo modo, asumo frente a la Universidad cualquier responsabilidad que pudiera derivarse de la autoría o falta de originalidad o contenido de la Tesis presentada de conformidad con el ordenamiento jurídico vigente.


Cunduacán, Tabasco a 07 de Junio de 2026.

Estudiante: Roberto Hernández Estrada



UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO

"ESTUDIO EN LA DUDA. ACCIÓN EN LA FE"



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN



Cunduacán, Tabasco a 30 de septiembre de 2024

Oficio No. 1220/DACYTI/CP/2024

Asunto: Autorización de impresión de Tesis

C. Fernando Contreras Pérez

Egresado de la Maestría en Ciencias de la Computación

En virtud de que cumple satisfactoriamente los requisitos establecidos en el Reglamento General de Estudios de Posgrado vigente en la Universidad, informo a Usted que se autoriza la impresión del trabajo recepcional **"Identificación automática de vehículos empleando aprendizaje profundo"**, para presentar examen y obtener el Grado de Maestro en Ciencias de la Computación.

Sin otro particular, aprovecho la ocasión para enviarle un afectuoso saludo.

Atentamente

MTE. Óscar Alberto González González
Director

UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN

C.c.p. Dr. Eddy Arquímedes García Alcocer. - Encargado del Despacho de la Coordinación de Posgrado DACYTI
Archivo.
Consecutivo.

M.T.E. OAGG/EAGA X

Carretera Cunduacán-Jalpa Km. 1, Colonia Esmeralda, C.P. 86690.
Cunduacán, Tabasco, México.
Tel: (993) 358 1500 ext. 6727; (914) 336 0616; Fax: (914) 336 0870
E-mail: direccion.dacyti@ujat.mx

www.ujat.mx

Carta de Cesión de Derechos

Cunduacán, Tabasco a 07 de Junio de 2026.

Por medio de la presente manifiesto haber colaborado como AUTOR en la producción, creación y/o realización de la obra denominada: **Simulación acelerada de speckle óptico: Un enfoque basado en redes neuronales físicamente informadas (PINNs)**.

Con fundamento en el artículo 83 de la Ley Federal del Derecho de Autor y toda vez que, la creación y/o realización de la obra antes mencionada se realizó bajo la comisión de la Universidad Juárez Autónoma de Tabasco; entendemos y aceptamos el alcance del artículo en mención de que tenemos el derecho al reconocimiento como autores de la obra, y a la Universidad Juárez Autónoma de Tabasco mantendrá en un 100 % la titularidad de los derechos patrimoniales por un período de 20 años sobre la obra en la que colaboramos, por lo anterior, cedemos el derecho patrimonial exclusivo en favor de la Universidad.

COLABORADOR

Estudiante: Roberto Hernández Estrada

TESTIGOS

Dr. José Adán Hernández Nolasco

Dr. Óscar Alberto Chávez Bosquez

Índice general

Índice de Figuras	IV
Índice de Tablas	VI
Resumen	VII
Abstract	VIII
1. Generalidades	1
1.1. Introducción	1
1.2. Planteamiento del problema	2
1.2.1. Definición del problema	2
1.2.2. Delimitación de la investigación	3
1.3. Preguntas de investigación e hipótesis	4
1.4. Objetivo general	5
1.5. Objetivos específicos	5
1.6. Justificación	6
1.7. Metodología	6
2. Marco Teórico	8
2.1. Conceptos y teorías fundamentales	8
2.1.1. Ecuación de onda de Helmholtz	8
2.1.2. Speckle óptico completamente desarrollado	9
2.1.3. Redes Neuronales Informadas por Física (PINNs)	9

2.1.4. Redes SIREN y sesgo espectral	10
2.1.5. Diferenciación automática	11
2.1.6. Muestreo Latino Hipercúbico (LHS)	11
2.1.7. Optimización híbrida Adam + L-BFGS	12
2.2. Literatura relacionada	12
2.3. Marco tecnológico	14
2.3.1. Infraestructura de hardware	14
2.3.2. Ecosistema de software	14
3. Modelo e implementación	15
3.1. Formulación del problema	15
3.1.1. Experimento 1 (NB01): Validación 1D	15
3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo	16
3.2. Arquitectura SIREN	16
3.3. Función de pérdida y calibración de pesos	17
3.4. Estrategia de muestreo	17
3.4.1. Puntos interiores (colocación)	17
3.4.2. Puntos de frontera	18
3.5. Estrategia de optimización	18
3.6. Métricas de validación	18
3.6.1. Error L^2 relativo (NB01 y NB02)	18
3.7. Implementación modular	19
4. Experimentos y Resultados	20
4.1. NB01: Validación 1D, Helmholtz con solución analítica	20
4.1.1. Configuración experimental	20
4.1.2. Resultados de precisión	21
4.1.3. Análisis y comparativa con el estado del arte	21
4.1.4. Barrido de ω_0 : evidencia cuantitativa del sesgo espectral	22
4.2. NB02: Validación 2D, Helmholtz con campo complejo	24
4.2.1. Configuración experimental	24

4.2.2. Resultados de precisión	24
4.2.3. Análisis de resultados	24
4.2.4. Reproducibilidad multi-semilla	25
4.3. Ablación del peso de física λ_{fis}	28
4.3.1. Explicación cuantitativa: análisis del núcleo tangente neuronal (NTK)	29
4.4. Contexto en la literatura	29
4.5. Resumen de experimentos completados	30
Bibliografía	32

Índice de figuras

4.1. Validación PINN-SIREN para Helmholtz 1D. Panel A: comparación entre la predicción de la red y la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel B: error puntual $ \hat{E}(x) - E_{\text{exacta}}(x) $. Panel C: curva de pérdida total durante las fases Adam y L-BFGS; la transición a la época 15,000 es visible como una caída abrupta. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.	22
4.2. Métricas adicionales de entrenamiento NB01. Panel A: distribución del error absoluto $ \hat{E}(x) - E_{\text{exacta}}(x) $. Panel B: error relativo puntual (%). Panel C: dispersión de la predicción PINN contra la solución exacta, con la línea $y = x$ como referencia de ajuste perfecto.	23
4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior (A1-A3): solución analítica, predicción PINN-SIREN y error absoluto para E_{real} . Fila central (B1-B3): lo mismo para E_{imag} . Fila inferior: intensidad predicha $I = E ^2$ (C1), puntos de colocación LHS (C2) y curvas de pérdida durante Adam y L-BFGS (C3). La diferencia visual entre solución exacta y predicción es indistinguible; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.3). Malla de evaluación 100×100 , SEED = 42.	26

4.4. Métricas adicionales de entrenamiento NB02. Paneles A-B: distribución del error absoluto $ E_{\text{real}} - \hat{E}_{\text{real}} $ y $ E_{\text{imag}} - \hat{E}_{\text{imag}} $. Paneles C, F: dispersión de la predicción PINN contra la solución exacta para cada componente. Paneles D-E: error relativo puntual (%) en la malla 100×100 ; los valores más altos se concentran en bandas antidiagonales ($x + y \approx \text{const.}$) donde la solución exacta cruza por cero, ya que el error relativo diverge al dividir por un valor cercano a cero, y no en las esquinas del dominio. La curva de pérdida de entrenamiento se muestra en el Panel C3 de la Figura 4.3.	27
---	----

Índice de tablas

3.1. Hiperparámetros de entrenamiento consolidados.	18
4.1. Métricas de precisión: PINN-SIREN 1D ($k = 2\pi$).	21
4.2. Barrido de ω_0 sobre el problema de NB01 (3,000 épocas Adam).	23
4.3. Métricas de precisión: PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$).	25
4.4. Reproducibilidad multi-semilla: NB02 ($\lambda_{\text{fis}} = 0.1$).	26
4.5. Ablación del peso de física λ_{fis} : NB02.	28
4.6. Espectro NTK: término de datos vs. término de física (NB02).	29
4.7. Error L^2 relativo: PINN-SIREN y antecedente de la literatura.	30
4.8. Estado de los experimentos planificados.	30

Resumen

Se presenta una implementación de Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para resolver la ecuación de Helmholtz, con miras a la simulación acelerada del patrón de speckle óptico mediante campo eléctrico complejo y condición de frontera de fase aleatoria. La arquitectura SIREN propuesta (5×128 neuronas, $\omega_0 = 1.0$) alcanza errores L^2 de 0.006% en el caso 1D y 0.171% en el caso 2D respecto a soluciones analíticas, varios órdenes de magnitud por debajo del umbral de tesis (5%). Una estrategia de optimización bifásica Adam + L-BFGS y el muestreo por hipercubo latino (LHS) son clave para la convergencia. La reproducibilidad del método fue verificada con tres semillas independientes para el caso 2D, obteniendo un error L^2 promedio de $0.192 \pm 0.089\%$. La etapa de generación de speckle (frontera de fase aleatoria, validación estadística contra el criterio de Goodman) está en progreso y no forma parte de los resultados validados que se reportan aquí.

Palabras clave: Redes Neuronales Informadas por Física, SIREN, ecuación de Helmholtz, speckle óptico, activación sinusoidal, muestreo por hipercubo latino.

Abstract

Physics-Informed Neural Networks with sinusoidal activation functions (SIREN-PINNs) are applied to solve the Helmholtz equation, toward the goal of simulating optical speckle patterns via a complex electric field and a random-phase boundary condition. The proposed SIREN architecture (5×128 , $\omega_0 = 1.0$) achieves relative L^2 errors of 0.006 % (1D) and 0.171 % (2D) against analytical solutions, several orders of magnitude below the 5 % thesis threshold. A two-phase Adam + L-BFGS optimization strategy and Latin Hypercube Sampling (LHS) are key to convergence. Reproducibility was verified with three independent random seeds for the 2D case, yielding a mean L^2 error of 0.192 ± 0.089 %. The speckle-generation stage (random-phase boundary, statistical validation against Goodman's criteria) is in progress and not yet part of the validated results reported here.

Keywords: Physics-Informed Neural Networks, SIREN, Helmholtz equation, optical speckle, sinusoidal activation, Latin Hypercube Sampling.

Capítulo 1

Generalidades

1.1. Introducción

La simulación de la propagación de la luz es una herramienta fundamental en la ciencia y la ingeniería, con aplicaciones que abarcan desde el diseño de sistemas de telecomunicaciones y la nanofotónica hasta el desarrollo de técnicas de imagenología médica. Un fenómeno de particular interés es el *speckle* óptico, un patrón de interferencia granular de alto contraste que surge cuando luz coherente, como la emitida por un láser, se dispersa sobre una superficie rugosa o un medio difusor.

Tradicionalmente, la simulación de estos fenómenos ondulatorios se aborda mediante métodos numéricos robustos como el Método de Elementos Finitos (*FEM*) o métodos estocásticos como el de Monte Carlo. Sin embargo, estos métodos presentan un cuello de botella computacional significativo: requieren una discretización extremadamente fina del dominio espacial para resolver las oscilaciones rápidas del campo de luz, lo que resulta en un consumo masivo de memoria y tiempos de cómputo que pueden extenderse por horas o días cuando se necesitan miles de realizaciones estadísticas (Goodman, 2007; Jin, 2014).

En paralelo, el campo de la inteligencia artificial ha experimentado un crecimiento disruptivo. Una innovación reciente son las Redes Neuronales Informadas por Física (*PINNs*, por sus siglas en inglés *Physics-Informed Neural Networks*), una metodología que fusiona el *Deep Learning* con las leyes físicas fundamentales. Las *PINNs* (Raissi et al., 2019) son redes neuronales entrenadas no solo para ajustarse a datos de frontera, sino para obedecer directamente una Ecuación

Diferencial Parcial (EDP) que gobierna el fenómeno físico de interés.

No obstante, las activaciones estándar de las redes neuronales (tanh, ReLU) presentan un sesgo espectral (Rahaman et al., 2019): tienden a aprender frecuencias bajas antes que las altas. Para la ecuación de Helmholtz con número de onda $k = 2\pi$, este sesgo produce derivadas de segundo orden inestables y una convergencia lenta. Las *Sinusoidal Representation Networks (SIREN)*, propuestas por Sitzmann et al. (2020), resuelven este problema mediante la función de activación $\phi(z) = \sin(\omega_0 z)$, convirtiendo la arquitectura en la elección natural para resolver ecuaciones de onda.

Este proyecto se sitúa en la intersección de la óptica computacional y la inteligencia artificial, aplicando el paradigma PINN-SIREN para superar las limitaciones computacionales de los métodos clásicos en la simulación del *speckle* óptico.

1.2. Planteamiento del problema

1.2.1. Definición del problema

La simulación precisa de cómo la luz se dispersa y forma patrones de *speckle* es crucial para sistemas ópticos avanzados en imagenología biomédica (tomografía de coherencia óptica), metrología (medición de vibraciones y deformaciones) y criptografía óptica.

El desafío central radica en el costo computacional prohibitivo de los métodos numéricos actuales:

1. **Métodos Basados en Malla (FEM):** Para capturar con precisión los detalles finos de un patrón de *speckle*, la malla debe tener una resolución espacial menor que la longitud de onda de la luz (Jin, 2014). Esto conduce a sistemas de ecuaciones con millones de incógnitas por realización, requiriendo alta memoria RAM y tiempos de ejecución que frenan la investigación. Cada nuevo perfil de rugosidad superficial exige resolver el sistema completo desde cero.
2. **Métodos Estocásticos (Monte Carlo):** Requieren simular un número masivo de fotones individuales para construir un patrón estadísticamente preciso, lo que los hace prohibitivos para estudios paramétricos que requieren miles de realizaciones.

Aunque la aplicación de las *PINNs* para resolver la ecuación de Helmholtz ha sido validada en simulaciones de ondas acústicas (Schoder & Kraxberger, 2024) y, de forma más reciente, en contextos ópticos y electromagnéticos con arquitectura SIREN (Panagiotakopoulos et al., 2026), hasta donde alcanza el conocimiento actual ningún trabajo combina la activación sinusoidal, una regla explícita de calibración de ω_0 respecto al número de onda, y la generación de *speckle* óptico desde una condición de frontera de fase aleatoria validada estadísticamente conforme al criterio de Goodman. Esta combinación es la que aborda sistemáticamente el presente trabajo.

Este trabajo propone tres elementos que, en conjunto, no se encuentran en la literatura relacionada. Primero, una regla de calibración $\omega_0 \approx k/(2\pi)$ que vincula el hiperparámetro de frecuencia de SIREN al número de onda físico, ausente tanto en la propuesta original de SIREN (Sitzmann et al., 2020) como en Panagiotakopoulos et al. (2026), el trabajo más cercano arquitectónicamente encontrado en la revisión de literatura (misma red SIREN, mismo campo complejo, misma estrategia de optimización Adam seguida de L-BFGS). Segundo, la generación de *speckle* óptico mediante la resolución directa de la ecuación de Helmholtz desde una condición de frontera de fase aleatoria, en lugar de ajustar un modelo a patrones de *speckle* ya medidos. Tercero, la validación estadística del patrón generado conforme al criterio de Goodman, no empleada en ningún trabajo previo de PINN aplicado a la ecuación de Helmholtz identificado en esta revisión.

1.2.2. Delimitación de la investigación

Alcances

- Se entregará un prototipo de *software* funcional, implementado en Python (PyTorch), capaz de construir y entrenar un modelo PINN-SIREN para resolver la ecuación de Helmholtz en dominios 2D.
- Se validará cuantitativamente la precisión del modelo contra soluciones analíticas conocidas mediante el error relativo L^2 .
- El modelo será capaz de simular la generación de patrones de *speckle* óptico en 2D, mediante la imposición de una condición de frontera con fase aleatoria $\psi(x) \sim \mathcal{U}(0, 2\pi)$.
- Se realizará una evaluación estadística del patrón generado conforme al criterio de Good-

man para *speckle* completamente desarrollado (Goodman, 2007).

- Se realizará una evaluación comparativa (*benchmark*) del tiempo de inferencia contra el método FEM para demostrar la viabilidad computacional del enfoque propuesto.

Limitaciones

- **Dimensionalidad:** Todas las simulaciones se restringen a dominios bidimensionales (2D). El desarrollo en 3D está fuera del alcance de este trabajo de maestría.
- **Alcance computacional:** Esta es una investigación puramente computacional y de simulación. No se incluyen montajes ópticos experimentales ni validación contra datos físicos reales.
- **Simplificación del medio difusor:** El medio se modela como una frontera con fase aleatoria discreta ($N_\psi = 256$ puntos). No se aborda la simulación de medios volumétricos ni propiedades no lineales.

1.3. Preguntas de investigación e hipótesis

Las preguntas que guían esta investigación son:

1. ¿Puede un modelo PINN con activación sinusoidal (SIREN) aproximar con precisión la solución de la ecuación de Helmholtz 2D para la simulación de patrones de *speckle* óptico, logrando un error $L^2 < 5\%$ respecto a soluciones de referencia?
2. ¿Cuál es la ganancia en eficiencia computacional (tiempo de inferencia y uso de memoria) del enfoque PINN-SIREN respecto al FEM para simular el mismo fenómeno?
3. ¿Presenta el patrón de intensidad simulado las propiedades estadísticas características del *speckle* completamente desarrollado definidas por la teoría de Goodman?

Hipótesis: El desarrollo de un modelo PINN-SIREN para la resolución de la ecuación de Helmholtz 2D con campo complejo permitirá: (i) simular la generación de *speckle* óptico con un error relativo $L^2 < 5\%$ respecto a la solución analítica de referencia; (ii) obtener un factor

de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}} > 1$ en la fase de inferencia; y (iii) preservar las propiedades estadísticas del fenómeno con un contraste de *speckle* $|C - 1| < 0.1$ conforme al criterio de Goodman (2007).

1.4. Objetivo general

Construir y validar un modelo computacional basado en Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la simulación acelerada y físicamente precisa de patrones de *speckle* óptico, mediante la resolución directa de la ecuación de Helmholtz bidimensional con campo eléctrico complejo.

1.5. Objetivos específicos

1. Diseñar e implementar una arquitectura SIREN que incorpore el residuo de la ecuación de Helmholtz en su función de pérdida, con activación $\phi(z) = \sin(\omega_0 z)$ y una estrategia de inicialización que preserve la distribución de activaciones en profundidad (Sitzmann et al., 2020).
2. Entrenar y validar la precisión del modelo PINN-SIREN en el escenario unidimensional (NB01), comparando contra la solución analítica $E(x) = \cos(kx)$ mediante el error relativo L^2 .
3. Escalar el modelo al caso bidimensional con campo complejo (NB02), empleando Muestreo Latino Hipercúbico (LHS) para los puntos de colocación y validando contra la solución de onda plana $E = e^{i(k_x x + k_y y)}$.
4. Aplicar el modelo validado a la simulación de *speckle* óptico (NB03) mediante una condición de frontera de fase aleatoria, y validar estadísticamente el patrón generado conforme al criterio de Goodman.
5. Comparar cuantitativamente el rendimiento computacional del modelo PINN-SIREN contra una implementación FEM de referencia (NB04), cuantificando el factor de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}}$.

1.6. Justificación

Esta investigación se justifica en tres ejes principales:

- **Justificación computacional:** El principal obstáculo en la simulación óptica avanzada es el costo prohibitivo de los métodos de malla. El enfoque *mesh-free* propuesto busca reducir los tiempos de simulación en al menos un orden de magnitud, habilitando estudios estadísticos de *speckle* que actualmente son intratables.
- **Justificación científica:** La simulación precisa de *speckle* impacta directamente en la imagenología biomédica (tomografía de coherencia óptica), la metrología de precisión y la criptografía óptica. Acelerar la simulación tiene consecuencias directas en la capacidad de innovar en estas áreas de alto impacto.
- **Justificación programática:** El proyecto se alinea estratégicamente con la Línea de Generación y Aplicación del Conocimiento (LGAC) en Ciencia de Datos e Inteligencia Artificial de la Maestría en Ciencias de la Computación de la UJAT. Aplica una técnica de vanguardia en *Deep Learning* para resolver una EDP fundamental de la física, demostrando la sinergia entre la IA y la ciencia computacional avanzada.

1.7. Metodología

La metodología se basa en el marco de trabajo de las *PINNs* propuesto por Raissi et al. (2019), extendido con la arquitectura de activación sinusoidal SIREN (Sitzmann et al., 2020). El proyecto es un estudio computacional cuantitativo y experimental, desarrollado en cuatro fases alineadas con los objetivos específicos.

Fase 1 - NB01: Validación analítica 1D. Se implementa el modelo PINN-SIREN (5×64 neuronas) para resolver la ecuación de Helmholtz 1D con solución analítica conocida $E(x) = \cos(kx)$. La función de pérdida combina el error en las condiciones de frontera Dirichlet y el residuo de Helmholtz evaluado en puntos de colocación uniformes. Se emplea una estrategia de optimización bifásica: Adam (hasta 15,000 épocas) seguido de L-BFGS (búsqueda de línea *strong Wolfe*).

Fase 2 - NB02: Escala a 2D con campo complejo. Se escala la arquitectura a 5×128 neuronas para acomodar el campo complejo $(E_{\text{real}}, E_{\text{imag}})$. Se introduce el Muestreo Latino Hipercúbico (LHS) con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por lado (McKay et al., 1979). Se calibra el peso de la función de pérdida $\lambda_{\text{fis}} = 0.1$ mediante ablación.

Fase 3 - NB03: Simulación de *speckle* óptico. Se aplica el modelo validado a la generación de *speckle*, reemplazando la condición de onda plana por una frontera con fase aleatoria $\psi(x) \sim \mathcal{U}(0, 2\pi)$ en $y = 0$ y bordes libres en el resto del dominio. La validación estadística sigue el criterio de Goodman (Goodman, 2007): contraste $C = \sigma_I / \langle I \rangle$ y test de Kolmogorov-Smirnov contra la distribución exponencial teórica.

Fase 4 - NB04: Benchmark FEM (trabajo futuro). Comparación cuantitativa del tiempo de inferencia PINN-SIREN contra una implementación de referencia con FEniCSx, para calcular el factor de aceleración $S = T_{\text{FEM}} / T_{\text{PINN}}$ y la huella de memoria pico. Esta fase está programada como trabajo futuro inmediato.

Capítulo 2

Marco Teórico

2.1. Conceptos y teorías fundamentales

Esta sección establece los fundamentos teóricos sobre los cuales se construye el modelo PINN-SIREN para la simulación de *speckle* óptico.

2.1.1. Ecuación de onda de Helmholtz

La propagación de luz coherente monocromática en un medio homogéneo e isótropo está gobernada por la ecuación de onda de Helmholtz escalar (Born & Wolf, 1999; Goodman, 2007; Jin, 2014):

$$\nabla^2 E(\mathbf{r}) + k^2 E(\mathbf{r}) = 0, \quad (2.1)$$

donde $E(\mathbf{r}) \in \mathbb{C}$ es la amplitud compleja del campo eléctrico, $k = 2\pi/\lambda$ es el número de onda y λ la longitud de onda del láser. En dos dimensiones espaciales ($\mathbf{r} = (x, y)$):

$$\frac{\partial^2 E}{\partial x^2} + \frac{\partial^2 E}{\partial y^2} + k^2 E = 0. \quad (2.2)$$

Dado que las redes neuronales operan sobre números reales, el campo complejo se descompone en sus partes real e imaginaria: $E = E_{\text{real}} + iE_{\text{imag}}$. Ambas componentes satisfacen la

ecuación (2.2) de forma independiente:

$$\nabla^2 E_{\text{real}} + k^2 E_{\text{real}} = 0, \quad \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}} = 0. \quad (2.3)$$

La intensidad física observable del *speckle* se calcula como:

$$I(x, y) = |E|^2 = E_{\text{real}}^2 + E_{\text{imag}}^2. \quad (2.4)$$

2.1.2. Speckle óptico completamente desarrollado

Cuando una superficie rugosa con variación de fase $\Delta\psi \gg 2\pi$ es iluminada por luz coherente, las contribuciones de los distintos puntos de la superficie interfieren de forma aleatoria. Por el Teorema del Límite Central, el campo complejo resultante sigue una distribución gaussiana circular compleja (Goodman, 2007):

$$E_{\text{real}}, E_{\text{imag}} \sim \mathcal{N}(0, \sigma_E^2), \quad \text{independientes.} \quad (2.5)$$

La intensidad $I = |E|^2$ sigue entonces una distribución exponencial negativa:

$$p(I) = \frac{1}{\langle I \rangle} \exp\left(-\frac{I}{\langle I \rangle}\right), \quad I \geq 0, \quad (2.6)$$

con valor esperado $\langle I \rangle = 2\sigma_E^2$ y desviación estándar $\sigma_I = \langle I \rangle$. El *contraste del speckle* se define como:

$$C = \frac{\sigma_I}{\langle I \rangle} = 1, \quad (2.7)$$

criterio que vale exactamente 1 para *speckle* completamente desarrollado y disminuye cuando el campo pierde coherencia o la rugosidad es insuficiente (Goodman, 2007).

2.1.3. Redes Neuronales Informadas por Física (PINNs)

El enfoque de resolver EDPs con redes neuronales fue pionero por Lagaris et al. (1998), quienes demostraron que redes feedforward podían aproximar soluciones de ecuaciones diferenciales ordinarias y parciales mediante una función de prueba que satisface las condiciones de frontera

exactamente. Este trabajo establece el precedente directo de las PINNs modernas. La capacidad de aproximación universal de las redes feedforward fue formalizada por Hornik et al. (1989).

Las PINNs modernas, introducidas por Raissi et al. (2019) y revisadas extensamente en Karniadakis et al. (2021) y Cuomo et al. (2022), aproximan la solución de una EDP mediante una red neuronal $\mathcal{N}_\theta(\mathbf{r})$ cuyos parámetros θ se optimizan minimizando una función de pérdida compuesta:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{datos}}(\theta) + \lambda_{\text{fís}} \mathcal{L}_{\text{física}}(\theta), \quad (2.8)$$

donde $\mathcal{L}_{\text{datos}}$ penaliza el error en las condiciones de frontera y $\mathcal{L}_{\text{física}}$ penaliza la violación de la EDP en el interior del dominio. Para la ecuación de Helmholtz 2D con campo complejo:

$$\mathcal{L}_{\text{datos}}(\theta) = \frac{1}{N_b} \sum_{j=1}^{N_b} \left\| \mathcal{N}_\theta(\mathbf{r}_j^b) - E(\mathbf{r}_j^b) \right\|^2, \quad (2.9)$$

$$\mathcal{L}_{\text{física}}(\theta) = \frac{1}{N_c} \sum_{i=1}^{N_c} [R_{\text{real}}(\mathbf{r}_i^c)^2 + R_{\text{imag}}(\mathbf{r}_i^c)^2], \quad (2.10)$$

donde $R_{\text{real}} = \nabla^2 E_{\text{real}} + k^2 E_{\text{real}}$ y $R_{\text{imag}} = \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}}$ son los residuos de Helmholtz, $\{\mathbf{r}_j^b\}$ son los puntos de frontera y $\{\mathbf{r}_i^c\}$ los puntos de colocación interiores. Las derivadas $\nabla^2 E$ se obtienen mediante diferenciación automática (Baydin et al., 2018).

2.1.4. Redes SIREN y sesgo espectral

Las activaciones estándar (ReLU, tanh) presentan un sesgo espectral (Rahaman et al., 2019): aprenden frecuencias bajas antes que las altas. Para la ecuación de Helmholtz con $k = 2\pi$, esto produce derivadas de segundo orden inestables y convergencia lenta. Adicionalmente, ReLU tiene segunda derivada nula, lo que impide computar el Laplaciano mediante diferenciación automática.

Sitzmann et al. (2020) proponen las redes SIREN (*Sinusoidal Representation Networks*), que utilizan la activación $\phi(z) = \sin(\omega_0 z)$ con una inicialización específica:

$$\mathbf{h}_\ell = \sin(\omega_0 (\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell)), \quad \ell = 1, \dots, L, \quad (2.11)$$

donde las matrices $\mathbf{W}_\ell$ se inicializan según $\mathcal{U}(-\sqrt{6/d}, \sqrt{6/d})$ para capas intermedias y $\mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa. Esta inicialización garantiza que las distribuciones de activación sean aproximadamente uniformes en $[-1, 1]$, condición necesaria para la estabilidad de derivadas de orden arbitrario. La derivada de cualquier orden de SIREN es también una red SIREN, lo que la convierte en la elección natural para resolver EDPs con operadores diferenciales de orden superior.

Una alternativa relacionada para mitigar el sesgo espectral es el mapeo de características de Fourier (*Fourier feature mapping*) propuesto por Tancik et al. (2020), que proyecta las coordenadas de entrada a través de funciones seno/coseno como una capa de preprocesamiento antes de una MLP estándar. SIREN incorpora este mismo principio de codificación periódica directamente en la función de activación de cada capa, en lugar de aplicarlo como una transformación previa de las coordenadas de entrada, lo que le permite propagar la periodicidad a través de toda la red y facilita el cálculo de derivadas de orden superior mediante diferenciación automática.

2.1.5. Diferenciación automática

La diferenciación automática (*autodiff*) permite calcular derivadas de cualquier orden con precisión de máquina mediante la aplicación sucesiva de la regla de la cadena sobre el grafo de operaciones del programa (Baydin et al., 2018). En el contexto de las PINNs, *autodiff* actúa como el motor que permite evaluar el Laplaciano ∇^2 directamente sobre las salidas de la red neuronal respecto a sus coordenadas de entrada, sin los errores de truncamiento de las diferencias finitas.

2.1.6. Muestreo Latino Hipercúbico (LHS)

El Muestreo Latino Hipercúbico (McKay et al., 1979) es una estrategia de muestreo estratificada diseñada para generar una distribución de puntos de colocación que cubra de manera cuasi-óptima el dominio computacional Ω . A diferencia del muestreo aleatorio simple, el LHS divide cada dimensión en N_c estratos iguales y coloca exactamente un punto por estrato, garantizando cobertura uniforme sin los patrones redundantes de una malla cartesiana. Esto permite a la red capturar la física de la ecuación de Helmholtz con una densidad de puntos significativamente menor, optimizando el uso de memoria GPU y reduciendo el tiempo de convergencia (Cuomo et al., 2022).

2.1.7. Optimización híbrida Adam + L-BFGS

El entrenamiento sigue una estrategia bifásica de Adam seguido de L-BFGS, práctica extendida en la literatura de PINNs (Cuomo et al., 2022):

1. **Fase 1 (Adam):** Optimizador estocástico de primer orden (Kingma & Ba, 2015) con tasa de aprendizaje $\eta = 10^{-3}$, paciencia de 800 épocas sin mejora mayor que $\delta = 10^{-7}$ y un máximo de 15,000 épocas. Adam realiza exploración global del espacio de parámetros y proporciona un punto de inicio próximo al mínimo global.
2. **Fase 2 (L-BFGS):** Optimizador cuasi-Newton de segundo orden (*Limited-memory Broyden-Fletcher-Goldfarb-Shanno*) (Nocedal & Wright, 2006) con búsqueda de línea *strong Wolfe*, máximo 1,000 iteraciones y tamaño de historial 100. L-BFGS aprovecha la información de curvatura para realizar un ajuste fino de alta precisión desde el punto entregado por Adam.

Esta combinación supera a Adam puro en precisión final y a L-BFGS puro en robustez ante mínimos locales.

2.2. Literatura relacionada

El uso de redes neuronales para resolver EDPs fue revitalizado por Raissi et al. (2019), quienes demostraron la capacidad de las PINNs para resolver una amplia gama de problemas físicos sin necesidad de mallado. El análisis teórico de por qué las PINNs pueden fallar en el entrenamiento fue abordado por Wang et al. (2022) mediante la teoría del núcleo tangente neuronal (NTK), estableciendo las condiciones bajo las cuales el entrenamiento converge. Desde una perspectiva más empírica, Krishnapriyan et al. (2021) caracterizan sistemáticamente los modos de falla de las PINN con pesos fijos entre los términos de datos y de física, mostrando que el entrenamiento puede estancarse en soluciones incorrectas incluso cuando la pérdida global parece decrecer — un fenómeno que se retoma en el Capítulo 4 al analizar la ablación del peso de física λ_{fis} .

En el campo de las ecuaciones de onda, Moseley et al. (2020) aplicaron PINNs para resolver la ecuación de onda acústica 2D en modelos de velocidad variables, demostrando la viabilidad del

enfoque en dominios inhomogéneos. Para la ecuación de Helmholtz específicamente, Alkhalifah et al. (2021) propusieron un marco de aprendizaje automático para obtener soluciones del campo de onda en sísmica, usando la ecuación de Helmholtz como restricción en la función de pérdida.

En el campo de la óptica y el electromagnetismo, Fang y Zhan (2020) aplicaron PINNs para resolver problemas de dispersión de ondas en medios inhomogéneos 2D, mientras que Chen et al. (2020) las utilizaron para el diseño inverso en nanofotónica. Lu et al. (2021) desarrollaron la biblioteca DeepXDE que sistematiza la implementación de PINNs para diversas EDPs.

Un antecedente relevante es el de Schoder y Kraxberger (2024), quienes realizaron un estudio de factibilidad resolviendo la ecuación de Helmholtz mediante PINNs para propagación de ondas acústicas, demostrando la viabilidad de la técnica en entornos complejos: reportaron un error relativo L^2 de 0.0249 (aproximadamente 2.5 %) entre su solución PINN y una malla FEM de referencia fina. Este resultado es indicativo del orden de magnitud de precisión alcanzable con PINNs, aunque no constituye una línea base de comparación directa para la presente investigación: su experimento es en 3D (no 1D/2D), su dominio físico es acústico (no óptico), y su métrica de referencia es una malla FEM (no una solución analítica exacta).

En una línea similar de validación cuantitativa, Zhang et al. (2025) proponen las redes de base radial mejoradas por características (FE-PIRBN) para resolver problemas de dispersión electromagnética de alta frecuencia, reportando errores L^2 entre 1.40 % y 5.82 % frente a simulaciones numéricas de referencia. Al igual que con Schoder y Kraxberger (2024), esta comparación se retoma en la Tabla 4.7 del Capítulo 4 como contexto de la literatura, no como línea base directa, dado que difieren en dimensionalidad, dominio físico y tipo de solución de referencia.

El antecedente más cercano en arquitectura a esta investigación es el de Panagiotakopoulos et al. (2026), quienes resuelven la misma ecuación de Helmholtz 2D con campo complejo empleando también una red SIREN y la estrategia de optimización bifásica Adam seguida de L-BFGS. Se diferencia de este trabajo en tres aspectos: no calibran ω_0 respecto al número de onda k ; validan la física del campo resultante de forma cualitativa (propagación, refracción, dispersión) en lugar de reportar un error L^2 cuantitativo contra una solución analítica; y su condición de frontera es una fuente puntual gaussiana con condición de radiación de Sommerfeld, distinta de la frontera de fase aleatoria que da lugar al patrón de *speckle* en esta investigación.

La brecha en el conocimiento identificada es la siguiente: ningún trabajo previo, incluyendo el

antecedente arquitectónico más cercano (Panagiotakopoulos et al., 2026), ha aplicado sistemáticamente la arquitectura SIREN (Sitzmann et al., 2020) (con su ventaja intrínseca para representar funciones de alta frecuencia) a la simulación del *speckle* óptico como fenómeno estadístico complejo, validado mediante los criterios de contraste y bondad de ajuste de Goodman (2007). Esta investigación se propone cerrar dicha brecha; los Capítulos 3 y 4 documentan el avance metodológico logrado en la validación 1D/2D del enfoque y el estado en progreso de su aplicación al *speckle* óptico.

2.3. Marco tecnológico

2.3.1. Infraestructura de hardware

El entrenamiento de los modelos PINN-SIREN se realizó sobre la siguiente infraestructura:

- **GPU:** NVIDIA GeForce RTX 5050 (8.5 GB VRAM), con núcleos CUDA para acelerar la diferenciación automática de segundo orden requerida por el cálculo del Laplaciano.
- **CUDA:** Versión 12.8.
- **Memoria RAM:** Gestión del flujo de puntos de colocación y ejecución del optimizador híbrido.

2.3.2. Ecosistema de software

- **Python 3.14:** Lenguaje de implementación principal.
- **PyTorch 2.11:** Framework de *Deep Learning* que proporciona diferenciación automática de segundo orden y soporte GPU mediante CUDA.
- **NumPy / SciPy:** Operaciones numéricas y muestreo LHS (`scipy.stats.qmc.LatinHypercube`).
- **Matplotlib:** Visualización de campos, distribuciones estadísticas y curvas de entrenamiento.
- **Módulos propios:** `src/models.py` (arquitectura SIREN), `src/losses.py` (función de pérdida PINN), `src/utils.py` (métricas y visualización).

Capítulo 3

Modelo e implementación

3.1. Formulación del problema

Se considera el dominio cuadrado adimensional $\Omega = [0, 1]^2$, donde las coordenadas han sido normalizadas por la longitud de onda del láser ($\lambda = 638 \text{ nm}$, láser de diodo rojo). Bajo esta normalización, el número de onda $k = 2\pi/\lambda$ definido en el Capítulo 2 toma el valor adimensional $k = 2\pi$; salvo que se indique lo contrario, k se usa en su forma adimensional en el resto de este capítulo.

Se plantean tres experimentos sucesivos de complejidad creciente:

3.1.1. Experimento 1 (NB01): Validación 1D

La ecuación de Helmholtz unidimensional en $x \in [0, 1]$ con condiciones de Dirichlet:

$$\frac{d^2 E}{dx^2} + k^2 E = 0, \quad E(x_j) = \cos(kx_j), \quad x_j \in \{0, 0.25, 0.5, 0.75, 1\}, \quad (3.1)$$

admite la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$, utilizada para validar la arquitectura y la función de pérdida. Se imponen cinco puntos de frontera (en lugar de únicamente los dos extremos $x = 0$ y $x = 1$): la condición simétrica $E(0) = E(1) = 1$ colapsa la red hacia la solución constante trivial durante el entrenamiento, ya que ambos extremos son consistentes con $E \equiv 1$; añadir tres puntos intermedios conocidos de la solución analítica rompe esa simetría y estabiliza la convergencia.

3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo

La ecuación de Helmholtz 2D en $\Omega = [0, 1]^2$ con condición de onda plana diagonal en los cuatro bordes:

$$E_{\text{exacta}}(x, y) = e^{i(k_x x + k_y y)}, \quad k_x = k_y = \frac{k}{\sqrt{2}}, \quad (3.2)$$

que satisface $k_x^2 + k_y^2 = k^2$. La condición de frontera se impone separando la solución en sus partes real e imaginaria:

$$E_{\text{real}}(x, y)|_{\partial\Omega} = \cos(k_x x + k_y y), \quad E_{\text{imag}}(x, y)|_{\partial\Omega} = \sin(k_x x + k_y y). \quad (3.3)$$

3.2. Arquitectura SIREN

Se emplea una arquitectura SIREN con los parámetros consolidados a partir de la validación 1D (NB01) y escalados para el caso 2D (NB02):

- **Entrada:** coordenadas espaciales $(x, y) \in [0, 1]^2$ (o $(x) \in [0, 1]$ para 1D).
- **Capas ocultas:** $L = 5$ capas de dimensión d neuronas cada una ($d = 64$ en NB01, $d = 128$ en NB02).
- **Activación:** $\phi(z) = \sin(\omega_0 z)$, con $\omega_0 = 1.0$.
- **Salida:** capa lineal de dos neuronas ($E_{\text{real}}, E_{\text{imag}}$) para el caso 2D, o una neurona E para el caso 1D.
- **Parámetros totales:** 16,833 (NB01) y 66,690 (NB02).

La elección $\omega_0 = 1.0$, en lugar del valor $\omega_0 = 30$ recomendado por Sitzmann et al. (2020) para señales de imagen, está justificada por la naturaleza del problema: el dominio adimensional $[0, 1]^2$ con $k = 2\pi$ no requiere capturar frecuencias ultra-altas, y valores mayores de ω_0 desestabilizan el entrenamiento con L-BFGS.

La inicialización sigue el esquema de Sitzmann et al. (2020): $\mathbf{W}_0 \sim \mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa y $\mathbf{W}_\ell \sim \mathcal{U}(-\sqrt{6/d}, \sqrt{6/d})$ para capas intermedias, garantizando que las distribuciones de activación sean aproximadamente uniformes en $[-1, 1]$.

3.3. Función de pérdida y calibración de pesos

La función de pérdida total para el caso 2D es:

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda_{\text{fís}} \left(\mathcal{L}_{R_{\text{real}}} + \mathcal{L}_{R_{\text{imag}}} \right), \quad (3.4)$$

con peso de física $\lambda_{\text{fís}} = 0.1$. Este valor fue calibrado empíricamente mediante un experimento de ablación (véase la Sección 4.3): valores superiores ($\lambda = 1.0$) sobrepesan la física e impiden la convergencia en 2D, dado que los dos residuos (real e imaginario) duplican efectivamente la contribución física; valores inferiores ($\lambda = 0.01$) producen campos que violan moderadamente la ecuación de Helmholtz.

Los residuos de Helmholtz se calculan mediante diferenciación automática de segundo orden (Baydin et al., 2018):

$$R_{\text{real}}(\mathbf{r}) = \nabla^2 E_{\text{real}}(\mathbf{r}) + k^2 E_{\text{real}}(\mathbf{r}), \quad R_{\text{imag}}(\mathbf{r}) = \nabla^2 E_{\text{imag}}(\mathbf{r}) + k^2 E_{\text{imag}}(\mathbf{r}), \quad (3.5)$$

donde el Laplaciano se obtiene con `torch.autograd.grad` activando la opción `create_graph=True` para permitir diferenciación de segundo orden. Es crítico que k^2 se convierta a tipo `float` de Python antes de multiplicar por el tensor de la red, para evitar conflictos de tipo entre `numpy.float64` y `torch.float32`.

3.4. Estrategia de muestreo

3.4.1. Puntos interiores (colocación)

Para el caso 2D, los $N_c = 3,000$ puntos de colocación interiores se generan mediante LHS (McKay et al., 1979) usando `scipy.stats.qmc.LatinHypercube` con dimensión $n = 2$. LHS divide cada dimensión en N_c estratos iguales de longitud $1/N_c$ y coloca exactamente un punto en cada estrato, garantizando cobertura uniforme del dominio sin los patrones redundantes de una malla cartesiana.

3.4.2. Puntos de frontera

En NB01, la condición de Dirichlet se impone en los cinco puntos conocidos descritos en la Sección 3 ($x = 0, 0.25, 0.5, 0.75, 1$). En NB02, los $N_b = 300$ puntos de frontera por borde se distribuyen uniformemente sobre cada uno de los cuatro lados del dominio $\partial\Omega$ (1,200 puntos en total). Para cada lado, se evalúa la solución exacta y se construye el par $(\mathbf{r}_j^b, E(\mathbf{r}_j^b))$ utilizado en $\mathcal{L}_{\text{datos}}$.

3.5. Estrategia de optimización

El entrenamiento sigue la estrategia bifásica descrita en el Capítulo 2, con los hiperparámetros consolidados en la Tabla 3.1.

Tabla 3.1. Hiperparámetros de entrenamiento consolidados.

Hiperparámetro	Valor	Aplicación
Tasa de aprendizaje Adam (η)	10^{-3}	NB01, NB02
Épocas máximas Adam	15,000	NB01, NB02
Paciencia (<i>early stopping</i>)	800 épocas	NB02
δ mejora mínima	10^{-7}	NB02
Iteraciones máximas L-BFGS	500 (NB01), 1,000 (NB02)	-
Historial L-BFGS	50 (NB01), 100 (NB02)	-
Semilla global (SEED)	42	NB01, NB02
Peso de física λ_{fis}	1.0 (NB01), 0.1 (NB02)	-

Todos los experimentos se ejecutaron en GPU NVIDIA RTX 5050. La semilla garantiza reproducibilidad. NB01 usa $\lambda_{\text{fis}} = 1.0$ porque un único residuo no duplica el peso de la física, a diferencia del caso 2D (real + imaginario); ver Sección 4.3.

3.6. Métricas de validación

3.6.1. Error L^2 relativo (NB01 y NB02)

El error L^2 relativo mide la discrepancia global entre la predicción de la red $\hat{E}$ y la solución exacta E_{exacta} , evaluada sobre una malla uniforme de 1,000 puntos en $[0, 1]$ para NB01 (1D) y

100×100 puntos en $[0, 1]^2$ para NB02 (2D):

$$\varepsilon_{L^2} = \frac{\|\hat{E} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2} \times 100 \%. \quad (3.6)$$

No existe en la literatura de PINNs un criterio estandarizado de tolerancia de error para este tipo de validación, por lo que se fijó $\varepsilon_{L^2} < 5\%$ como umbral ingenieril propio de la tesis. Este valor resulta, además, considerablemente menor que el orden de magnitud reportado en implementaciones comparables de PINNs para la ecuación de Helmholtz identificadas posteriormente (Tabla 4.7).

3.7. Implementación modular

El código fuente está organizado en módulos reutilizables en `src/`:

`models.py` Clase `PINN_2D_SIREN` que implementa la arquitectura SIREN con la inicialización de Sitzmann et al. (2020). El método `forward(x)` aplica la activación sinusoidal capa por capa y retorna el campo complejo como un tensor de dos columnas ($E_{\text{real}}, E_{\text{imag}}$).

`losses.py` Función `pinn_loss_2d(model, xy_int, xy_bc, E_bc, k, lam)` que calcula la pérdida total (3.4). El cálculo del Laplaciano utiliza `torch.autograd.grad` con `create_graph=True` para habilitar la diferenciación de segundo orden. El escalar k se convierte explícitamente a `float(k)` antes de multiplicar por el tensor de la red, evitando conflictos de dtype entre `numpy.float64` y `torch.float32`.

`training.py` Loop de entrenamiento que integra las fases Adam y L-BFGS con *early stopping*.

`utils.py` Métricas (L^2 , R^2 , RMSE, MAE), funciones de muestreo LHS y rutinas de visualización.

Los experimentos están reproducidos en los notebooks `01_pinn_helmholtz_1d_validation.ipynb`, `02_pinn_helmholtz_2d_complex_field.ipynb` y `03_pinn_optical_speckle_simulation.ipynb`. Los resultados numéricos están archivados en formato JSON en `results/`.

Capítulo 4

Experimentos y Resultados

Este capítulo presenta los resultados de los experimentos de validación ejecutados en GPU NVIDIA RTX 5050 (CUDA 12.8, PyTorch 2.11, SEED = 42): validación analítica 1D (NB01) y validación 2D con campo complejo (NB02). El tercer experimento planeado (NB03, simulación de *speckle* óptico mediante PINN) se encuentra pausado; el diagnóstico y los hallazgos acumulados hasta la fecha se documentan en [archive/nb03_speckle_pausado/](#) para retomarlo posteriormente.

4.1. NB01: Validación 1D, Helmholtz con solución analítica

4.1.1. Configuración experimental

El primer experimento valida la arquitectura SIREN frente a la solución analítica exacta de la ecuación de Helmholtz 1D. Se empleó la arquitectura SIREN 5×64 (16,833 parámetros) con los hiperparámetros de la Tabla 3.1. Los puntos de colocación son $N_c = 2,000$ puntos uniformes en $[0, 1]$ y las condiciones de frontera Dirichlet se imponen en cinco puntos conocidos de la solución analítica ($x = 0, 0.25, 0.5, 0.75, 1$), en lugar de únicamente los extremos, para evitar el colapso hacia la solución constante que produce la condición simétrica $E(0) = E(1) = 1$.

4.1.2. Resultados de precisión

La Tabla 4.1 presenta las métricas de precisión obtenidas tras el entrenamiento completo Adam (15,000 épocas) seguido de L-BFGS (202 evaluaciones de la función objetivo), con un tiempo total de 131.1 segundos.

Tabla 4.1. Métricas de precisión: PINN-SIREN 1D ($k = 2\pi$).

Métrica	Valor
Error L^2 relativo (%)	0.006
MSE	1.5×10^{-9}
RMSE	3.9×10^{-5}
MAE	3.50×10^{-5}
Error máximo	5.77×10^{-5}
R^2	1.000000
Correlación de Pearson	1.000000
Épocas Adam	15,000 / 15,000
Evaluaciones L-BFGS	202 / 500
Tiempo total (s)	131.1

Evaluated on a uniform grid of 1,000 points in $[0, 1]$. Architecture SIREN: 5 capas $\times$ 64 neurons, $\omega_0 = 1.0$. Analytical solution: $E_{\text{exacta}}(x) = \cos(kx)$. GPU: NVIDIA RTX 5050, SEED = 42, laptop connected to power and without concurrent processes. "Evaluaciones L-BFGS" counts the calls to the loss function during the search for *strong Wolfe* line, no iterations of the optimizer. In a previous run under these conditions the total time was 504.2 s: the same hardware, running in thermal regime (reduced GPU clock frequency due to sustained load), reproduced identically L^2 , R^2 and the rest of precision metrics, but at 8.75 ms/epoch in the first stage and 60.4 ms/epoch after the epoch $\sim 8,700$. The training time on portable hardware depends on the thermal conditions of the session and should not be interpreted as a figure of merit of the algorithm.

4.1.3. Análisis y comparativa con el estado del arte

The error $L^2 = 0.006\%$ remains below the thesis threshold ($< 5\%$) by nearly three orders of magnitude. This result is attributable to the intrinsic advantage of the sinusoidal activation

SIREN para representar funciones oscilatorias: la red aprende la solución $\cos(kx)$ de forma casi exacta, con $R^2 = 1.000000$ y correlación de Pearson = 1.000000 en toda la malla de evaluación.

La Figura 4.1 muestra la comparación entre la predicción de la red y la solución analítica, así como la distribución del error puntual.




Figura 4.1. Validación PINN-SIREN para Helmholtz 1D. Panel A: comparación entre la predicción de la red y la solución analítica $E_{exacta}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel B: error puntual $|\hat{E}(x) - E_{exacta}(x)|$. Panel C: curva de pérdida total durante las fases Adam y L-BFGS; la transición a la época 15,000 es visible como una caída abrupta. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.

La Figura 4.2 complementa este resultado con la distribución del error y las métricas de ajuste adicionales.

4.1.4. Barrido de ω_0 : evidencia cuantitativa del sesgo espectral

La regla de calibración $\omega_0 \approx k/(2\pi)$ (Tabla 3.1) se documentó originalmente a partir de un único caso puntual: $\omega_0 = 30$ (el valor recomendado por Sitzmann et al. (2020) para señales de imagen) desestabiliza el entrenamiento con $k \approx 2\pi$. Para verificar esta regla más allá de un solo punto, se entrenó el mismo problema de NB01 con $\omega_0 \in \{1.0, 5.0, 15.0, 30.0\}$ durante 3,000 épocas Adam idénticas (sin L-BFGS), manteniendo $k = 2\pi$ fijo.

El valor calibrado $\omega_0 = 1.0$ converge a una pérdida consistentemente menor que los tres




Figura 4.2. Métricas adicionales de entrenamiento NB01. Panel A: distribución del error absoluto $|\hat{E}(x) - E_{exacta}(x)|$. Panel B: error relativo puntual (%). Panel C: dispersión de la predicción PINN contra la solución exacta, con la línea $y = x$ como referencia de ajuste perfecto.

Tabla 4.2. Barrido de ω_0 sobre el problema de NB01 (3,000 épocas Adam).

ω_0	Pérdida total final	Observación
1.0	0.2656	Calibrado ($\omega_0 = k/2\pi$)
5.0	0.5355	Descalibrado
15.0	0.4375	Descalibrado
30.0	0.6030	Descalibrado (valor de Sitzmann et al. (2020) para imágenes)

Corridas nuevas y cortas, independientes del entrenamiento final de NB01 (15,000 épocas + L-BFGS, Tabla 4.1); no modifican ni reemplazan esos resultados. Mismo $N_c = 2,000$, $\lambda_{fis} = 1.0$ y puntos de frontera que NB01. Ninguna corrida diverge (pérdida infinita o NaN) dentro de las 3,000 épocas: la desestabilización numérica documentada para $\omega_0 = 30$ en el entrenamiento completo de 15,000 épocas no se reproduce como divergencia literal en este barrido corto, pero sí se observa la tendencia esperada de peor convergencia a mayor descalibración.

valores descalibrados en la misma cantidad de épocas. Este resultado es consistente con el sesgo espectral descrito por Rahaman et al. (2019): la activación sinusoidal de SIREN impone un espectro de frecuencias nativo determinado por ω_0 , y cuando este no coincide con la frecuencia k de la solución objetivo, la red debe aprender a compensar ese desajuste espectral antes de ajustar la solución misma, retrasando o degradando la convergencia.

4.2. NB02: Validación 2D, Helmholtz con campo complejo

4.2.1. Configuración experimental

El segundo experimento escala el modelo al caso bidimensional con campo complejo. Se empleó la arquitectura SIREN 5×128 (66,690 parámetros), LHS con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por borde. El peso de física $\lambda_{\text{fis}} = 0.1$ fue seleccionado mediante el experimento de ablación descrito en la Sección 4.3.

4.2.2. Resultados de precisión

La Tabla 4.3 reporta las métricas detalladas para cada componente del campo complejo, evaluadas en una malla uniforme de 100×100 puntos.

4.2.3. Análisis de resultados

El error L^2 promedio de 0.171 % se mantiene por debajo del umbral de la tesis (< 5 %) por más de un orden de magnitud. La precisión se mantiene alta en ambas componentes del campo complejo, con $R^2 > 0.9999$ para E_{real} y E_{imag} .

En un experimento preliminar con $d = 64$ (mismo N_c , N_b y protocolo de optimización que la Tabla 3.1) el error promedio fue 0.436 %, frente a 0.171 % con $d = 128$. Esta comparación involucra además una diferencia en el número de evaluaciones de L-BFGS entre ambas corridas, por lo que la mejora de $2.5\times$ no puede atribuirse de forma aislada al aumento de capacidad de la red; se reporta como evidencia cualitativa de que $d = 128$ es preferible, no como una ablación controlada. No se dispone de un experimento que aísle la contribución específica del Muestreo Latino Hipercúbico frente a una malla cartesiana equivalente.

Tabla 4.3. Métricas de precisión: PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$).

Métrica	E_{real}	E_{imag}
Error L^2 (%)	0.214	0.127
MSE	2.20×10^{-6}	8.43×10^{-7}
RMSE	1.48×10^{-3}	9.18×10^{-4}
MAE	1.27×10^{-3}	7.71×10^{-4}
Error máximo	3.05×10^{-3}	2.93×10^{-3}
R^2	0.999995	0.999998
Correlación de Pearson	0.999998	0.999999
Error L^2 promedio (%)	0.171	

Evaluado en malla uniforme de 100×100 puntos. Arquitectura: SIREN 5×128 , $\omega_0 = 1.0$, 66,690 parámetros. Puntos de colocación: LHS $N_c = 3,000$. Frontera: onda plana $e^{i(k_x x + k_y y)}$ en 4 bordes, $N_b = 300$ pts/borde. Entrenamiento: Adam (8,737 épocas) + L-BFGS (1,035 evaluaciones de la función objetivo), tiempo total 209.9 s (GPU RTX 5050 laptop, conectada a corriente, sin procesos concurrentes). Dispersión entre semillas ($\text{SEED} \in \{42, 123, 777\}$): error L^2 promedio = 0.192 ± 0.089 % (media $\pm$ desv. est.).

La Figura 4.3 muestra los mapas de calor de la solución exacta y la predicción PINN-SIREN para ambas componentes del campo.

La Figura 4.4 complementa este resultado con la distribución espacial del error puntual para ambas componentes del campo.

4.2.4. Reproducibilidad multi-semilla

Para evaluar la robustez estadística del método, el experimento NB02 se repitió con tres semillas diferentes: $\text{SEED} \in \{42, 123, 777\}$. Los resultados se presentan en la Tabla 4.4.

La desviación estándar inter-semilla de ± 0.089 % representa un coeficiente de variación del 46 % respecto a la media, considerable en términos relativos, pero las tres semillas se mantienen entre 16 y 53 veces por debajo del umbral de la tesis (< 5 %): la inicialización aleatoria afecta la precisión final de forma apreciable, sin comprometer el cumplimiento de la hipótesis (i) en ninguno de los tres casos.




Figura 4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior (A1-A3): solución analítica, predicción PINN-SIREN y error absoluto para E_{real} . Fila central (B1-B3): lo mismo para E_{imag} . Fila inferior: intensidad predicha $I = |E|^2$ (C1), puntos de colocación LHS (C2) y curvas de pérdida durante Adam y L-BFGS (C3). La diferencia visual entre solución exacta y predicción es indistinguible; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.3). Malla de evaluación 100×100 , SEED = 42.

Tabla 4.4. Reproducibilidad multi-semilla: NB02 ($\lambda_{\text{fis}} = 0.1$).

SEED	Error L^2 prom. (%)	Épocas Adam	Tiempo (s)
42	0.1707	8,737	220.7
123	0.0949	9,441	225.9
777	0.3100	10,443	253.2
Media $\pm$ Desv. est.	0.192 ± 0.089	-	-

Misma arquitectura, hiperparámetros y protocolo de entrenamiento (scripts/experiments/run_multiseed.py), ejecutadas en la misma sesión para que los tiempos sean comparables entre sí. GPU: NVIDIA RTX 5050, laptop conectada a corriente. La semilla 42 reproduce el resultado de NB02 ($L^2 = 0.1707\%$ vs. 0.171% , dentro del redondeo).




Figura 4.4. Métricas adicionales de entrenamiento NB02. Paneles A-B: distribución del error absoluto $|E_{\text{real}} - \hat{E}_{\text{real}}|$ y $|E_{\text{imag}} - \hat{E}_{\text{imag}}|$. Paneles C, F: dispersión de la predicción PINN contra la solución exacta para cada componente. Paneles D-E: error relativo puntual (%) en la malla 100×100 ; los valores más altos se concentran en bandas antidiagonales ($x + y \approx \text{const.}$) donde la solución exacta cruza por cero, ya que el error relativo diverge al dividir por un valor cercano a cero, y no en las esquinas del dominio. La curva de pérdida de entrenamiento se muestra en el Panel C3 de la Figura 4.3.

4.3. Ablación del peso de física λ_{fis}

Para calibrar el balance entre el término de datos y el término físico en la función de pérdida (3.4), se realizó un experimento de ablación con $\lambda_{\text{fis}} \in \{0.01, 0.1, 1.0\}$, manteniendo fija la arquitectura SIREN 5×128 y SEED = 42. Los resultados se presentan en la Tabla 4.5.

Tabla 4.5. Ablación del peso de física λ_{fis} : NB02.

λ_{fis}	Error L^2 prom. (%)	Converge	Observación
0.01	0.163	Sí	Física subponderada
0.1	0.171	Sí	Configuración seleccionada
1.0	—	No (<i>crash</i>)	Física sobreponderada

Arquitectura SIREN 5×128 , $\omega_0 = 1.0$, SEED = 42. Mismo protocolo Adam + L-BFGS que NB02. El caso $\lambda = 1.0$ no produjo un valor de L^2 : la corrida se interrumpió por una excepción de CUDA antes de completar el entrenamiento, debido a que los dos residuos (real e imaginario) duplican la contribución de la física y generan gradientes de gran magnitud en `float32`. No es un caso de no convergencia por agotar épocas, sino una falla numérica (`results/ablation_lambda.json`).

El valor $\lambda_{\text{fis}} = 0.1$ se seleccionó por su estabilidad numérica, no por precisión: el modelo con $\lambda = 0.01$ obtiene un error ligeramente menor (0.163 % frente a 0.171 %) al sacrificar restricción física, mientras que $\lambda = 1.0$ produce gradientes explosivos que interrumpen el entrenamiento. Entre las dos configuraciones que sí convergen, $\lambda = 0.1$ se prefiere porque impone una restricción física más fuerte sin un costo de precisión relevante frente al umbral de la tesis.

Esta fragilidad frente al peso relativo de los términos de pérdida no es un fenómeno aislado de esta implementación: Krishnapriyan et al. (2021) documentan sistemáticamente que las PINN con pesos fijos entre el término de datos/condición inicial y el término de residuo físico pueden fallar en converger a la solución correcta incluso cuando la función de pérdida global parece decrecer, atribuyendo el problema a un paisaje de optimización mal condicionado por la competencia entre ambos términos. Wang et al. (2021) describen un mecanismo relacionado: los gradientes del término físico pueden dominar en magnitud a los del término de datos durante el entrenamiento, generando un flujo de gradiente patológico que dificulta la convergencia. La inestabilidad observada con $\lambda = 1.0$ en este trabajo es consistente con ambas caracterizaciones: los dos residuos (real e imaginario) duplican el peso efectivo del término físico, agravando el mismo tipo de desbalance.

4.3.1. Explicación cuantitativa: análisis del núcleo tangente neuronal (NTK)

La teoría del núcleo tangente neuronal (*Neural Tangent Kernel*, NTK) de Wang et al. (2022) permite cuantificar directamente el desbalance descrito arriba: cada término de la función de pérdida induce su propio kernel NTK, y la magnitud relativa de sus autovalores predice qué término domina el gradiente durante el entrenamiento. Sobre el modelo final de NB02 ya entrenado ($\lambda_{\text{fís}} = 0.1$), se calculó el NTK empírico del término de datos (frontera, 80 puntos) y del término de física (residuo de Helmholtz, 80 puntos de colocación LHS).

Tabla 4.6. Espectro NTK: término de datos vs. término de física (NB02).

	Traza NTK	Autovalor máximo
Datos (frontera)	1.45×10^4	5.29×10^3
Física (residuo Helmholtz)	1.24×10^7	8.49×10^6
Razón física / datos	858×	1,605×

Calculado sobre los pesos finales guardados de NB02 (results/models/nb02_helmholtz2d_gpu.pt), sin reentrenar ni modificar los resultados de la Tabla 4.3. NTK aproximado con 80 puntos por término (Jacobiano de E_{real} para datos, del residuo real de Helmholtz para física, respecto a los 66,690 parámetros del modelo).

El espectro NTK del término de física es entre 858 y 1,605 veces mayor que el del término de datos, lo que explica cuantitativamente por qué $\lambda_{\text{fís}} = 1.0$ (peso igual entre ambos términos) resulta en que el gradiente de la física domine por completo el paso de optimización, consistente con la inestabilidad numérica reportada arriba. Esta razón no debe interpretarse como que $\lambda_{\text{fís}} = 0.1$ sea el valor que compensa exactamente el desbalance (una compensación literal sugeriría un factor de reescalamiento considerablemente menor); el análisis NTK aquí presentado explica la *dirección y el orden de magnitud* del desbalance identificado empíricamente en la ablación, no deriva analíticamente el valor óptimo de $\lambda_{\text{fís}}$.

4.4. Contexto en la literatura

La Tabla 4.7 sitúa los resultados de precisión de la PINN-SIREN propuesta junto al antecedente más cercano en la literatura.

El antecedente más cercano en arquitectura a este trabajo es Panagiotakopoulos et al. (2026),

Tabla 4.7. Error L^2 relativo: PINN-SIREN y antecedente de la literatura.

Método	Dimensión	Comparación	Error L^2 (%)
Schoder & Kraxberger (2024)	3D (acústica)	PINN vs. FEM (malla fina)	2.49
Zhang et al. (2025)	2D (EM)	PINN vs. simulación numérica	1.40–5.82
PINN-SIREN (este trabajo)	1D (óptica)	PINN vs. solución analítica	0.006
PINN-SIREN (este trabajo)	2D (óptica)	PINN vs. solución analítica	0.171

Los cuatro resultados no son directamente comparables entre sí: difieren en dimensionalidad, dominio físico (acústico/electromagnético vs. óptico) y tipo de solución de referencia (FEM/simulación numérica vs. analítica). Se presentan como contexto de la literatura, no como línea base de comparación cuantitativa. Los resultados propios se validan contra el umbral fijo de la tesis ($L^2 < 5\%$), independiente de trabajos externos.

quienes resuelven la misma ecuación de Helmholtz 2D con campo complejo, usando también una red SIREN y la misma estrategia de optimización bifásica Adam seguido de L-BFGS. Se diferencia de este trabajo en tres aspectos: (i) validan cualitativamente la física del campo resultante (propagación, refracción, dispersión) en lugar de reportar un error L^2 cuantitativo contra una solución analítica; (ii) no calibran ω_0 respecto al número de onda k ; y (iii) su condición de frontera es una fuente puntual gaussiana con condición de radiación de Sommerfeld, en lugar de la fase aleatoria en $y = 0$ que da lugar al patrón de *speckle* en este trabajo. No aborda, por tanto, la generación de *speckle* ni su validación estadística contra los criterios de Goodman (2007).

4.5. Resumen de experimentos completados

La Tabla 4.8 sintetiza el estado de los cuatro experimentos planificados en los objetivos específicos.

Tabla 4.8. Estado de los experimentos planificados.

Experimento	Descripción	Estado	Métrica principal
NB01	Helmholtz 1D, validación analítica	Completo	$L^2 = 0.006\%$
NB02	Helmholtz 2D, campo complejo	Completo	$L^2 = 0.171\%$
NB03	Speckle óptico, frontera rugosa	Pausado	—
NB04	Benchmark FEM, factor de aceleración	Pendiente	$S = T_{\text{FEM}}/T_{\text{PINN}}$

NB01 y NB02 verifican la hipótesis de precisión ($L^2 < 5\%$). NB03 (speckle óptico por PINN con frontera de fase aleatoria) se pausó tras diagnosticar que el ajuste de frontera y el residuo interior de la EDP no convergen simultáneamente con los hiperparámetros heredados de NB02; el diagnóstico completo se documenta en [archive/nb03_speckle_pausado/](#) para retomarse posteriormente. NB04 es necesario para verificar la hipótesis de velocidad ($S > 1$) y se planifica como trabajo futuro.

Los dos primeros experimentos completados (NB01, NB02) verifican la hipótesis de precisión: el error $L^2 < 5\%$ se supera con amplitud en ambos casos. El tercero (NB03, speckle óptico por PINN) está pausado mientras se consolida el trabajo de validación 1D/2D; el diagnóstico acumulado se conserva para retomarlo (véase [archive/nb03_speckle_pausado/](#)). La hipótesis de velocidad ($S > 1$) requiere la implementación de la referencia FEM (NB04), programada como trabajo futuro inmediato.

Bibliografía

- Alkhalifah, T., Song, C., Waheed, U. b., & Hao, Q. (2021). Wavefield solutions from machine learned functions constrained by the Helmholtz equation. *Artificial Intelligence in Geosciences*, 2, 11-19. <https://doi.org/10.1016/j.aiig.2021.08.002>
- Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(153), 1-43.
- Born, M., & Wolf, E. (1999). *Principles of Optics: Electromagnetic Theory of Propagation, Interference and Diffraction of Light* (7.^a ed.). Cambridge University Press.
- Chen, Y., Lu, L., Karniadakis, G. E., & Dal Negro, L. (2020). Physics-informed neural networks for inverse problems in nano-optics and plasmonics. *Optics Express*, 28(8), 11618-11633. <https://doi.org/10.1364/OE.384875>
- Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next. *Journal of Scientific Computing*, 92(3), 88. <https://doi.org/10.1007/s10915-022-01939-z>
- Fang, Z., & Zhan, J. (2020). Deep physical informed neural networks for metamaterial design. *IEEE Access*, 8, 24506-24513. <https://doi.org/10.1109/ACCESS.2019.2963375>
- Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Roberts & Company.
- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359-366. [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8)
- Jin, J.-M. (2014). *The Finite Element Method in Electromagnetics* (3.^a ed.). John Wiley & Sons.

- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440. <https://doi.org/10.1038/s42254-021-00314-5>
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization [Published at ICLR 2015].
- Krishnapriyan, A. S., Gholami, A., Zhe, S., Kirby, R. M., & Mahoney, M. W. (2021). Characterizing Possible Failure Modes in Physics-Informed Neural Networks [arXiv:2109.01050]. *Advances in Neural Information Processing Systems*, 34, 26548-26560.
- Lagaris, I. E., Likas, A., & Fotiadis, D. I. (1998). Artificial neural networks for solving ordinary and partial differential equations. *IEEE Transactions on Neural Networks*, 9(5), 987-1000. <https://doi.org/10.1109/72.712178>
- Lu, L., Meng, X., Mao, Z., & Karniadakis, G. E. (2021). DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1), 208-228. <https://doi.org/10.1137/19M1274067>
- McKay, M. D., Beckman, R. J., & Conover, W. J. (1979). A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2), 239-245. <https://doi.org/10.1080/00401706.1979.10489755>
- Moseley, B., Markham, A., & Nissen-Meyer, T. (2020). Solving the wave equation with physics-informed deep learning.
- Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization* (2.^a ed.). Springer.
- Panagiotakopoulos, T., Velissaris, C., & Rapsomanikis, A. N. (2026). Physics-Informed Neural Network Solution of the 2D Helmholtz Equation with a Gaussian Source [Repository deposit, publicado el 9 de abril de 2026; aún no revisado por pares; sin DOI disponible]. <https://stars.library.ucf.edu/ucfscholar/1345>
- Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F., Bengio, Y., & Courville, A. (2019). On the spectral bias of neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 97, 5301-5310.
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial

- differential equations. *Journal of Computational Physics*, 378, 686-707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- Schoder, S., & Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. <https://doi.org/10.48550/arXiv.2403.06623>
- Sitzmann, V., Martel, J. N. P., Bergman, A. W., Lindell, D. B., & Wetzstein, G. (2020). Implicit Neural Representations with Periodic Activation Functions. *Advances in Neural Information Processing Systems*, 33, 7462-7473.
- Tancik, M., Srinivasan, P. P., Mildenhall, B., Fridovich-Keil, S., Raghavan, N., Singhal, U., Ramamoorthi, R., Barron, J. T., & Ng, R. (2020). Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains. *Advances in Neural Information Processing Systems*, 33, 7537-7547.
- Wang, S., Teng, Y., & Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5), A3055-A3081. <https://doi.org/10.1137/20M1318043>
- Wang, S., Yu, X., & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449, 110768. <https://doi.org/10.1016/j.jcp.2021.110768>
- Zhang, H., Li, C., Xia, R., Chen, X., Xiao, T., Guo, X.-W., & Liu, J. (2025). FE-PIRBN: Feature-enhanced physics-informed radial basis neural networks for solving high-frequency electromagnetic scattering problems. *Journal of Computational Physics*, 527, 113798. <https://doi.org/10.1016/j.jcp.2025.113798>