



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO EN REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINNS)**

TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: JUNIO 2026



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO EN REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINNS)**

TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: JUNIO 2026

Declaración de Autoría y Originalidad

En la Ciudad de Cunduacán el día Siete del mes de Junio del año 2026, el que suscribe **Roberto Hernández Estrada**, alumno del Programa de la **Maestría en Ciencias de la Computación** con número de matrícula **252H21004**, adscrito a la **División Académica de Ciencias y Tecnologías de la Información**, de la Universidad Juárez Autónoma de Tabasco, como autor de la Tesis presentada para la obtención del Grado de Maestría y titulada **Simulación acelerada de speckle óptico: Un enfoque basado en redes neuronales físicamente informadas (PINNs)**, dirigida por el Dr. José Adán Hernández Nolasco.

DECLARO QUE: La Tesis es una obra original que no infringe los derechos de propiedad intelectual ni los derechos de propiedad industrial u otros, de acuerdo con el ordenamiento jurídico vigente, en particular, la LEY FEDERAL DEL DERECHO DE AUTOR (Decreto por el que se reforman y adicionan diversas disposiciones de la Ley Federal del Derecho de Autor del 01 de Julio de 2020 regularizando, aclarando y armonizando las disposiciones legales vigentes sobre la materia), en particular, las disposiciones referidas al derecho de cita. Del mismo modo, asumo frente a la Universidad cualquier responsabilidad que pudiera derivarse de la autoría o falta de originalidad o contenido de la Tesis presentada de conformidad con el ordenamiento jurídico vigente.

Cunduacán, Tabasco a 07 de Junio de 2026.

Estudiante: Roberto Hernández Estrada



UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO

"ESTUDIO EN LA DUDA. ACCIÓN EN LA FE"



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN



Cunduacán, Tabasco a 30 de septiembre de 2024

Oficio No. 1220/DACYTI/CP/2024

Asunto: Autorización de impresión de Tesis

C. Fernando Contreras Pérez

Egresado de la Maestría en Ciencias de la Computación

En virtud de que cumple satisfactoriamente los requisitos establecidos en el Reglamento General de Estudios de Posgrado vigente en la Universidad, informo a Usted que se autoriza la impresión del trabajo recepcional **"Identificación automática de vehículos empleando aprendizaje profundo"**, para presentar examen y obtener el Grado de Maestro en Ciencias de la Computación.

Sin otro particular, aprovecho la ocasión para enviarle un afectuoso saludo.

Atentamente

MTE. Óscar Alberto González González
Director

UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN

C.c.p. Dr. Eddy Arquímedes García Alcocer. - Encargado del Despacho de la Coordinación de Posgrado DACYTI
Archivo.
Consecutivo.

M.T.E. OAGG/EAGA X

Carretera Cunduacán-Jalpa Km. 1, Colonia Esmeralda, C.P. 86690.
Cunduacán, Tabasco, México.
Tel: (993) 358 1500 ext. 6727; (914) 336 0616; Fax: (914) 336 0870
E-mail: direccion.dacyti@ujat.mx

www.ujat.mx

Carta de Cesión de Derechos

Cunduacán, Tabasco a 07 de Junio de 2026.

Por medio de la presente manifiesto haber colaborado como AUTOR en la producción, creación y/o realización de la obra denominada: **Simulación acelerada de speckle óptico: Un enfoque basado en redes neuronales físicamente informadas (PINNs)**.

Con fundamento en el artículo 83 de la Ley Federal del Derecho de Autor y toda vez que, la creación y/o realización de la obra antes mencionada se realizó bajo la comisión de la Universidad Juárez Autónoma de Tabasco; entendemos y aceptamos el alcance del artículo en mención de que tenemos el derecho al reconocimiento como autores de la obra, y a la Universidad Juárez Autónoma de Tabasco mantendrá en un 100 % la titularidad de los derechos patrimoniales por un período de 20 años sobre la obra en la que colaboramos, por lo anterior, cedemos el derecho patrimonial exclusivo en favor de la Universidad.

COLABORADOR

Estudiante: Roberto Hernández Estrada

TESTIGOS

Dr. José Adán Hernández Nolasco

Dr. Óscar Alberto Chávez Bosquez

Índice general

Índice de Figuras	IV
Índice de Tablas	VI
Resumen	VII
Abstract	VIII
1. Generalidades	1
1.1. Introducción	1
1.2. Planteamiento del problema	2
1.2.1. Definición del problema	2
1.2.2. Delimitación de la investigación	3
1.3. Preguntas de investigación e hipótesis	4
1.4. Objetivo general	5
1.5. Objetivos específicos	5
1.6. Justificación	6
1.7. Metodología	7
2. Marco Teórico	9
2.1. Conceptos y teorías fundamentales	9
2.1.1. Ecuación de onda de Helmholtz	9
2.1.2. Speckle óptico completamente desarrollado	10
2.1.3. Redes Neuronales Informadas por Física (PINNs)	10

2.1.4. Redes SIREN y sesgo espectral	11
2.1.5. Diferenciación automática	12
2.1.6. Muestreo Latino Hipercúbico (LHS)	12
2.1.7. Optimización híbrida Adam + L-BFGS	13
2.2. Literatura relacionada	13
2.3. Marco tecnológico	15
2.3.1. Infraestructura de hardware	15
2.3.2. Ecosistema de software	16
3. Modelo e implementación	17
3.1. Formulación del problema	17
3.1.1. Experimento 1 (NB01): Validación 1D	17
3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo	18
3.1.3. Experimento 3 (NB03): Simulación de speckle óptico	18
3.2. Arquitectura SIREN	20
3.3. Función de pérdida y calibración de pesos	21
3.4. Estrategia de muestreo	22
3.4.1. Puntos interiores (colocación)	22
3.4.2. Puntos de frontera	22
3.5. Estrategia de optimización	23
3.6. Métricas de validación	23
3.6.1. Métricas de NB03: campo complejo y estadística de speckle	23
3.6.2. Error L^2 relativo (NB01 y NB02)	24
3.7. Implementación modular	24
4. Experimentos y Resultados	26
4.1. NB01: Validación 1D, Helmholtz con solución analítica	26
4.1.1. Configuración experimental	26
4.1.2. Resultados de precisión	26
4.1.3. Análisis y comparativa con el estado del arte	27
4.1.4. Barrido de ω_0 : evidencia cuantitativa del sesgo espectral	29

4.2. NB02: Validación 2D, Helmholtz con campo complejo	30
4.2.1. Configuración experimental	30
4.2.2. Resultados de precisión	30
4.2.3. Análisis de resultados	30
4.2.4. Reproducibilidad multi-semilla	31
4.2.5. Ablación de profundidad: 4 frente a 5 capas	34
4.3. Ablación del peso de física λ_{fis}	34
4.3.1. Diagnóstico espectral: análisis del núcleo tangente neuronal (NTK)	36
4.4. NB03: Simulación de speckle óptico	37
4.4.1. Diagnóstico del planteamiento: por qué la formulación directa no extiende	37
4.4.2. Experimento puente: aislamiento del planteamiento	37
4.4.3. Validación de la arquitectura modal contra solución exacta	38
4.4.4. Formulación modal adoptada	40
4.4.5. Verificación de la referencia	41
4.4.6. Calibración de ω_0 en el régimen modal	42
4.4.7. Resultados en $\tilde{z} = 1\lambda$	43
4.4.8. Dependencia del piso evanescente con la distancia	43
4.4.9. Criterio estadístico: conjunto frente a realización individual	45
4.4.10. Ensayo de extensión a $\tilde{z} = 2\lambda$: resultado negativo	46
4.4.11. Tiempo de inferencia frente a la referencia de propagación	47
4.4.12. Limitaciones del método	48
4.5. Contexto en la literatura	49
4.6. Resumen de experimentos completados	50

Bibliografía

52

Índice de figuras

4.1. Validación PINN-SIREN para Helmholtz 1D. Panel A: comparación entre la predicción de la red y la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel B: error puntual $ \hat{E}(x) - E_{\text{exacta}}(x) $. Panel C: curva de pérdida total durante las fases Adam y L-BFGS; la transición a la época 15,000 es visible como una caída abrupta. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.	27
4.2. Métricas adicionales de entrenamiento NB01. Panel A: distribución del error absoluto $ \hat{E}(x) - E_{\text{exacta}}(x) $. Panel B: error relativo puntual (%). Panel C: dispersión de la predicción PINN contra la solución exacta, con la línea $y = x$ como referencia de ajuste perfecto.	29
4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior (A1-A3): solución analítica, predicción PINN-SIREN y error absoluto para E_{real} . Fila central (B1-B3): lo mismo para E_{imag} . Fila inferior: intensidad predicha $I = E ^2$ (C1), puntos de colocación LHS (C2) y curvas de pérdida durante Adam y L-BFGS (C3). La diferencia visual entre solución exacta y predicción es muy pequeña a esta escala; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.3). Malla de evaluación 100×100 , SEED = 42.	32

4.4. Métricas adicionales de entrenamiento NB02. Paneles A-B: distribución del error absoluto $ E_{\text{real}} - \hat{E}_{\text{real}} $ y $ E_{\text{imag}} - \hat{E}_{\text{imag}} $. Paneles C, F: dispersión de la predicción PINN contra la solución exacta para cada componente. Paneles D-E: error relativo puntual (%) en la malla 100×100 ; los valores más altos se concentran en bandas antidiagonales ($x + y \approx \text{const.}$) donde la solución exacta cruza por cero, ya que el error relativo diverge al dividir por un valor cercano a cero, y no en las esquinas del dominio. La curva de pérdida de entrenamiento se muestra en el Panel C3 de la Figura 4.3.	33
4.5. Resultados de NB03: calibración de ω_0 y piso evanescente	44

Índice de tablas

3.1. Hiperparámetros de entrenamiento consolidados.	23
4.1. Métricas de precisión: PINN-SIREN 1D ($k = 2\pi$).	28
4.2. Barrido de ω_0 sobre el problema de NB01 (3,000 épocas Adam).	29
4.3. Métricas de precisión: PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$).	31
4.4. Reproducibilidad multi-semilla: NB02 ($\lambda_{\text{fis}} = 0.1$).	32
4.5. Ablación de profundidad en NB01 y NB02.	34
4.6. Ablación del peso de física λ_{fis} : NB02.	35
4.7. Espectro NTK: término de datos vs. término de física (NB02).	36
4.8. Experimento puente: misma solución analítica, tres planteamientos.	38
4.9. Arquitectura modal de NB03 frente a una solución analítica exacta.	39
4.10. Configuración de NB03 frente a NB01 y NB02.	41
4.11. Barrido de ω_0 en la formulación modal (pantalla 42, 5,000 épocas Adam).	42
4.12. NB03 modal con ω_0 calibrado: cinco pantallas de fase independientes en $\tilde{z} = 1\lambda$	43
4.13. Piso evanescente y contraste de la referencia en función de la distancia.	44
4.14. Ensayo de extensión a $\tilde{z} = 2\lambda$ con presupuesto uniforme.	46
4.15. Tiempo de evaluación: PINN-SIREN modal frente al espectro angular.	47
4.16. Error L^2 relativo: PINN-SIREN y antecedente de la literatura.	50
4.17. Estado de los experimentos planificados.	50

Resumen

Se presenta una implementación de Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la validación de la resolución de la ecuación de Helmholtz en una y dos dimensiones, como base para la simulación de speckle óptico. Con $\omega_0 = 1.0$ calibrado al número de onda, la arquitectura SIREN alcanza un error L^2 de 0.006 % en el caso 1D (5×64 neuronas) y de 0.171 % en el caso 2D (5×128) respecto a soluciones analíticas, tres y casi dos órdenes de magnitud por debajo del umbral de tesis (5 %). La extensión a speckle se formula mediante una pantalla de fase aleatoria espacialmente correlacionada y una referencia semianalítica de propagación por espectro angular, y se resuelve con una reducción modal que impone la condición de Cauchy de forma exacta en la arquitectura. En cinco realizaciones de fase independientes a $z = 1\lambda$ el error L^2 del campo complejo es de 3.161 %, dominado por la fracción evanescente del espectro que la base modal no puede representar; medido sobre el subespacio propagante, el error es de 0.042 %. El contraste del conjunto es $C = 0.9489$. El contraste de referencia promedio de los conjuntos de 64 realizaciones es $C = 0.9661$. Una estrategia de optimización bifásica Adam + L-BFGS y el muestreo por hipercubo latino (LHS) se emplean en el protocolo de entrenamiento. La reproducibilidad del método fue verificada con tres semillas independientes, obteniendo un promedio componente a componente de error L^2 de 0.192 ± 0.089 % (desviación estándar poblacional).

Palabras clave: Redes Neuronales Informadas por Física, SIREN, ecuación de Helmholtz, speckle óptico, activación sinusoidal, muestreo por hipercubo latino.

Abstract

Physics-Informed Neural Networks with sinusoidal activation functions (SIREN-PINNs) are evaluated for solving the Helmholtz equation in one and two dimensions as a foundation for optical speckle simulation. With $\omega_0 = 1.0$ calibrated to the wavenumber, the SIREN architecture achieves relative L^2 errors of 0.006 % in 1D (5×64 neurons) and 0.171 % in 2D (5×128) against analytical solutions, three and nearly two orders of magnitude below the 5 % thesis threshold. The speckle extension uses a spatially correlated random-phase screen and a semianalytical angular-spectrum reference, and is solved through a modal reduction that imposes the Cauchy condition exactly within the architecture. Across five independent phase realizations at $z = 1\lambda$ the complex-field L^2 error is 3.161 %, dominated by the evanescent fraction of the spectrum that the modal basis cannot represent; measured over the propagating subspace the error is 0.042 %. The ensemble contrast is $C = 0.9489$, against a mean reference ensemble contrast of $C = 0.9661$ over 64 realizations each. A two-phase Adam + L-BFGS optimization strategy and Latin Hypercube Sampling (LHS) are used in the training protocol. Reproducibility was verified with three independent random seeds, yielding a component-wise mean L^2 error of 0.192 ± 0.089 % (population standard deviation).

Keywords: Physics-Informed Neural Networks, SIREN, Helmholtz equation, optical speckle, sinusoidal activation, Latin Hypercube Sampling.

Capítulo 1

Generalidades

1.1. Introducción

La simulación de la propagación de la luz es una herramienta fundamental en la ciencia y la ingeniería, con aplicaciones que abarcan desde el diseño de sistemas de telecomunicaciones y la nanofotónica hasta el desarrollo de técnicas de imagenología médica. Un fenómeno de particular interés es el *speckle* óptico, un patrón de interferencia granular de alto contraste que surge cuando luz coherente, como la emitida por un láser, se dispersa sobre una superficie rugosa o un medio difusor.

Tradicionalmente, la simulación de estos fenómenos ondulatorios se aborda mediante métodos numéricos robustos como el Método de Elementos Finitos (*FEM*) o métodos estocásticos como el de Monte Carlo. Sin embargo, estos métodos presentan un cuello de botella computacional significativo: requieren una discretización suficientemente fina del dominio espacial para resolver las oscilaciones del campo de luz. Esto puede aumentar el consumo de memoria y el tiempo de cómputo, especialmente cuando se necesitan muchas realizaciones estadísticas (Goodman, 2007; Jin, 2014).

En paralelo, el campo de la inteligencia artificial ha experimentado un crecimiento disruptivo. Una innovación reciente son las Redes Neuronales Informadas por Física (*PINNs*, por sus siglas en inglés *Physics-Informed Neural Networks*), una metodología que fusiona el *Deep Learning* con las leyes físicas fundamentales. Las *PINNs* (Raissi et al., 2019) son redes neuronales entrenadas no solo para ajustarse a datos de frontera, sino para obedecer directamente una Ecuación

Diferencial Parcial (EDP) que gobierna el fenómeno físico de interés.

No obstante, las activaciones estándar de las redes neuronales ($\tanh$, ReLU) presentan un sesgo espectral (Rahaman et al., 2019): tienden a aprender frecuencias bajas antes que las altas. Para la ecuación de Helmholtz con número de onda $k = 2\pi$, este sesgo puede dificultar el ajuste de soluciones oscilatorias y hacer más exigente el cálculo de derivadas de segundo orden. Las *Sinusoidal Representation Networks (SIREN)*, propuestas por Sitzmann et al. (2020), utilizan la activación $\phi(z) = \sin(\omega_0 z)$; por ello se seleccionan en este trabajo como una arquitectura adecuada para evaluar ecuaciones de onda, sin asumir que sean universalmente superiores.

Este proyecto se sitúa en la intersección de la óptica computacional y la inteligencia artificial, aplicando el paradigma PINN-SIREN para superar las limitaciones computacionales de los métodos clásicos en la simulación del *speckle* óptico.

1.2. Planteamiento del problema

1.2.1. Definición del problema

La simulación precisa de cómo la luz se dispersa y forma patrones de *speckle* es crucial para sistemas ópticos avanzados en imagenología biomédica (tomografía de coherencia óptica), metrología (medición de vibraciones y deformaciones) y criptografía óptica.

El desafío central radica en el costo computacional prohibitivo de los métodos numéricos actuales:

1. **Métodos Basados en Malla (FEM):** Para capturar con precisión los detalles finos de un patrón de *speckle*, la malla debe tener una resolución espacial menor que la longitud de onda de la luz (Jin, 2014). En dominios grandes o con alta resolución esto puede conducir a sistemas con un número muy elevado de incógnitas, además de requerir memoria y tiempo de ejecución considerables. Cada nuevo perfil de rugosidad superficial puede exigir repetir la resolución del problema.
2. **Métodos Estocásticos (Monte Carlo):** Requieren simular un número masivo de fotones individuales para construir un patrón estadísticamente preciso, lo que los hace prohibitivos para estudios paramétricos que requieren miles de realizaciones.

Aunque la aplicación de las *PINNs* para resolver la ecuación de Helmholtz ha sido validada en simulaciones de ondas acústicas (Schoder & Kraxberger, 2024) y, de forma más reciente, en contextos bidimensionales de Helmholtz con arquitectura SIREN (Panagiotakopoulos et al., 2026), en la revisión realizada no se identificó un trabajo que combine simultáneamente la activación sinusoidal, una regla explícita de calibración de ω_0 respecto al número de onda y la generación de *speckle* óptico desde una condición de frontera de fase aleatoria validada estadísticamente conforme al criterio de Goodman. Esta combinación es la que aborda el presente trabajo y deberá contrastarse con una revisión sistemática más amplia si se formula como afirmación de novedad.

Este trabajo propone tres elementos que, en conjunto, no se encontraron en la literatura revisada. Primero, una regla de calibración $\omega_0 \approx k/(2\pi)$ que vincula el hiperparámetro de frecuencia de SIREN al número de onda físico, no identificada en la propuesta original de SIREN (Sitzmann et al., 2020) ni en Panagiotakopoulos et al. (2026), el trabajo más cercano arquitectónicamente encontrado en la revisión de literatura (misma red SIREN, mismo campo complejo, misma estrategia de optimización Adam seguida de L-BFGS). Segundo, la generación de *speckle* óptico mediante la resolución directa de la ecuación de Helmholtz desde una condición de frontera de fase aleatoria, en lugar de ajustar un modelo a patrones de *speckle* ya medidos. Tercero, la validación estadística del patrón generado conforme al criterio de Goodman, no identificada en los trabajos de PINN aplicados a la ecuación de Helmholtz incluidos en esta revisión.

La contribución se plantea como un marco de validación reproducible: la PINN se compara contra una referencia independiente de propagación por espectro angular, se evalúa con realizaciones de fase no utilizadas durante el ajuste y se reportan simultáneamente métricas de campo complejo y estadísticas de *speckle*. La afirmación de novedad queda limitada a esta combinación y deberá sostenerse únicamente con los resultados que superen los criterios cuantitativos definidos en el Capítulo 3.

1.2.2. Delimitación de la investigación

Alcances

- Se entregará un prototipo de *software* funcional, implementado en Python (PyTorch), capaz de construir y entrenar un modelo PINN-SIREN para resolver la ecuación de Helmholtz en

dominios 2D.

- Se validará cuantitativamente la precisión del modelo contra soluciones analíticas conocidas mediante el error relativo L^2 en NB01 y NB02, y contra una referencia numérica independiente en NB03.
- Se implementará una extensión del modelo para simular la generación de patrones de *speckle* óptico en 2D, mediante una pantalla de fase aleatoria espacialmente correlacionada y limitada al régimen propagante.
- Se evaluará estadísticamente el patrón generado conforme al criterio de Goodman para *speckle* completamente desarrollado (Goodman, 2007), una vez que NB03 alcance una solución física consistente.
- Se realizará una evaluación comparativa (*benchmark*) del tiempo de inferencia contra una referencia numérica de propagación y, cuando el problema se formule con fronteras absorbentes, contra una implementación FEM.

Limitaciones

- **Dimensionalidad:** Todas las simulaciones se restringen a dominios bidimensionales (2D). El desarrollo en 3D está fuera del alcance de este trabajo de maestría.
- **Alcance computacional:** Esta es una investigación puramente computacional y de simulación. No se incluyen montajes ópticos experimentales ni validación contra datos físicos reales.
- **Simplificación del medio difusor:** El medio se modela como una frontera con fase aleatoria discreta ($N_\psi = 256$ puntos). No se aborda la simulación de medios volumétricos ni propiedades no lineales.

1.3. Preguntas de investigación e hipótesis

Las preguntas que guían esta investigación son:

1. ¿Puede un modelo PINN con activación sinusoidal (SIREN) aproximar con precisión la solución de la ecuación de Helmholtz 2D para la simulación de patrones de *speckle* óptico, logrando un error complejo relativo $L^2 < 5\%$ respecto a una referencia numérica independiente?
2. ¿Cuál es la ganancia en eficiencia computacional (tiempo de inferencia y uso de memoria) del enfoque PINN-SIREN respecto al FEM para simular el mismo fenómeno?
3. ¿Presenta el patrón de intensidad simulado las propiedades estadísticas características del *speckle* completamente desarrollado definidas por la teoría de Goodman?

Hipótesis: El desarrollo de un modelo PINN-SIREN para la resolución de la ecuación de Helmholtz 2D con campo complejo permitirá: (i) simular la generación de *speckle* óptico con un error relativo $L^2 < 5\%$ respecto a la referencia correspondiente al experimento: analítica en NB01/NB02 y numérica independiente en NB03; (ii) obtener un factor de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}} > 1$ en la fase de inferencia; y (iii) preservar las propiedades estadísticas del fenómeno con un contraste de *speckle* $|C - 1| < 0.1$ conforme al criterio de Goodman (2007).

1.4. Objetivo general

Construir y validar un modelo computacional basado en Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la simulación acelerada y físicamente precisa de patrones de *speckle* óptico, mediante la resolución directa de la ecuación de Helmholtz bidimensional con campo eléctrico complejo.

1.5. Objetivos específicos

1. Diseñar e implementar una arquitectura SIREN que incorpore el residuo de la ecuación de Helmholtz en su función de pérdida, con activación $\phi(z) = \sin(\omega_0 z)$ y una estrategia de inicialización que preserve la distribución de activaciones en profundidad (Sitzmann et al., 2020).

2. Entrenar y validar la precisión del modelo PINN-SIREN en el escenario unidimensional (NB01), comparando contra la solución analítica $E(x) = \cos(kx)$ mediante el error relativo L^2 .
3. Escalar el modelo al caso bidimensional con campo complejo (NB02), empleando Muestreo Latino Hipercúbico (LHS) para los puntos de colocación y validando contra la solución de onda plana $E = e^{i(k_x x + k_y y)}$.
4. Aplicar el modelo validado a la simulación de *speckle* óptico (NB03) mediante una pantalla de fase aleatoria correlacionada, condiciones laterales periódicas y una condición de propagación saliente, y validar el campo contra el espectro angular y el patrón conforme al criterio de Goodman.
5. Comparar cuantitativamente el rendimiento computacional del modelo PINN-SIREN contra una implementación FEM de referencia (NB04), cuantificando el factor de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}}$.

1.6. Justificación

Esta investigación se justifica en tres ejes principales:

- **Justificación computacional:** El principal obstáculo en la simulación óptica avanzada es el costo computacional de los métodos de malla. El enfoque *mesh-free* propuesto evalúa si es posible reducir los tiempos de simulación y facilitar estudios estadísticos de *speckle* que resultan costosos con los métodos de referencia.
- **Justificación científica:** La simulación precisa de *speckle* impacta directamente en la imagenología biomédica (tomografía de coherencia óptica), la metrología de precisión y la criptografía óptica. Acelerar la simulación tiene consecuencias directas en la capacidad de innovar en estas áreas de alto impacto.
- **Justificación programática:** El proyecto se alinea estratégicamente con la Línea de Generación y Aplicación del Conocimiento (LGAC) en Ciencia de Datos e Inteligencia Artificial

de la Maestría en Ciencias de la Computación de la UJAT. Aplica una técnica de vanguardia en *Deep Learning* para resolver una EDP fundamental de la física, demostrando la sinergia entre la IA y la ciencia computacional avanzada.

1.7. Metodología

La metodología se basa en el marco de trabajo de las *PINNs* propuesto por Raissi et al. (2019), extendido con la arquitectura de activación sinusoidal SIREN (Sitzmann et al., 2020). El proyecto es un estudio computacional cuantitativo y experimental, desarrollado en cuatro fases alineadas con los objetivos específicos.

Fase 1 - NB01: Validación analítica 1D. Se implementa el modelo PINN-SIREN (5×64 neuronas) para resolver la ecuación de Helmholtz 1D con solución analítica conocida $E(x) = \cos(kx)$. La función de pérdida combina el error en las condiciones de frontera Dirichlet y el residuo de Helmholtz evaluado en puntos de colocación uniformes. Se emplea una estrategia de optimización bifásica: Adam (hasta 15,000 épocas) seguido de L-BFGS (búsqueda de línea *strong Wolfe*).

Fase 2 - NB02: Escala a 2D con campo complejo. Se escala la arquitectura a 5×128 neuronas para acomodar el campo complejo ($E_{\text{real}}, E_{\text{imag}}$). Se introduce el Muestreo Latino Hipercúbico (LHS) con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por lado (McKay et al., 1979). Se calibra el peso de la función de pérdida $\lambda_{\text{fis}} = 0.1$ mediante ablación.

Fase 3 - NB03: Simulación de *speckle* óptico. Se aplica el modelo validado a la generación de *speckle* en el dominio de propagación $x/\lambda \in [-10, 10]$ y $z/\lambda \in [0, 20]$. La pantalla de fase tiene correlación espacial finita para evitar una condición dominada por modos evanescentes. En la dirección transversal se impone periodicidad y en la dirección longitudinal se selecciona la propagación saliente mediante el campo y la derivada en la interfaz de entrada. Para mejorar la estabilidad, el dominio se entrena por bloques cortos en z , transfiriendo el campo y su derivada entre interfaces. La PINN se compara contra la referencia de espectro angular sin usar valores interiores de esa referencia durante el ajuste. La validación estadística sigue

el criterio de Goodman (Goodman, 2007): contraste $C = \sigma_I / \langle I \rangle$, distribución de intensidad y, como diagnóstico complementario, el test de Kolmogorov-Smirnov.

Fase 4 - NB04: Benchmark FEM (trabajo futuro). Comparación cuantitativa del tiempo de inferencia PINN-SIREN contra una implementación de referencia con FEniCSx, para calcular el factor de aceleración $S = T_{\text{FEM}} / T_{\text{PINN}}$ y la huella de memoria pico. Esta fase está programada como trabajo futuro inmediato.

Capítulo 2

Marco Teórico

2.1. Conceptos y teorías fundamentales

Esta sección establece los fundamentos teóricos sobre los cuales se construye el modelo PINN-SIREN para la simulación de *speckle* óptico.

2.1.1. Ecuación de onda de Helmholtz

La propagación de luz coherente monocromática en un medio homogéneo e isótropo está gobernada por la ecuación de onda de Helmholtz escalar (Born & Wolf, 1999; Goodman, 2007; Jin, 2014):

$$\nabla^2 E(\mathbf{r}) + k^2 E(\mathbf{r}) = 0, \quad (2.1)$$

donde $E(\mathbf{r}) \in \mathbb{C}$ es la amplitud compleja del campo eléctrico, $k = 2\pi/\lambda$ es el número de onda y λ la longitud de onda del láser. En dos dimensiones espaciales ($\mathbf{r} = (x, y)$):

$$\frac{\partial^2 E}{\partial x^2} + \frac{\partial^2 E}{\partial y^2} + k^2 E = 0. \quad (2.2)$$

Dado que las redes neuronales operan sobre números reales, el campo complejo se descompone en sus partes real e imaginaria: $E = E_{\text{real}} + iE_{\text{imag}}$. Ambas componentes satisfacen la

ecuación (2.2) de forma independiente:

$$\nabla^2 E_{\text{real}} + k^2 E_{\text{real}} = 0, \quad \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}} = 0. \quad (2.3)$$

La intensidad física observable del *speckle* se calcula como:

$$I(x, y) = |E|^2 = E_{\text{real}}^2 + E_{\text{imag}}^2. \quad (2.4)$$

2.1.2. Speckle óptico completamente desarrollado

Cuando una superficie rugosa con variación de fase $\Delta\psi \gtrsim 2\pi$ es iluminada por luz coherente, las contribuciones de los distintos puntos de la superficie interfieren de forma aleatoria. Por el Teorema del Límite Central, el campo complejo resultante sigue una distribución gaussiana circular compleja (Goodman, 2007):

$$E_{\text{real}}, E_{\text{imag}} \sim \mathcal{N}(0, \sigma_E^2), \quad \text{independientes.} \quad (2.5)$$

La intensidad $I = |E|^2$ sigue entonces una distribución exponencial negativa:

$$p(I) = \frac{1}{\langle I \rangle} \exp\left(-\frac{I}{\langle I \rangle}\right), \quad I \geq 0, \quad (2.6)$$

con valor esperado $\langle I \rangle = 2\sigma_E^2$ y desviación estándar $\sigma_I = \langle I \rangle$. El *contraste del speckle* se define como:

$$C = \frac{\sigma_I}{\langle I \rangle} = 1, \quad (2.7)$$

criterio que vale exactamente 1 para *speckle* completamente desarrollado y disminuye cuando el campo pierde coherencia o la rugosidad es insuficiente (Goodman, 2007).

2.1.3. Redes Neuronales Informadas por Física (PINNs)

El uso de redes neuronales para aproximar soluciones de EDPs tiene un antecedente temprano en Lagaris et al. (1998), quienes demostraron que redes feedforward podían aproximar soluciones de ecuaciones diferenciales ordinarias y parciales mediante una función de prueba

que satisface las condiciones de frontera exactamente. Las PINNs modernas fueron formuladas posteriormente por Raissi et al. (2019). La capacidad de aproximación universal de las redes feedforward fue formalizada por Hornik et al. (1989).

Las PINNs modernas, introducidas por Raissi et al. (2019) y revisadas extensamente en Karniadakis et al. (2021) y Cuomo et al. (2022), aproximan la solución de una EDP mediante una red neuronal $\mathcal{N}_\theta(\mathbf{r})$ cuyos parámetros θ se optimizan minimizando una función de pérdida compuesta:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{datos}}(\theta) + \lambda_{\text{fís}} \mathcal{L}_{\text{física}}(\theta), \quad (2.8)$$

donde $\mathcal{L}_{\text{datos}}$ penaliza el error en las condiciones de frontera y $\mathcal{L}_{\text{física}}$ penaliza la violación de la EDP en el interior del dominio. Para la ecuación de Helmholtz 2D con campo complejo:

$$\mathcal{L}_{\text{datos}}(\theta) = \frac{1}{N_b} \sum_{j=1}^{N_b} \left\| \mathcal{N}_\theta(\mathbf{r}_j^b) - E(\mathbf{r}_j^b) \right\|^2, \quad (2.9)$$

$$\mathcal{L}_{\text{física}}(\theta) = \frac{1}{N_c} \sum_{i=1}^{N_c} [R_{\text{real}}(\mathbf{r}_i^c)^2 + R_{\text{imag}}(\mathbf{r}_i^c)^2], \quad (2.10)$$

donde $R_{\text{real}} = \nabla^2 E_{\text{real}} + k^2 E_{\text{real}}$ y $R_{\text{imag}} = \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}}$ son los residuos de Helmholtz, $\{\mathbf{r}_j^b\}$ son los puntos de frontera y $\{\mathbf{r}_i^c\}$ los puntos de colocación interiores. Las derivadas $\nabla^2 E$ se obtienen mediante diferenciación automática (Baydin et al., 2018).

2.1.4. Redes SIREN y sesgo espectral

Las activaciones estándar basadas en rectificadores presentan un sesgo espectral (Rahaman et al., 2019): tienden a aprender frecuencias bajas antes que las altas. En una PINN para Helmholtz, esta tendencia puede dificultar el ajuste de soluciones oscilatorias y hacer más exigente la optimización de derivadas de segundo orden. En particular, la segunda derivada clásica de ReLU es nula casi en todas partes, por lo que no es una elección adecuada para representar directamente un Laplaciano no trivial mediante diferenciación automática.

Sitzmann et al. (2020) proponen las redes SIREN (*Sinusoidal Representation Networks*), que

utilizan la activación $\phi(z) = \sin(\omega_0 z)$ con una inicialización específica:

$$\mathbf{h}_\ell = \sin(\omega_0 (\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell)), \quad \ell = 1, \dots, L, \quad (2.11)$$

donde las matrices $\mathbf{W}_\ell$ se inicializan según $\mathcal{U}(-\sqrt{6/d}/\omega_0, \sqrt{6/d}/\omega_0)$ para capas intermedias y $\mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa. Esta inicialización busca mantener controlada la escala de las activaciones y de sus derivadas; no implica que las activaciones tengan una distribución uniforme ni constituye por sí sola una garantía de estabilidad. La suavidad de la función seno permite calcular derivadas de orden superior con diferenciación automática, que es la propiedad relevante para este trabajo.

Una alternativa relacionada para mitigar el sesgo espectral es el mapeo de características de Fourier (*Fourier feature mapping*) propuesto por Tancik et al. (2020), que proyecta las coordenadas de entrada a través de funciones seno/coseno como una capa de preprocesamiento antes de una MLP estándar. SIREN incorpora este mismo principio de codificación periódica directamente en la función de activación de cada capa, en lugar de aplicarlo como una transformación previa de las coordenadas de entrada, lo que le permite propagar la periodicidad a través de toda la red y facilita el cálculo de derivadas de orden superior mediante diferenciación automática.

2.1.5. Diferenciación automática

La diferenciación automática (*autodiff*) permite calcular derivadas de cualquier orden mediante la aplicación sucesiva de la regla de la cadena sobre el grafo de operaciones del programa (Baydin et al., 2018). En el contexto de las PINNs, *autodiff* actúa como el motor que permite evaluar el Laplaciano ∇^2 directamente sobre las salidas de la red neuronal respecto a sus coordenadas de entrada, sin introducir el error de truncamiento propio de las diferencias finitas; los resultados siguen sujetos a los errores de redondeo y precisión del cálculo numérico.

2.1.6. Muestreo Latino Hipercúbico (LHS)

El Muestreo Latino Hipercúbico (McKay et al., 1979) es una estrategia de muestreo estratificado para distribuir puntos de colocación en el dominio computacional Ω . Su ventaja aquí es

proporcionar una cobertura estratificada reproducible con un número fijo de puntos; no garantiza por sí misma una cobertura óptima ni una convergencia más rápida de la PINN. A diferencia del muestreo aleatorio simple, el LHS divide cada dimensión en N_c estratos iguales y coloca exactamente un punto por estrato, garantizando cobertura estratificada sin imponer una malla cartesiana. En este proyecto se evalúa con $N_c = 3,000$ puntos; cualquier ventaja adicional en memoria o tiempo de convergencia es dependiente de la implementación y no se ha aislado frente a una malla cartesiana equivalente.

2.1.7. Optimización híbrida Adam + L-BFGS

El entrenamiento de NB01 y NB02 sigue una estrategia bifásica de Adam seguido de L-BFGS, práctica extendida en la literatura de PINNs (Cuomo et al., 2022):

1. **Fase 1 (Adam):** Optimizador estocástico de primer orden (Kingma & Ba, 2015) con tasa de aprendizaje $\eta = 10^{-3}$, paciencia de 800 épocas sin mejora mayor que $\delta = 10^{-7}$ y un máximo de 15,000 épocas. En este trabajo, Adam actualiza los parámetros durante la fase inicial y proporciona el punto de partida para L-BFGS; no se interpreta como una búsqueda global ni como una garantía de proximidad al mínimo global.
2. **Fase 2 (L-BFGS):** Optimizador cuasi-Newton de segundo orden (*Limited-memory Broyden-Fletcher-Goldfarb-Shanno*) (Nocedal & Wright, 2006) con búsqueda de línea *strong Wolfe*, máximo 1,000 iteraciones y tamaño de historial 100. L-BFGS aprovecha la información de curvatura para realizar un ajuste fino de alta precisión desde el punto entregado por Adam.

Esta combinación se adopta como protocolo de entrenamiento: Adam realiza la fase inicial y L-BFGS el ajuste final. En este proyecto no se realizó una ablación controlada frente a Adam puro o L-BFGS puro, por lo que no se afirma experimentalmente que la combinación sea superior en todos los criterios.

2.2. Literatura relacionada

El uso de redes neuronales para resolver EDPs fue revitalizado por Raissi et al. (2019), quienes demostraron la capacidad de las PINNs para resolver una amplia gama de problemas físicos

sin necesidad de mallado. El análisis teórico de por qué las PINNs pueden fallar en el entrenamiento fue abordado por Wang et al. (2022) mediante la teoría del núcleo tangente neuronal (NTK), relacionando la dinámica de entrenamiento con el desbalance entre los términos de la función de pérdida y las características espectrales del problema. Desde una perspectiva más empírica, Krishnapriyan et al. (2021) caracterizan sistemáticamente los modos de falla de las PINN con pesos fijos entre los términos de datos y de física, mostrando que el optimizador puede quedar atrapado en mínimos locales de pérdida elevada por un paisaje de optimización mal condicionado, y que ajustar el peso relativo atenúa el error sin resolver el problema — un fenómeno que se retoma en el Capítulo 4 al analizar la ablación del peso de física λ_{fis} .

En el campo de las ecuaciones de onda, Moseley et al. (2020) aplicaron PINNs para resolver la ecuación de onda acústica 2D en modelos de velocidad variables, demostrando la viabilidad del enfoque en dominios inhomogéneos. Para la ecuación de Helmholtz específicamente, Alkhalifah et al. (2021) propusieron un marco de aprendizaje automático para obtener soluciones del campo de onda en sísmica, usando la ecuación de Helmholtz como restricción en la función de pérdida.

En el campo de la óptica y el electromagnetismo, Fang y Zhan (2020) propusieron un enfoque de PINN para el diseño de metamateriales electromagnéticos —encubrimiento, rotadores y concentradores— y, como subproducto, un método para resolver la ecuación de Helmholtz de alta frecuencia; Chen et al. (2020), por su parte, las utilizaron para resolver problemas inversos de dispersión en nanofotónica. Lu et al. (2021) desarrollaron la biblioteca DeepXDE que sistematiza la implementación de PINNs para diversas EDPs.

Un antecedente relevante es el de Schoder y Kraxberger (2024), quienes realizaron un estudio de factibilidad resolviendo la ecuación de Helmholtz mediante PINNs para propagación de ondas acústicas, demostrando la viabilidad de la técnica en entornos complejos: reportaron un error relativo L^2 de 0.0249 (aproximadamente 2.5 %) entre su solución PINN y una malla FEM de referencia fina. Este resultado es indicativo del orden de magnitud de precisión alcanzable con PINNs, aunque no constituye una línea base de comparación directa para la presente investigación: su experimento es en 3D (no 1D/2D), su dominio físico es acústico (no óptico), y su métrica de referencia es una malla FEM (no una solución analítica exacta).

En una línea similar de validación cuantitativa, Zhang et al. (2025) proponen las redes de base radial mejoradas por características (FE-PIRBN) para resolver problemas de dispersión electro-

magnética de alta frecuencia, reportando errores L^2 entre 1.40 % y 5.82 % frente a simulaciones numéricas de referencia. Al igual que con Schoder y Kraxberger (2024), esta comparación se retoma en la Tabla 4.16 del Capítulo 4 como contexto de la literatura, no como línea base directa, dado que difieren en dimensionalidad, dominio físico y tipo de solución de referencia.

El antecedente más cercano en arquitectura a esta investigación es el de Panagiotakopoulos et al. (2026), quienes resuelven la misma ecuación de Helmholtz 2D con campo complejo empleando también una red SIREN y la estrategia de optimización bifásica Adam seguida de L-BFGS. Se diferencia de este trabajo en tres aspectos: no calibran ω_0 respecto al número de onda k ; validan la física del campo resultante de forma cualitativa (propagación, refracción, dispersión) en lugar de reportar un error L^2 cuantitativo contra una solución analítica; y su condición de frontera es una fuente puntual gaussiana con condición de radiación de Sommerfeld, distinta de la frontera de fase aleatoria que da lugar al patrón de *speckle* en esta investigación.

La brecha en el conocimiento identificada es la siguiente: ningún trabajo previo, incluyendo el antecedente arquitectónico más cercano (Panagiotakopoulos et al., 2026), ha aplicado sistemáticamente la arquitectura SIREN (Sitzmann et al., 2020) (con su ventaja intrínseca para representar funciones de alta frecuencia) a la simulación del *speckle* óptico como fenómeno estadístico complejo, validado mediante los criterios de contraste y bondad de ajuste de Goodman (2007). Esta investigación se propone cerrar dicha brecha; los Capítulos 3 y 4 documentan el avance metodológico logrado en la validación 1D/2D del enfoque y el estado en progreso de su aplicación al *speckle* óptico.

2.3. Marco tecnológico

2.3.1. Infraestructura de hardware

El entrenamiento de los modelos PINN-SIREN se realizó sobre la siguiente infraestructura:

- **GPU:** NVIDIA GeForce RTX 5050 (8.5 GB VRAM), con núcleos CUDA para acelerar la diferenciación automática de segundo orden requerida por el cálculo del Laplaciano.
- **CUDA:** Versión 12.8.

- **Memoria RAM:** Gestión del flujo de puntos de colocación y ejecución del optimizador híbrido.

2.3.2. Ecosistema de software

- **Python 3.14:** Lenguaje de implementación principal.
- **PyTorch 2.11:** Framework de *Deep Learning* que proporciona diferenciación automática de segundo orden y soporte GPU mediante CUDA.
- **NumPy / SciPy:** Operaciones numéricas y muestreo LHS (`scipy.stats.qmc.LatinHypercube`).
- **Matplotlib:** Visualización de campos, distribuciones estadísticas y curvas de entrenamiento.
- **Módulos propios:** `src/models.py` (arquitectura SIREN), `src/losses.py` (función de pérdida PINN), `src/utlis.py` (métrica de error L^2 y utilidades de rutas y de guardado).

Capítulo 3

Modelo e implementación

3.1. Formulación del problema

Se consideran dominios adimensionales cuyas coordenadas están normalizadas por la longitud de onda del láser ($\lambda = 638 \text{ nm}$, láser de diodo rojo). Bajo esta normalización, el número de onda $k = 2\pi/\lambda$ definido en el Capítulo 2 toma el valor adimensional $k = 2\pi$; salvo que se indique lo contrario, k se usa en su forma adimensional en el resto de este capítulo.

Para NB01 y NB02 se conserva el dominio adimensional $[0, 1]$ y $[0, 1]^2$, respectivamente, porque esos experimentos validan la arquitectura contra soluciones analíticas. NB03 requiere un dominio de propagación más amplio para representar varios periodos ópticos y separar la pantalla de fase de la región de observación. Por ello se define de forma independiente $\Omega_{03} = [-10, 10] \times [0, 20]$ en coordenadas $(x/\lambda, z/\lambda)$, manteniendo $k = 2\pi$. Ese es el dominio declarado como objetivo; la validación reportada en el Capítulo 4 se realiza sobre el subdominio $[-10, 10] \times [0, 1]$, y la extensión a distancias mayores se documenta con su propio alcance.

Se plantean tres experimentos sucesivos de complejidad creciente:

3.1.1. Experimento 1 (NB01): Validación 1D

La ecuación de Helmholtz unidimensional en $x \in [0, 1]$ con condiciones de Dirichlet:

$$\frac{d^2 E}{dx^2} + k^2 E = 0, \quad E(x_j) = \cos(kx_j), \quad x_j \in \{0, 0.25, 0.5, 0.75, 1\}, \quad (3.1)$$

admite la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$, utilizada para validar la arquitectura y la función de pérdida. Se usan cinco puntos conocidos en la pérdida de datos: los dos extremos $x = 0$ y $x = 1$ y tres puntos interiores de supervisión. La condición simétrica $E(0) = E(1) = 1$ colapsa la red hacia la solución constante trivial durante el entrenamiento, ya que ambos extremos son consistentes con $E \equiv 1$; añadir tres puntos intermedios conocidos de la solución analítica rompe esa simetría y estabiliza la convergencia.

3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo

La ecuación de Helmholtz 2D en $\Omega = [0, 1]^2$ con condición de onda plana diagonal en los cuatro bordes:

$$E_{\text{exacta}}(x, y) = e^{i(k_x x + k_y y)}, \quad k_x = k_y = \frac{k}{\sqrt{2}}, \quad (3.2)$$

que satisface $k_x^2 + k_y^2 = k^2$. La condición de frontera se impone separando la solución en sus partes real e imaginaria:

$$E_{\text{real}}(x, y)|_{\partial\Omega} = \cos(k_x x + k_y y), \quad E_{\text{imag}}(x, y)|_{\partial\Omega} = \sin(k_x x + k_y y). \quad (3.3)$$

3.1.3. Experimento 3 (NB03): Simulación de speckle óptico

La ecuación de Helmholtz 2D en Ω_{03} con una pantalla de fase aleatoria en la entrada $z = 0$. La fase no se genera de forma independiente en cada punto: se obtiene como un proceso gaussiano periódico con longitud de correlación $\ell_\phi = 0.10\lambda$ y desviación estándar 2 rad. Esta correlación evita que la condición de entrada quede dominada por componentes evanescentes no observables en la región de propagación:

$$E(x, 0) = \mathcal{P}_{|k_x| \leq k} \left\{ e^{i\psi(x)} \right\}, \quad \psi(x) = \mathcal{G}_{\ell_\phi}[\xi(x)], \quad \xi(x) \sim \mathcal{N}(0, 1), \quad (3.4)$$

donde $\mathcal{P}_{|k_x| \leq k}$ conserva los modos propagantes del espectro angular. La derivada de entrada se fija mediante la condición saliente:

$$\partial_z E(x, 0) = \mathcal{F}^{-1} \left[i \sqrt{k^2 - k_x^2} \hat{E}(k_x, 0) \right]. \quad (3.5)$$

En x se imponen periodicidad de valor y de derivada.

Reducción modal

La periodicidad transversal permite desarrollar el campo en serie de Fourier de forma exacta,

$$u(\tilde{x}, \tilde{z}) = \sum_m a_m(\tilde{z}) e^{ik_{x,m}\tilde{x}}, \quad k_{x,m} = 2\pi m, \quad (3.6)$$

con lo que la ecuación de Helmholtz 2D se separa en un sistema de ecuaciones diferenciales ordinarias desacopladas,

$$a_m''(\tilde{z}) + (k^2 - k_{x,m}^2) a_m(\tilde{z}) = 0. \quad (3.7)$$

La base se trunca a los 41 modos propagantes ($k_{x,m}^2 < k^2$). Los modos evanescentes se descartan porque su rama creciente $e^{+|\kappa_m|\tilde{z}}$ hace que la solución no dependa de forma continua de los datos; el truncamiento espectral es la regularización de este problema de Cauchy analizada por Nguyen et al. (2016).

Condición de Cauchy dura

En lugar de penalizar la frontera en la función de pérdida, se impone dentro de la arquitectura mediante la función de prueba

$$a_m(\tilde{z}) = a_m(0) + \tilde{z} a_m'(0) + \tilde{z}^2 N_\theta(\tilde{z}), \quad (3.8)$$

donde N_θ es la salida de la red. El término $\tilde{z}^2$ no contribuye ni al valor ni a la primera derivada en $\tilde{z} = 0$, de modo que ambas condiciones se satisfacen exactamente para cualquier valor de los parámetros. Una ecuación de segundo orden con valor y derivada fijados en un punto tiene solución única, por lo que la ecuación (3.8) determina el problema. Esta estrategia de imponer la frontera en la función de prueba corresponde al enfoque de Sukumar y Srivastava (2022).

De aquí se siguen dos diferencias metodológicas con NB01 y NB02. Primero, la pérdida de NB03 contiene únicamente el residuo modal: al no existir término de datos, **no hay peso λ_{fis} que calibrar**. Segundo, cada salida se escala por $s_m = k^2 \max(|a_m(0)|, |a_m'(0)|/k, \epsilon)$, con ϵ un piso

que evita divisiones por cero, de modo que los modos de amplitud pequeña contribuyen al residuo en la misma escala que los dominantes.

La extensión a distancias mayores que 1λ sí emplea una división del dominio longitudinal en bloques, en la que cada bloque recibe el campo y la derivada de la interfaz anterior por la misma construcción de la ecuación (3.8); esa extensión se reporta por separado y con su propio alcance de validación.

3.2. Arquitectura SIREN

Se emplea una arquitectura SIREN con los parámetros consolidados a partir de la validación 1D (NB01) y escalados para el caso 2D (NB02):

- **Entrada:** coordenadas espaciales, $x \in [0, 1]$ en NB01 y $(x, y) \in [0, 1]^2$ en NB02. En NB03 la entrada es la coordenada de propagación $\tilde{z}$ como escalar, porque la dependencia transversal está resuelta de forma exacta por el desarrollo modal.
- **Capas ocultas:** $L = 5$ capas de dimensión d neuronas cada una ($d = 64$ en NB01, $d = 128$ en NB02). NB03 emplea 4 capas de 128.
- **Activación:** $\phi(z) = \sin(\omega_0 z)$, con $\omega_0 = 1.0$ en los tres experimentos, conforme a la regla $\omega_0 \approx k/2\pi$ verificada en NB01 y en el régimen modal de NB03.
- **Salida:** capa lineal de dos neuronas ($E_{\text{real}}, E_{\text{imag}}$) en NB02, una neurona E en NB01, y 82 neuronas en NB03 (41 coeficientes modales complejos).
- **Parámetros totales:** 16,833 (NB01) y 66,690 (NB02).

La elección $\omega_0 = 1.0$ en NB01/NB02 se conserva porque esos casos ya fueron validados en $[0, 1]^2$. En NB03 la entrada de la red es $\tilde{z}$ normalizado y cada coeficiente modal oscila como $a_m(\tilde{z}) \propto e^{ik_{z,m}\tilde{z}}$ con $k_{z,m} \leq k$: a lo sumo una oscilación completa en el dominio, de modo que la misma regla predice $\omega_0 = 1$. Esa predicción se contrastó experimentalmente contra $\omega_0 \in \{5, 15, 30\}$ y el resultado se reporta en el Capítulo 4.

La inicialización sigue el esquema de Sitzmann et al. (2020): $\mathbf{W}_0 \sim \mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa y $\mathbf{W}_\ell \sim \mathcal{U}(-\sqrt{6/d}/\omega_0, \sqrt{6/d}/\omega_0)$ para capas intermedias. El objetivo es controlar la

escala de las activaciones y sus derivadas; no se supone que las activaciones sean uniformes en $[-1, 1]$.

3.3. Función de pérdida y calibración de pesos

La función de pérdida total para el caso 2D es:

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda_{\text{fis}} \left(\mathcal{L}_{R_{\text{real}}} + \mathcal{L}_{R_{\text{imag}}} \right), \quad (3.9)$$

con peso de física $\lambda_{\text{fis}} = 0.1$. Este valor fue calibrado empíricamente mediante un experimento de ablación (véase la Sección 4.3). En esta implementación, la pérdida física suma los residuos real e imaginario; con $\lambda = 1.0$ la corrida no completó el entrenamiento, mientras que $\lambda = 0.01$ produjo un error ligeramente menor pero corresponde a una restricción física de menor peso.

Los residuos de Helmholtz se calculan mediante diferenciación automática de segundo orden (Baydin et al., 2018):

$$R_{\text{real}}(\mathbf{r}) = \nabla^2 E_{\text{real}}(\mathbf{r}) + k^2 E_{\text{real}}(\mathbf{r}), \quad R_{\text{imag}}(\mathbf{r}) = \nabla^2 E_{\text{imag}}(\mathbf{r}) + k^2 E_{\text{imag}}(\mathbf{r}), \quad (3.10)$$

donde el Laplaciano se obtiene con `torch.autograd.grad` activando la opción `create_graph=True` para permitir diferenciación de segundo orden. Es crítico que k^2 se convierta a tipo `float` de Python antes de multiplicar por el tensor de la red, para evitar conflictos de tipo entre `numpy.float64` y `torch.float32`.

En NB03 la función de pérdida es estructuralmente distinta. El valor y la derivada en la interfaz de entrada, y la periodicidad lateral, dejan de ser términos de la pérdida: los tres se satisfacen exactamente por construcción —el desarrollo modal impone la periodicidad y la ecuación (3.8) impone los datos de Cauchy—. La pérdida se reduce al residuo modal normalizado por la escala de cada modo:

$$\mathcal{L}_{03} = \frac{1}{MN} \sum_m \sum_j \left| \frac{a_m''(\tilde{z}_j) + (k^2 - k_{x,m}^2) a_m(\tilde{z}_j)}{s_m} \right|^2, \quad s_m = k^2 \max\left(|a_m(0)|, \frac{|a_m'(0)|}{k}, \epsilon\right). \quad (3.11)$$

No hay, por tanto, ningún peso relativo que calibrar en NB03: el problema de balance entre térmi-

nos que motivó la ablación de λ_{fis} en NB02 desaparece al imponer la frontera dentro de la arquitectura. La condición de derivada saliente no se usa como etiqueta interior: se calcula desde la pantalla radiativa. Así, la referencia angular se reserva para evaluación independiente.

3.4. Estrategia de muestreo

3.4.1. Puntos interiores (colocación)

Para NB02, los $N_c = 3,000$ puntos de colocación interiores se generan mediante LHS (McKay et al., 1979) usando `scipy.stats.qmc.LatinHypercube` con dimensión $n = 2$.

En NB03 el muestreo es de naturaleza distinta, porque la red no recibe la coordenada transversal: la dependencia en $\tilde{x}$ queda resuelta de forma exacta por el desarrollo modal de la ecuación (3.6). En cada época se sortean 256 valores de $\tilde{z}$ con distribución uniforme sobre $[0, 1]$, remuestreados en cada iteración; no se emplea muestreo por hipercubo latino en este experimento. La evaluación del campo se realiza sobre la malla transversal de la referencia angular, y la del residuo sobre una malla propia de 1,001 valores de $\tilde{z}$, independiente del muestreo de entrenamiento.

3.4.2. Puntos de frontera

En NB01, la condición de Dirichlet se impone en los cinco puntos conocidos descritos en la Sección 3 ($x = 0, 0.25, 0.5, 0.75, 1$). En NB02, los $N_b = 300$ puntos de frontera por borde se distribuyen uniformemente sobre cada uno de los cuatro lados del dominio $\partial\Omega$ (1,200 puntos en total). Para cada lado, se evalúa la solución exacta y se construye el par $(\mathbf{r}_j^b, E(\mathbf{r}_j^b))$ utilizado en $\mathcal{L}_{\text{datos}}$. En NB03, en cambio, ninguna condición de frontera se impone mediante puntos de muestreo: las tres se satisfacen por construcción. La periodicidad lateral está contenida en el desarrollo de Fourier de la ecuación (3.6); el valor y la derivada saliente en la interfaz de entrada quedan fijados exactamente por la función de prueba de la ecuación (3.8), con independencia de los parámetros de la red. No hay, por tanto, ni bordes libres sin condición física ni término de frontera en la pérdida.

3.5. Estrategia de optimización

El entrenamiento de NB01 y NB02 sigue la estrategia bifásica descrita en el Capítulo 2, con los hiperparámetros consolidados en la Tabla 3.1.

Tabla 3.1. Hiperparámetros de entrenamiento consolidados.

Hiperparámetro	Valor	Aplicación
Tasa de aprendizaje Adam (η)	10^{-3}	NB01, NB02
Épocas máximas Adam	15,000	NB01, NB02
Paciencia (<i>early stopping</i>)	800 épocas	NB02
δ mejora mínima	10^{-7}	NB02
Iteraciones máximas L-BFGS	500 (NB01), 1,000 (NB02)	-
Historial L-BFGS	50 (NB01), 100 (NB02)	-
Semilla global (SEED)	42	NB01, NB02
Peso de física λ_{fis}	1.0 (NB01), 0.1 (NB02)	-

Todos los experimentos se ejecutaron en GPU NVIDIA RTX 5050. La semilla favorece la reproducibilidad bajo las mismas condiciones de ejecución. NB01 usa $\lambda_{\text{fis}} = 1.0$ porque un único residuo no duplica el peso de la física, a diferencia del caso 2D (real + imaginario); ver Sección 4.3.

3.6. Métricas de validación

3.6.1. Métricas de NB03: campo complejo y estadística de speckle

Para NB03 se evalúan tres familias de métricas contra la referencia por espectro angular, que no se utiliza en ningún momento del entrenamiento:

- **Error de campo.** Error L^2 relativo complejo $\varepsilon_{L^2} = \|E_{\text{PINN}} - E_{\text{AS}}\|_2 / \|E_{\text{AS}}\|_2$ y coherencia compleja $\gamma = |\langle E_{\text{AS}}, E_{\text{PINN}} \rangle| / (\|E_{\text{AS}}\|_2 \|E_{\text{PINN}}\|_2)$. Puesto que la base modal contiene sólo los modos propagantes, el error se descompone de forma exacta como $\varepsilon_{L^2}^2 = \varepsilon_{\text{prop}}^2 + \varepsilon_{\text{evan}}^2$, donde $\varepsilon_{\text{evan}}$ es la fracción evanescente de la referencia –irrepresentable por construcción– y $\varepsilon_{\text{prop}}$ el error sobre el subespacio que el modelo sí puede expresar. Ambos se reportan.
- **Residuo físico.** RMSE del residuo de la ecuación (3.7), normalizado por la escala modal s_m y evaluado en una malla fija de $\tilde{z}$ independiente del muestreo de entrenamiento.
- **Estadística de speckle.** Contraste $C = \sigma_I / \langle I \rangle$, evaluado en dos niveles: sobre el conjunto de realizaciones frente al contraste unitario que Goodman (2007) establece para el *speckle*

completamente desarrollado, con la tolerancia operativa $|C - 1| < 0.1$ adoptada en este trabajo; y sobre cada realización individual como fidelidad al contraste de su propia referencia, $|C_{\text{PINN}} - C_{\text{ref}}| < 0.05$. El test de Kolmogorov–Smirnov contra la exponencial y la fracción de píxeles con $I > 2\langle I \rangle$ (valor teórico e^{-2}) se reportan como estadísticos descriptivos; el primero supone muestras independientes, hipótesis que un corte espacial de *speckle* no satisface por la correlación dentro de cada grano.

3.6.2. Error L^2 relativo (NB01 y NB02)

El error L^2 relativo mide la discrepancia global entre la predicción de la red $\hat{E}$ y la solución exacta E_{exacta} . Se evalúa sobre una malla uniforme de 1,000 puntos en $[0, 1]$ para NB01 y de 100×100 puntos en $[0, 1]^2$ para NB02. Para NB01, que tiene salida escalar, se utiliza

$$\varepsilon_{L^2} = \frac{\|\hat{E} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2} \times 100 \%. \quad (3.12)$$

En NB02, el código calcula esta cantidad por separado para las componentes real e imaginaria y reporta su promedio aritmético:

$$\begin{aligned} \varepsilon_{L^2}^{(c)} &= \frac{\|\hat{E}_c - E_{c,\text{exacta}}\|_2}{\|E_{c,\text{exacta}}\|_2} \times 100 \%, \quad c \in \{\text{real}, \text{imag}\}, \\ \bar{\varepsilon}_{L^2} &= \frac{\varepsilon_{L^2}^{(\text{real})} + \varepsilon_{L^2}^{(\text{imag})}}{2}. \end{aligned} \quad (3.13)$$

Por tanto, 0.171 % es un promedio componente a componente y no la norma relativa de un vector complejo concatenado.

Para esta validación no se adopta un criterio universal de tolerancia de error; se fijó $\varepsilon_{L^2} < 5 \%$ como umbral ingenieril propio de la tesis. Este valor resulta, además, considerablemente menor que el orden de magnitud reportado en implementaciones comparables de PINNs para la ecuación de Helmholtz identificadas posteriormente (Tabla 4.16).

3.7. Implementación modular

El código fuente está organizado en módulos reutilizables en `src/`:

`models.py` Clases `PINN_1D_SIREN` y `PINN_2D_SIREN`, que implementan la arquitectura SIREN con la inicialización de Sitzmann et al. (2020). El método `forward(x)` aplica la activación sinusoidal capa por capa y retorna el campo complejo como un tensor de dos columnas $(E_{\text{real}}, E_{\text{imag}})$.

`losses.py` Función `pinn_loss_2d(model, xy_colloc, xy_bc, E_bc, k, lambda_phys)` que calcula la pérdida total (3.9). El cálculo del Laplaciano utiliza `torch.autograd.grad` con `create_graph=True` para habilitar la diferenciación de segundo orden. El escalar k se convierte explícitamente a `float(k)` antes de multiplicar por el tensor de la red, evitando conflictos de `dtype` entre `numpy.float64` y `torch.float32`.

`training.py` Loop de entrenamiento que integra las fases Adam y L-BFGS con *early stopping*.

`utils.py` Métrica de error L^2 relativo y utilidades de rutas y de guardado de modelos. Las métricas R^2 , RMSE y MAE se calculan en los propios notebooks, y el muestreo por hipercubo latino se invoca directamente desde `scipy.stats.qmc`. El módulo no incluye rutinas de visualización: las figuras se generan en los notebooks.

Los experimentos están reproducidos en los notebooks `01_validacion_helmholtz_1d_normalizada.ipynb`, `02_validacion_helmholtz_2d_normalizada.ipynb` y `03_simulacion_speckle_2d_pinn_siren_modal.ipynb`. Los resultados numéricos están archivados en formato JSON en `results/`.

Capítulo 4

Experimentos y Resultados

Este capítulo presenta los resultados de tres experimentos, ejecutados en GPU NVIDIA RTX 5050 (CUDA 12.8, PyTorch 2.11, SEED = 42). Siguen una complejidad creciente: validación analítica 1D (NB01), validación 2D con campo complejo (NB02) y simulación de *speckle* óptico mediante una formulación modal (NB03), validada en $\tilde{z} = 1\lambda$ sobre cinco realizaciones de fase independientes.

4.1. NB01: Validación 1D, Helmholtz con solución analítica

4.1.1. Configuración experimental

El primer experimento valida la arquitectura SIREN frente a la solución analítica exacta de la ecuación de Helmholtz 1D. Se empleó la arquitectura SIREN 5×64 (16,833 parámetros) con los hiperparámetros de la Tabla 3.1. Los puntos de colocación son $N_c = 2,000$ puntos uniformes en $[0, 1]$. Las condiciones de frontera Dirichlet físicas se imponen en los extremos $x = 0$ y $x = 1$; adicionalmente, se incorporan tres puntos interiores de supervisión de la solución analítica ($x = 0.25, 0.5, 0.75$). Estos cinco puntos conocidos evitan el colapso hacia la solución constante que produce la condición simétrica $E(0) = E(1) = 1$.

4.1.2. Resultados de precisión

La Tabla 4.1 presenta las métricas de precisión obtenidas tras el entrenamiento completo Adam (15,000 épocas) seguido de L-BFGS (202 evaluaciones de la función objetivo), con un

tiempo total de 131.1 segundos.

4.1.3. Análisis y comparativa con el estado del arte

El error $L^2 = 0.006\%$ se mantiene por debajo del umbral de la tesis ($< 5\%$) por casi tres órdenes de magnitud. Este resultado es consistente con la motivación de la activación sinusoidal para representar funciones oscilatorias (Sitzmann et al., 2020); este trabajo no contrasta SIREN frente a activaciones alternativas, de modo que la ventaja no se cuantifica aquí. La red aprende la solución $\cos(kx)$ de forma casi exacta, con $R^2 = 1.000000$ y correlación de Pearson = 1.000000 en toda la malla de evaluación.

La Figura 4.1 muestra la comparación entre la predicción de la red y la solución analítica, así como la distribución del error puntual.




Figura 4.1. Validación PINN-SIREN para Helmholtz 1D. Panel A: comparación entre la predicción de la red y la solución analítica $E_{exacta}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel B: error puntual $|\hat{E}(x) - E_{exacta}(x)|$. Panel C: curva de pérdida total durante las fases Adam y L-BFGS; la transición a la época 15,000 es visible como una caída abrupta. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.

La Figura 4.2 complementa este resultado con la distribución del error y las métricas de ajuste adicionales.

Tabla 4.1. Métricas de precisión: PINN-SIREN 1D ($k = 2\pi$).

Métrica	Valor
Error L^2 relativo (%)	0.006
MSE	1.5×10^{-9}
RMSE	3.9×10^{-5}
MAE	3.50×10^{-5}
Error máximo	5.77×10^{-5}
R^2	1.000000
Correlación de Pearson	1.000000
Residuo de Helmholtz, RMS	3.63×10^{-3}
Residuo de Helmholtz, máximo	1.48×10^{-2}
Residuo relativo	1.30×10^{-4}
Épocas Adam	15,000 / 15,000
Evaluaciones L-BFGS	202 / 500
Tiempo total (s)	131.1

Evaluado en malla uniforme de 1,000 puntos en $[0, 1]$. Arquitectura SIREN: 5 capas $\times$ 64 neuronas, $\omega_0 = 1.0$. Solución analítica: $E_{\text{exacta}}(x) = \cos(kx)$. GPU: NVIDIA RTX 5050, SEED = 42, laptop conectada a corriente y sin procesos concurrentes. “Evaluaciones L-BFGS” cuenta las llamadas a la función de pérdida durante la búsqueda de línea *strong Wolfe*, no iteraciones del optimizador. En una corrida previa sin estas condiciones el tiempo total fue 504.2 s: el mismo hardware, ejecutando en régimen térmico degradado (frecuencia de reloj de GPU reducida por carga sostenida), reprodujo idénticamente L^2 , R^2 y el resto de métricas de precisión, pero a 8.75 ms/época en el primer tramo y 60.4 ms/época tras la época $\sim 8,700$. El tiempo de entrenamiento en hardware portátil depende por tanto de las condiciones térmicas de la sesión y no debe interpretarse como una cifra de rendimiento del algoritmo. Una tercera ejecución, al reejecutar el notebook completo de forma concurrente con otro entrenamiento en la misma GPU, arrojó 357.5 s y volvió a reproducir de forma idéntica L^2 , MSE, RMSE, MAE, error máximo, R^2 , correlación, número de épocas, evaluaciones L-BFGS y mejor pérdida de Adam (4.847×10^{-4}). Las métricas de precisión son por tanto estables frente a las condiciones de ejecución; sólo el tiempo varía.




Figura 4.2. Métricas adicionales de entrenamiento NB01. Panel A: distribución del error absoluto $|\hat{E}(x) - E_{\text{exacta}}(x)|$. Panel B: error relativo puntual (%). Panel C: dispersión de la predicción PINN contra la solución exacta, con la línea $y = x$ como referencia de ajuste perfecto.

4.1.4. Barrido de ω_0 : evidencia cuantitativa del sesgo espectral

La regla de calibración $\omega_0 \approx k/(2\pi)$ (Tabla 3.1) se documentó originalmente a partir de un único caso puntual: $\omega_0 = 30$ —el valor que Sitzmann et al. (2020) reportan como adecuado para *todas* las aplicaciones de su trabajo, incluida la resolución de la propia ecuación de Helmholtz— desestabiliza el entrenamiento con $k \approx 2\pi$. Para verificar esta regla más allá de un solo punto, se entrenó el mismo problema de NB01 con $\omega_0 \in \{1.0, 5.0, 15.0, 30.0\}$ durante 3,000 épocas Adam idénticas (sin L-BFGS), manteniendo $k = 2\pi$ fijo.

Tabla 4.2. Barrido de ω_0 sobre el problema de NB01 (3,000 épocas Adam).

ω_0	Pérdida total final	Observación
1.0	0.2656	Calibrado ($\omega_0 = k/2\pi$)
5.0	0.5355	Descalibrado
15.0	0.4375	Descalibrado
30.0	0.6030	Descalibrado (valor propuesto por Sitzmann et al. (2020))

Corridas nuevas y cortas, independientes del entrenamiento final de NB01 (15,000 épocas + L-BFGS, Tabla 4.1); no modifican ni reemplazan esos resultados. Mismo $N_c = 2,000$, $\lambda_{\text{fis}} = 1.0$ y puntos de frontera que NB01. Ninguna corrida diverge (pérdida infinita o NaN) dentro de las 3,000 épocas: la desestabilización numérica documentada para $\omega_0 = 30$ en el entrenamiento completo de 15,000 épocas no se reproduce como divergencia literal en este barrido corto, pero sí se observa la tendencia esperada de peor convergencia a mayor descalibración.

El valor calibrado $\omega_0 = 1.0$ converge a una pérdida menor que $\omega_0 = 15$ y $\omega_0 = 30$ en la misma cantidad de épocas. La comparación con $\omega_0 = 5$ no es concluyente: una repetición independiente del mismo barrido, ejecutada en CPU en lugar de GPU (`results/diagnostics/nb01-omega0-sweep.json`), invierte el orden entre 1 y 5. Lo que ambas corridas sí establecen de forma consistente es la de-

gradación para $\omega_0 \geq 15$; el barrido de la formulación modal (Tabla 4.11) muestra el mismo patrón, con 1 y 5 próximos entre sí y separados por más de un orden de magnitud de los valores altos. Este resultado es consistente con el sesgo espectral descrito por Rahaman et al. (2019): la activación sinusoidal de SIREN impone un espectro de frecuencias nativo determinado por ω_0 , y cuando este no coincide con la frecuencia k de la solución objetivo, la red debe aprender a compensar ese desajuste espectral antes de ajustar la solución misma, retrasando o degradando la convergencia.

4.2. NB02: Validación 2D, Helmholtz con campo complejo

4.2.1. Configuración experimental

El segundo experimento escala el modelo al caso bidimensional con campo complejo. Se empleó la arquitectura SIREN 5×128 (66,690 parámetros), LHS con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por borde. El peso de física $\lambda_{\text{fis}} = 0.1$ fue seleccionado mediante el experimento de ablación descrito en la Sección 4.3.

4.2.2. Resultados de precisión

La Tabla 4.3 reporta las métricas detalladas para cada componente del campo complejo, evaluadas en una malla uniforme de 100×100 puntos.

4.2.3. Análisis de resultados

El error L^2 promedio de 0.171 % se mantiene por debajo del umbral de la tesis ($< 5\%$) por más de un orden de magnitud. La precisión se mantiene alta en ambas componentes del campo complejo, con $R^2 > 0.9999$ para E_{real} y E_{imag} .

En un experimento preliminar con $d = 64$ (mismo N_c , N_b y protocolo de optimización que la Tabla 3.1) el error promedio fue 0.436 %, frente a 0.171 % con $d = 128$. Esta comparación involucra además una diferencia en el número de evaluaciones de L-BFGS entre ambas corridas, por lo que la mejora de $2.5\times$ no puede atribuirse de forma aislada al aumento de capacidad de la red; se reporta como evidencia cualitativa de que $d = 128$ es preferible, no como una ablación

Tabla 4.3. Métricas de precisión: PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$).

Métrica	E_{real}	E_{imag}
Error L^2 componente (%)	0.214	0.127
MSE	2.20×10^{-6}	8.43×10^{-7}
RMSE	1.48×10^{-3}	9.18×10^{-4}
MAE	1.27×10^{-3}	7.71×10^{-4}
Error máximo	3.05×10^{-3}	2.93×10^{-3}
R^2	0.999995	0.999998
Correlación de Pearson	0.999998	0.999999
Promedio aritmético de errores L^2 (%)	0.171	
Error L^2 del campo complejo (%)	0.174	
Error L^2 de intensidad (%)	0.248	
RMSE de fase circular (rad)	1.23×10^{-3}	
Residuo de Helmholtz, RMS relativo	1.96×10^{-4}	

Evaluado en malla uniforme de 100×100 puntos. Arquitectura: SIREN 5×128 , $\omega_0 = 1.0$, 66,690 parámetros. Puntos de colocación: LHS $N_c = 3,000$. Frontera: onda plana $e^{i(k_x x + k_y y)}$ en 4 bordes, $N_b = 300$ pts/borde. Entrenamiento: Adam (8,737 épocas) + L-BFGS (1,035 evaluaciones de la función objetivo), tiempo total 209.9 s (GPU RTX 5050 laptop, conectada a corriente, sin procesos concurrentes). Dispersión entre semillas (SEED $\in \{42, 123, 777\}$): error L^2 promedio = 0.192 ± 0.089 % (media $\pm$ desviación estándar poblacional, ddof = 0).

controlada. No se dispone de un experimento que aísle la contribución específica del Muestreo Latino Hipercúbico frente a una malla cartesiana equivalente.

La Figura 4.3 muestra los mapas de calor de la solución exacta y la predicción PINN-SIREN para ambas componentes del campo.

La Figura 4.4 complementa este resultado con la distribución espacial del error puntual para ambas componentes del campo.

4.2.4. Reproducibilidad multi-semilla

Para evaluar la robustez estadística del método, el experimento NB02 se repitió con tres semillas diferentes: SEED $\in \{42, 123, 777\}$. Los resultados se presentan en la Tabla 4.4.

La desviación estándar inter-semilla de ± 0.089 % representa un coeficiente de variación del 46 % respecto a la media, considerable en términos relativos, pero las tres semillas se mantienen entre 16 y 53 veces por debajo del umbral de la tesis (< 5 %): la inicialización aleatoria afecta la precisión final de forma apreciable, sin comprometer el cumplimiento de la hipótesis (i) en ninguno




Figura 4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior (A1-A3): solución analítica, predicción PINN-SIREN y error absoluto para E_{real} . Fila central (B1-B3): lo mismo para E_{imag} . Fila inferior: intensidad predicha $I = |E|^2$ (C1), puntos de colocación LHS (C2) y curvas de pérdida durante Adam y L-BFGS (C3). La diferencia visual entre solución exacta y predicción es muy pequeña a esta escala; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.3). Malla de evaluación 100×100 , SEED = 42.

Tabla 4.4. Reproducibilidad multi-semilla: NB02 ($\lambda_{\text{fis}} = 0.1$).

SEED	Error L^2 prom. (%)	Épocas Adam	Tiempo (s)
42	0.1707	8,737	220.7
123	0.0949	9,441	225.9
777	0.3100	10,443	253.2
Media $\pm$ Desv. est.	0.192 ± 0.089	-	-

Misma arquitectura, hiperparámetros y protocolo de entrenamiento (scripts/experiments/run_multiseed.py), ejecutadas en la misma sesión para que los tiempos sean comparables entre sí. GPU: NVIDIA RTX 5050, laptop conectada a corriente. La semilla 42 reproduce el resultado de NB02 ($L^2 = 0.1707\%$ vs. 0.171% , dentro del redondeo).




Figura 4.4. Métricas adicionales de entrenamiento NB02. Paneles A-B: distribución del error absoluto $|E_{\text{real}} - \hat{E}_{\text{real}}|$ y $|E_{\text{imag}} - \hat{E}_{\text{imag}}|$. Paneles C, F: dispersión de la predicción PINN contra la solución exacta para cada componente. Paneles D-E: error relativo puntual (%) en la malla 100×100 ; los valores más altos se concentran en bandas antidiagonales ($x + y \approx \text{const.}$) donde la solución exacta cruza por cero, ya que el error relativo diverge al dividir por un valor cercano a cero, y no en las esquinas del dominio. La curva de pérdida de entrenamiento se muestra en el Panel C3 de la Figura 4.3.

de los tres casos.

4.2.5. Ablación de profundidad: 4 frente a 5 capas

La profundidad de 5 capas ocultas se heredó de NB01 sin contrastarla. Para verificar que no es una elección arbitraria se repitieron ambos experimentos con 4 capas, manteniendo el resto del protocolo idéntico.

Tabla 4.5. Ablación de profundidad en NB01 y NB02.

Experimento	Capas	Parámetros	Error L^2 (%)
NB01 (1D)	4	12,673	0.0133
NB01 (1D)	5	16,833	0.006
NB02 (2D)	4	50,178	0.2279
NB02 (2D)	5	66,690	0.171

Mismo ω_0 , semilla, muestreo, λ_{fis} y presupuesto de épocas que las corridas de referencia. La configuración de 5 capas obtiene menor error en ambos casos, con un incremento de parámetros del 33 % en 1D y del 33 % en 2D. La diferencia es de un factor 2.2 en 1D y 1.3 en 2D, ambas muy por debajo del umbral del 5 %. La comparación se realizó con una sola semilla: en 2D la diferencia (0.057 puntos porcentuales) es menor que la dispersión inter-semilla medida para configuración idéntica en la Tabla 4.4 (± 0.089 pp), por lo que el contraste no distingue ambas profundidades. Se reporta como verificación de que 4 capas tampoco comprometen el umbral, no como justificación de la elección. Fuente: [explorations/architecture_ablation_4layers/output/](#).

4.3. Ablación del peso de física λ_{fis}

Para calibrar el balance entre el término de datos y el término físico en la función de pérdida (3.9), se realizó un experimento de ablación con $\lambda_{\text{fis}} \in \{0.01, 0.1, 1.0\}$, manteniendo fija la arquitectura SIREN 5×128 y SEED = 42. Los resultados se presentan en la Tabla 4.6.

El valor $\lambda_{\text{fis}} = 0.1$ se seleccionó por la estabilidad numérica observada, no por precisión: el modelo con $\lambda = 0.01$ registra 0.163 % frente a 0.171 %, diferencia de 0.008 puntos porcentuales que es un orden de magnitud menor que la dispersión inter-semilla (Tabla 4.4) y que además procede de una corrida con distinto presupuesto de L-BFGS, por lo que no distingue ambas

Tabla 4.6. Ablación del peso de física λ_{fis} : NB02.

λ_{fis}	Error L^2 prom. (%)	Convergencia	Observación
0.01	0.163	Sí	Física subponderada
0.1	0.171	Sí	Configuración seleccionada
1.0	—	No (<i>crash</i>)	Física sobreponderada

Arquitectura SIREN 5×128 , $\omega_0 = 1.0$, SEED = 42. Las tres filas no proceden de una misma corrida por lotes: $\lambda = 0.1$ es el resultado de NB02; $\lambda = 0.01$ procede de una corrida previa con 6,575 épocas Adam y 320 evaluaciones de L-BFGS, frente a 8,737 y 1,035 de NB02; y sólo $\lambda = 1.0$ se ejecutó con `run_ablation_lambda.py`, que además no restaura el mejor estado tras el *early stopping*. La comparación es por tanto indicativa del comportamiento cualitativo, no una ablación bajo protocolo homogéneo. El caso $\lambda = 1.0$ no produjo un valor de L^2 : la corrida se interrumpió por una excepción de CUDA antes de completar el entrenamiento. El registro de la corrida asocia el fallo con el crecimiento del gradiente en `float32`; como no se guardó una medición independiente de su magnitud, se reporta como diagnóstico de la falla y no como una relación causal demostrada. No es un caso de no convergencia por agotar épocas, sino una interrupción numérica (`results/ablation_lambda.json`).

configuraciones en precisión. $\lambda = 1.0$ se interrumpió antes de completar el entrenamiento. Entre las dos configuraciones que sí convergen, $\lambda = 0.1$ se prefiere porque impone una restricción física más fuerte sin un costo de precisión relevante frente al umbral de la tesis.

Esta fragilidad frente al peso relativo de los términos de pérdida no es un fenómeno aislado de esta implementación: Krishnapriyan et al. (2021) documentan sistemáticamente que las PINN con pesos fijos entre el término de datos/condición inicial y el término de residuo físico pueden fallar en converger a la solución correcta, quedando el optimizador atrapado en mínimos locales de pérdida elevada, y atribuyen el problema a un paisaje de optimización mal condicionado por la competencia entre ambos términos. Wang et al. (2021) describen un mecanismo relacionado: los gradientes del término físico pueden dominar en magnitud a los del término de datos durante el entrenamiento, generando un flujo de gradiente patológico que dificulta la convergencia. La inestabilidad observada con $\lambda = 1.0$ en este trabajo es consistente con ambas caracterizaciones: los dos residuos (real e imaginario) duplican el peso efectivo de la contribución del término físico, un posible factor del mismo tipo de desbalance; esta interpretación no se aisló experimentalmente en la corrida de ablación.

4.3.1. Diagnóstico espectral: análisis del núcleo tangente neuronal (NTK)

La teoría del núcleo tangente neuronal (*Neural Tangent Kernel*, NTK) de Wang et al. (2022) permite cuantificar directamente el desbalance descrito arriba: cada término de la función de pérdida induce su propio kernel NTK, y la magnitud relativa de sus autovalores predice qué término domina el gradiente durante el entrenamiento. Sobre el modelo final de NB02 ya entrenado ($\lambda_{\text{fis}} = 0.1$), se calculó el NTK empírico del término de datos (frontera, 80 puntos) y del término de física (residuo de Helmholtz, 80 puntos de colocación LHS).

Tabla 4.7. Espectro NTK: término de datos vs. término de física (NB02).

	Traza NTK	Autovalor máximo
Datos (frontera)	1.45×10^4	5.29×10^3
Física (residuo Helmholtz)	1.24×10^7	8.49×10^6
Razón física / datos	858×	1,605×

Calculado sobre los pesos finales guardados de NB02 (results/models/nb02_helmholtz2d_gpu.pt), sin reentrenar ni modificar los resultados de la Tabla 4.3. NTK aproximado con 80 puntos por término (Jacobiano de E_{real} para datos, del residuo real de Helmholtz para física, respecto a los 66,690 parámetros del modelo).

El espectro NTK del término de física es entre 858 y 1,605 veces mayor que el del término de datos, magnitud consistente con que $\lambda_{\text{fis}} = 1.0$ (peso igual entre ambos términos) deje al gradiente de la física dominando el paso de optimización, y con la inestabilidad numérica reportada arriba. La medición se realizó sobre los pesos finales del modelo entrenado con $\lambda_{\text{fis}} = 0.1$, no sobre la corrida que falló, de modo que ofrece una magnitud plausible del desbalance y no una observación directa de su dinámica. Esta razón no debe interpretarse como que $\lambda_{\text{fis}} = 0.1$ sea el valor que compensa exactamente el desbalance (una compensación literal sugeriría un factor de reescalamiento considerablemente menor); el análisis NTK aquí presentado explica la *dirección y el orden de magnitud* del desbalance identificado empíricamente en la ablación, no deriva analíticamente el valor óptimo de λ_{fis} .

4.4. NB03: Simulación de speckle óptico

4.4.1. Diagnóstico del planteamiento: por qué la formulación directa no extiende

La extensión directa de la arquitectura de NB02 al problema de *speckle* —una red que recibe $(\tilde{x}, \tilde{z})$ y devuelve el campo complejo, con la pantalla de fase impuesta como término de datos— no converge, y la causa no es la capacidad de la red. En la prueba de control correspondiente, el campo aprendido reproduce la condición de frontera con un error máximo de 9×10^{-8} y alcanza un residuo de Helmholtz varios órdenes de magnitud menor que el de cualquier corrida aceptada, y aun así difiere de la referencia en un 92.75 %. Las tres observaciones son simultáneamente ciertas porque el problema, tal como estaba planteado, no tiene solución única: con datos impuestos únicamente en la cara de entrada y sin condición de radiación, si E es solución también lo es E más cualquier campo que se anule en esa frontera.

El problema pertenece por tanto a la clase de Cauchy para un operador elíptico, mal planteada en el sentido de Hadamard. Descomponiendo en modos transversales, la ecuación para cada coeficiente es

$$a_m''(\tilde{z}) + (k^2 - k_{x,m}^2) a_m(\tilde{z}) = 0, \quad (4.1)$$

cuyas soluciones son oscilatorias y acotadas cuando $k_{x,m}^2 < k^2$ (modos propagantes) pero exponenciales $e^{\pm|\kappa_m|\tilde{z}}$ cuando $k_{x,m}^2 > k^2$ (modos evanescentes). La rama creciente amplifica cualquier error de los datos, de modo que la dependencia continua se pierde en el subespacio evanescente.

4.4.2. Experimento puente: aislamiento del planteamiento

Para separar el efecto del planteamiento del efecto del método se construyó un experimento con solución analítica conocida, en el que la geometría, la solución exacta, la arquitectura (5×128 , $\omega_0 = \sqrt{q}$) y la semilla se mantienen fijos y sólo cambia la condición de frontera. El campo de prueba es

$$E(\tilde{x}, \tilde{y}) = \sum_{n=-1}^1 c_n e^{i(2\pi n \tilde{x} + 2\pi \sqrt{q-n^2} \tilde{y})}, \quad q = 1.625, \quad (4.2)$$

que satisface Helmholtz de forma exacta con $k = 2\pi\sqrt{q}$, es periódico en $\tilde{x}$ sobre $[0, 1]$ y tiene sus tres modos propagantes. El valor $k^2 = 6.5\pi^2$ se eligió de modo que no coincida con ningún

autovalor del laplaciano de Dirichlet en $[0, 1]^2$ —que son $\pi^2(m^2 + n^2)$ con m, n enteros positivos—, condición necesaria para que el caso de control tenga solución única.

Tabla 4.8. Experimento puente: misma solución analítica, tres planteamientos.

Caso	Datos y formulación	L^2 global	E_{evan} en $\tilde{y} = 1$
A	Dirichlet en los 4 lados, formulación directa	0.077 %	$1 \times 10^{-5} \%$
B	Cauchy en $\tilde{y} = 0$, formulación directa	45.14 %	7.39 %
C	Cauchy idéntico a B, formulación modal	0.155 %	0 %

Los casos B y C reciben exactamente la misma información: valor y derivada normal del campo exacto en $\tilde{y} = 0$. E_{evan} es la fracción de energía de la predicción que cae fuera del cono propagante $|k_x| \leq k$; la solución física tiene cero por construcción. En el caso B esa fracción crece de $4 \times 10^{-4} \%$ en $\tilde{y} = 0$ a un máximo de 13.2 %, y el error local pasa de 0.209 % a 73.7 %: el ajuste de los datos es correcto y la degradación ocurre al propagar. Fuente: [explorations/nb02b_bien_vs_mal_puesto/](#).

Con información idéntica, la formulación modal es unos dos órdenes de magnitud más precisa que la directa. La diferencia no procede de los datos disponibles: los casos B y C reciben exactamente el mismo valor y la misma derivada en la frontera. Procede de la formulación completa —base modal truncada al cono propagante, imposición dura de la condición de Cauchy y ausencia de término de datos—, que además emplea 4 capas y otro presupuesto de optimización. El diseño aísla el planteamiento del problema (contraste A frente a B), pero no separa la contribución del truncamiento espectral de la de la imposición dura (contraste B frente a C).

4.4.3. Validación de la arquitectura modal contra solución exacta

El experimento anterior aísla el planteamiento del problema, pero lo hace con una red distinta de la que se emplea en NB03. Queda por comprobar que la arquitectura concreta que se usará —con su condición de Cauchy dura, su base truncada y su ausencia de término de datos— reproduce una solución conocida antes de exponerla a una pantalla aleatoria, donde ya no hay solución exacta contra la cual medir.

La prueba importa la clase `ModalSiren` de NB03 sin modificarla y sustituye la pantalla de fase por una superposición de ondas planas

$$E(\tilde{x}, \tilde{z}) = \sum_m A_m e^{i(k_{x,m}\tilde{x} + k_{z,m}\tilde{z})}, \quad k_{z,m} = \sqrt{k^2 - k_{x,m}^2}, \quad (4.3)$$

que satisface Helmholtz de forma exacta sobre el mismo dominio de NB03, $[-10, 10] \times [0, 1]$ en $(\tilde{x}, \tilde{z})$ con $k = 2\pi$. La condición de Cauchy dura impone $a'_m(0) = i k_{z,m} a_m(0)$, que es la condición de onda saliente, de modo que la solución de referencia contiene únicamente propagación hacia $+\tilde{z}$. No se emplean etiquetas interiores: la solución analítica se reserva por completo para la evaluación posterior. Se recorren tres tamaños de base –1, 5 y 41 modos– para comprobar que el comportamiento no depende de haber ajustado la red a un número concreto de salidas.

Tabla 4.9. Arquitectura modal de NB03 frente a una solución analítica exacta.

Modos	L^2 global	L^2 en $\tilde{z} = 1\lambda$	Residuo de Helmholtz	Cauchy: $a'_m(0)$
1	0.0149 %	0.0030 %	1.74×10^{-3}	1.7×10^{-7}
5	0.0112 %	0.0070 %	1.55×10^{-3}	6.7×10^{-8}
41	0.0078 %	0.0073 %	1.32×10^{-3}	2.5×10^{-8}

Protocolo idéntico en los tres casos: 2,500 épocas de Adam con $\text{lr} = 2 \times 10^{-4}$, 6,000 de Adam con $\text{lr} = 5 \times 10^{-5}$ y 80 pasos de L-BFGS *strong Wolfe* con colocación fija, 8,580 en total. Arquitectura y ω_0 los de NB03 (§4.4.4); semilla 2,026. El residuo está normalizado por k^2 . La última columna es el RMSE del error en la derivada impuesta en $\tilde{z} = 0$; el error en el valor $a_m(0)$ es nulo o del orden de 10^{-9} , porque la condición se impone por construcción y no por penalización. La coherencia compleja en $\tilde{z} = 1\lambda$ es 1.000000 en los tres casos. Fuente: `results/nb02b_modal_bridge/summary.json`, generado por `notebooks/02b_validacion_puente_arquitectura_modal_nb03.ipynb`.

Los tres casos superan los criterios por más de dos órdenes de magnitud, y el error *disminuye* al ampliar la base, de 0.0149 % con un modo a 0.0078 % con 41. Esto último es lo que se espera de una representación que converge: añadir modos añade capacidad sin degradar el ajuste. Conviene subrayar qué se mide aquí y qué no. Estas cifras no son comparables con el 3.161 % de la Sección 4.4.7: allí el L^2 total está dominado por el piso evanescente de la pantalla aleatoria, que la base modal no puede representar por construcción, mientras que el campo de la Ecuación (4.3) es propagante puro y carece de ese piso. Lo que este experimento acota es el error atribuible a la arquitectura y a su optimización, aislado de la física del problema de Cauchy: es del orden de 10^{-4} , dos órdenes de magnitud por debajo del error propagante medido sobre speckle (0.042 %).

La prueba aporta además una tercera verificación de la regla de calibración $\omega_0 \approx k/2\pi$, ahora contra solución exacta. Una ejecución preliminar de este mismo experimento con $\omega_0 = 30$ –el valor por defecto que Sitzmann et al. (2020) proponen– obtuvo 1.637 % de error global con 41 modos, frente al 0.0078 % de la Tabla 4.9, e invertía la tendencia: el error crecía al añadir modos. Debe señalarse que esa ejecución preliminar no siguió el mismo presupuesto de optimización, de

modo que la comparación es corroborativa y no un contraste controlado; el contraste controlado es el de la Tabla 4.11. Con esa salvedad, la regla queda respaldada en tres regímenes distintos: la solución analítica $\cos(kx)$ de NB01 (Tabla 4.2), el speckle de NB03 (Tabla 4.11) y la superposición de ondas planas de esta sección.

4.4.4. Formulación modal adoptada

El dominio es $\Omega_{03} = [-10, 10] \times [0, 1]$ en $(\tilde{x}, \tilde{z})$, con 1,024 puntos transversales y 101 planos longitudinales. La condición de entrada es una pantalla de fase aleatoria periódica y correlacionada, con longitud de correlación $\ell_\phi = 0.10\lambda$ y desviación estándar 2 rad. De los 1,024 modos transversales, 41 son propagantes. La fracción de energía espectral que concentran depende de la realización: 40.99 % en la pantalla 42, y entre 34.55 % y 41.28 % en las cinco empleadas.

Como las fronteras laterales son periódicas, el campo admite el desarrollo exacto $u(\tilde{x}, \tilde{z}) = \sum_m a_m(\tilde{z}) e^{ik_x m \tilde{x}}$, y Helmholtz 2D se separa en las 41 ecuaciones diferenciales ordinarias desacopladas de la ecuación (4.1). La base se trunca al conjunto propagante. Este truncamiento no es una simplificación de conveniencia: es la regularización del problema de Cauchy para Helmholtz analizada por Nguyen et al. (2016), quienes establecen la solución regularizada acotando la frecuencia mediante un parámetro de regularización y demuestran estabilidad y convergencia con estimaciones de error en norma L^2 .

La condición de Cauchy se impone de forma exacta en la arquitectura,

$$a_m(\tilde{z}) = a_m(0) + \tilde{z} a'_m(0) + \tilde{z}^2 N_\theta(\tilde{z}), \quad (4.4)$$

de modo que el valor y la derivada en $\tilde{z} = 0$ se cumplen con independencia de los parámetros de la red. El error es nulo por construcción algebraica; la verificación numérica registrada da 1.28×10^{-8} en RMSE, residuo de la aritmética en `float32` y no del ajuste. Una ecuación diferencial de segundo orden con valor y derivada fijados en un punto tiene solución única, por lo que la ecuación (4.4) restaura la unicidad perdida en §4.4.1. Esta estrategia de imponer la frontera dentro de la imponer la frontera dentro de la función de prueba, en lugar de penalizarla en la pérdida, sigue el mismo principio que Sukumar y Srivastava (2022), quienes lo aplican mediante funciones de distancia aproximadas para condiciones de Dirichlet, Neumann y Robin sobre fron-

teras geométricas; aquí el mecanismo es distinto –una prolongación polinómica que fija valor y derivada en un punto– aunque la consecuencia sobre la pérdida es la misma.

Dos consecuencias metodológicas se siguen de la ecuación (4.4). Primero, la pérdida contiene únicamente el residuo modal: no hay término de datos y por tanto **no existe un peso λ_{fis} que calibrar** en NB03, a diferencia de NB01 y NB02. Segundo, cada salida se escala por $s_m = k^2 \max(|a_m(0)|, |a'_m(0)|/k, \epsilon)$, lo que evita que los modos de mayor amplitud dominen el residuo y los débiles queden sin ajustar.

Tabla 4.10. Configuración de NB03 frente a NB01 y NB02.

Elemento	NB01 / NB02	NB03 modal
Entrada de la red	$\tilde{x} / (\tilde{x}, \tilde{y})$	$\tilde{z}$ escalar
Salidas	1 / 2	82 (41 modos complejos)
Capas ocultas	$5 \times 64 / 5 \times 128$	4×128
ω_0 primera capa	1.0	1.0
Frontera	término de datos con λ_{fis}	dura, en la arquitectura
λ_{fis}	1.0 / 0.1	no aplica
Optimización	Adam + L-BFGS	Adam 5,000 + Adam 3,000
Tasa de aprendizaje	10^{-3}	2×10^{-4} y 5×10^{-5}
Colocación	uniforme / LHS 2D	256 posiciones de $\tilde{z}$ por época

NB03 no emplea L-BFGS en el protocolo de $\tilde{z} = 1\lambda$ ni tiene peso de física que calibrar, por lo que las filas correspondientes de la Tabla 3.1 no le son aplicables. La inicialización sinusoidal de Sitzmann et al. (2020) y la autodiferenciación de segundo orden sí se conservan desde NB01 y NB02.

4.4.5. Verificación de la referencia

La referencia se calcula por el método del espectro angular, que propaga cada modo como $a_m(0)e^{ik_{z,m}\tilde{z}}$. El método se validó previamente contra una propagación exacta, con un error relativo del orden de la precisión de máquina ($\sim 10^{-16}$). Las cinco referencias empleadas se regeneraron desde cero y coinciden **bit a bit** con las originales: la diferencia máxima es 0.000×10^0 en los ocho campos almacenados (fase, campo objetivo, campo en todos los planos, intensidad, intensidad del conjunto, coordenadas y espectro), para las cinco semillas.

Debe señalarse que esta referencia es **semianalítica** y no constituye un método numérico independiente en el sentido del elemento finito: propaga cada modo mediante la solución cerrada de la misma ecuación diferencial ordinaria que la red minimiza. Mide, por tanto, la exactitud del

solucionador frente a la solución exacta de sus propias ecuaciones, igual que NB01 se valida contra $\cos(2\pi\tilde{x})$ y NB02 contra una onda plana. La independencia metodológica plena corresponde a la comparación con FEM planteada como trabajo pendiente.

4.4.6. Calibración de ω_0 en el régimen modal

La red modal recibe $\tilde{z}$ normalizado y cada coeficiente oscila como $a_m(\tilde{z}) \propto e^{ik_{z,m}\tilde{z}}$ con $k_{z,m} \leq k = 2\pi$: como máximo una oscilación completa en todo el dominio. La regla $\omega_0 \approx k/2\pi$ establecida en §4.1.4 predice por tanto $\omega_0 = 1$. Para contrastarla en este segundo régimen se repitió el barrido sobre la pantalla 42 con protocolo idéntico.

Tabla 4.11. Barrido de ω_0 en la formulación modal (pantalla 42, 5,000 épocas Adam).

ω_0	L^2 total	L^2 propagante	Residuo de la EDO
1.0	3.819 %	0.090 %	3.59×10^{-3}
5.0	3.819 %	0.081 %	2.61×10^{-3}
15.0	3.833 %	0.329 %	1.33×10^{-2}
30.0	4.962 %	3.172 %	5.49×10^{-2}

Mismo protocolo en los cuatro casos, sin refinamiento posterior. El valor $\omega_0 = 30$ es el que Sitzmann et al. (2020) proponen para el conjunto de sus aplicaciones, entre ellas la ecuación de Helmholtz, de modo que el contraste se establece frente al valor por defecto de la literatura en este mismo dominio. El error propagante –la componente que la representación puede expresar– se degrada en un factor de 35 entre $\omega_0 = 1$ y $\omega_0 = 30$, y el residuo de la ecuación en un factor de 15. El comportamiento es el esperado del sesgo espectral descrito por Rahaman et al. (2019) y replica, en un problema con entrada, salida y física distintas, el resultado de la Tabla 4.2. Fuente: `results/nb03_modal_omega0_sweep_summary.json`, generado por `scripts/experiments/nb03_omega0_sweep_summary.py`, que recalcula la descomposición del error desde los campos guardados.

Consolidado sobre las cinco pantallas, el cambio de $\omega_0 = 30$ a $\omega_0 = 1$ reduce el error propagante medio a lo largo de la propagación de 2.983 % a 0.042 %, y el máximo de 4.791 % a 0.084 %.

El barrido reproduce el patrón observado en NB01: $\omega_0 = 1$ y $\omega_0 = 5$ quedan próximos entre sí –de hecho $\omega_0 = 5$ registra un error propagante marginalmente menor, 0.081 % frente a 0.090 %– y ambos separados por más de un orden de magnitud de los valores altos. Lo que el barrido establece, por tanto, es que calibrar ω_0 al orden de $k/2\pi$ es condición relevante del desempeño

de la formulación modal, no que la regla acierte el valor óptimo dentro del rango bajo. En ese sentido acotado, la regla derivada en NB01 sí resulta determinante para el tercer experimento.

4.4.7. Resultados en $\tilde{z} = 1\lambda$

Tabla 4.12. NB03 modal con ω_0 calibrado: cinco pantallas de fase independientes en $\tilde{z} = 1\lambda$.

Pantalla	L^2 complejo	Piso evan.	Coherencia	C_{ref}	C_{PINN}	$ \Delta C $
42	3.819 %	3.818 %	0.999271	0.9063	0.9012	0.0051
123	2.402 %	2.401 %	0.999712	0.8827	0.8821	0.0006
321	3.573 %	3.573 %	0.999362	0.9200	0.9231	0.0030
777	2.947 %	2.947 %	0.999566	1.2246	1.2403	0.0157
2026	3.064 %	3.063 %	0.999531	0.7812	0.7841	0.0029
Media	3.161 %	3.160 %	0.999488	—	—	0.0055

Semilla de red fija en 42; las cinco pantallas son realizaciones de fase independientes. Las cinco cumplen el criterio $L^2 < 5\%$. El residuo modal RMSE medio es 2.34×10^{-3} y el error de las condiciones de Cauchy es de 1.28×10^{-8} en RMSE, nulo salvo por la aritmética en float32. Los cinco modelos se entrenaron desde cero en el equipo de este trabajo y reproducen corridas previas dentro de 0.08 puntos porcentuales. Fuente: results/nb03_modal_multiseed_z1_omega1_summary.json.

La columna del piso evanescente permite interpretar correctamente la métrica, y la Figura 4.5 la resume. Pantalla por pantalla, el error total del modelo coincide con el piso hasta la tercera cifra decimal (3.819 frente a 3.818; 2.402 frente a 2.401; 3.573 frente a 3.573), y la desviación de ambas columnas es la misma (± 0.497 puntos porcentuales). Es decir: el L^2 total está dominado por la energía evanescente de la referencia, que la base modal no puede representar por construcción, y no por el ajuste de la red. Medido sobre el subespacio representable, el error propagante medio a lo largo de la propagación es de 0.042 % y el máximo de 0.084 %.

4.4.8. Dependencia del piso evanescente con la distancia

La fracción evanescente decae como $e^{-|\kappa_m|\tilde{z}}$, de modo que el piso es una función de la distancia de propagación y no una constante del método.

Este comportamiento explica el valor $C = 0.906$ de la pantalla 42 en $\tilde{z} = 1\lambda$ sin recurrir a una deficiencia del modelo: el patrón está todavía en formación. El contraste transversal medido sobre la referencia crece de 0 en la pantalla a 0.797 en $\tilde{z} = 0.25\lambda$, 0.828 en 0.5λ y 0.906 en 1λ , mientras el tamaño de grano transversal pasa de 0.298λ a 0.378λ .

Tabla 4.13. Piso evanescente y contraste de la referencia en función de la distancia.

$\tilde{z}/\lambda$	Piso evanescente	C de la referencia
0.25	25.49 %	0.7968
0.50	12.61 %	0.8283
1.00	3.818 %	0.9063
2.00	0.456 %	1.1595
3.00	0.0598 %	1.2069
5.00	0.0011 %	1.0476

Calculado analíticamente desde el espectro de la pantalla 42, sin entrenar ningún modelo. La distancia $\tilde{z} = 1\lambda$ corresponde a campo cercano estricto: es la peor distancia posible para la métrica de campo completo, porque casi el 4 % de la energía es irrepresentable por la base propagante y el patrón aún no ha madurado estadísticamente. El contraste de la referencia parte de $C = 0$ exactamente en $\tilde{z} = 0$ —donde la pantalla es de fase pura y la intensidad es uniforme—, crece hasta superar la unidad alrededor de $\tilde{z} = 2\lambda$ y después fluctúa, sin comportamiento monótono: cae de 1.2069 en 3λ a 1.0476 en 5λ . Estos son valores de una realización individual, para la que el criterio de conjunto $|C - 1| < 0.1$ no es aplicable; de las distancias tabuladas sólo lo satisfarían 1λ (0.0937) y 5λ (0.0476).




Figura 4.5. Resultados de NB03 modal. **(a)** Error L^2 propagante a lo largo de la propagación para las cinco pantallas, con $\omega_0 = 30$ (rojo) y $\omega_0 = 1$ (azul); las curvas tenues son las pantallas individuales y las gruesas su promedio. La separación es de aproximadamente dos órdenes de magnitud en todo el intervalo. **(b)** Fracción de energía irrepresentable por la base modal —el piso evanescente— frente a la distancia de propagación, en escala logarítmica, junto al error medio del modelo calibrado. Cómo leerla: en $\tilde{z} = 1\lambda$ el piso es 92 veces mayor que el error del modelo, de modo que la métrica de campo completo mide la física irrepresentable y no el ajuste de la red. El piso decae con la distancia y cruzaría el nivel de error aquí medido alrededor de $\tilde{z} \approx 3.2\lambda$ si ese error se mantuviera constante, extrapolación que este trabajo no verifica: el modelo sólo se validó en $\tilde{z} = 1\lambda$, y el ensayo de extensión a 2λ (§4.4.10) muestra que el error crece con la distancia. Fuentes: results/nb03_modal_multiseed_z1_omega1_12_curves.npz y results/nb03_angular_spectrum_reference_z1_corr0.10.npz.

4.4.9. Criterio estadístico: conjunto frente a realización individual

Goodman (2007) caracteriza el *speckle* completamente desarrollado como aquel cuyo contraste vale $C = 1$, propiedad del conjunto de realizaciones. La tolerancia $|C - 1| < 0.1$ con la que se evalúa aquí es una decisión operativa de este trabajo y no un umbral establecido por ese autor. Aplicado a una pantalla finita individual, el criterio no se cumple ni siquiera para la referencia exacta: su contraste varía entre 0.7812 y 1.2246 según la realización (Tabla 4.12). La evaluación se realiza por ello en dos niveles:

- **Conjunto.** Reuniendo las cinco pantallas, el contraste del campo de la PINN es $C = 0.9489$, esto es $|C - 1| = 0.051$, dentro del criterio. Este conjunto lo forman cinco realizaciones, mientras que cada contraste de conjunto de la referencia citado a continuación procede de 64: las dos cifras no son equivalentes en tamaño muestral. Las referencias por espectro angular, cada una sobre 64 realizaciones en $\tilde{z} = 1\lambda$, dan contrastes de 0.9759, 0.9757, 0.9531, 0.9619 y 0.9637, con media 0.9661: el conjunto sí se encuentra en el régimen de *speckle* completamente desarrollado.
- **Realización individual.** Fidelidad al contraste de su propia referencia, $|C_{\text{PINN}} - C_{\text{ref}}| < 0.05$, que se cumple en las cinco pantallas con un error máximo de 0.0157. El criterio absoluto $|C - 1| < 0.1$ aplicado a cada realización por separado se cumple, en cambio, en sólo 2 de las 5 pantallas, tanto para la PINN como para su referencia exacta.

Esta distinción no relaja el criterio: lo aplica al objeto estadístico para el que fue definido.

Debe reportarse una limitación asociada, que afecta a la referencia exacta y no sólo al modelo. El test de Kolmogorov–Smirnov de bondad de ajuste a la distribución exponencial, aplicado a los 1,024 valores de intensidad de una realización individual *de la referencia por espectro angular*, sólo alcanza $p > 0.05$ en una de las cinco pantallas (valores de p : 0.1423, 0.0266, 0.0048, 0.0000 y 0.0000). El motivo es que la prueba supone muestras independientes, mientras que los valores de intensidad de un corte espacial de *speckle* están correlacionados dentro de cada grano —de tamaño transversal 0.378λ en $\tilde{z} = 1\lambda$, es decir unas 19 muestras por grano en esta malla—, lo que reduce drásticamente el número efectivo de muestras independientes y sesga el p -valor hacia el rechazo. Por ello el test se reporta aquí como estadístico descriptivo y no como criterio de

aceptación.

Debe añadirse que el rechazo persiste al agregar las cinco pantallas: sobre el conjunto, el test da $p = 1.98 \times 10^{-3}$ para el campo de la PINN y $p = 4.24 \times 10^{-4}$ para la referencia por espectro angular. Que la referencia exacta sea rechazada con la misma claridad que el modelo respalda que la causa es la hipótesis de independencia del test y no un defecto del ajuste; esta explicación es, sin embargo, una interpretación y no un resultado: el trabajo no incluye un contraste con número efectivo de muestras corregido ni un remuestreo por bloques que la verifique formalmente.

La fracción de píxeles con $I > 2\langle I \rangle$, que no depende de esa hipótesis, se sitúa entre 0.1299 y 0.1543 por pantalla frente al valor teórico $e^{-2} = 0.1353$, y sobre el conjunto da 0.1467 para la PINN y 0.1475 para la referencia. Fuente: `results/nb03_estadistica_conjunto.json`, generado por `scripts/experiments/nb03_estadistica_conjunto.py`.

4.4.10. Ensayo de extensión a $\tilde{z} = 2\lambda$: resultado negativo

La validación reportada se limita a $\tilde{z} = 1\lambda$. Se ensayó extenderla a 2λ partiendo del punto de control validado de cada pantalla y reentrenando únicamente sobre el residuo, con un presupuesto uniforme de 180 s por pantalla.

Tabla 4.14. Ensayo de extensión a $\tilde{z} = 2\lambda$ con presupuesto uniforme.

Pantalla	L^2 propagante	L^2 complejo	Máximo propagante	Piso evan.
42	1.690 %	1.750 %	2.499 %	0.456 %
123	6.144 %	6.151 %	7.373 %	0.292 %
321	8.069 %	8.082 %	10.010 %	0.462 %
777	4.178 %	4.192 %	5.651 %	0.340 %
2026	1.047 %	1.111 %	1.722 %	0.371 %
Media	4.226 %	4.257 %	5.451 %	0.384 %

Presupuesto idéntico de 180 s para las cinco pantallas. Dos de ellas superan el umbral del 5 % en el error final y tres lo superan en el máximo sobre los planos evaluados; la media del máximo propagante queda también por encima. Fuente: `results/nb03_distance_pilot/z2_cinco_uniforme_180s/`.

La extensión a 2λ no supera el criterio de aceptación y se reporta aquí como resultado negativo. Un segundo hecho agrava el diagnóstico: el error no decrece de forma monótona con el presupuesto de cómputo. Con 120 s en lugar de 180 s, la pantalla 321 había registrado 3.108 % y la 123, 4.457 %; al aumentar el tiempo empeoran a 8.069 % y 6.144 %. Un refinamiento que se

degrada al recibir más iteraciones indica que el procedimiento no converge de forma estable en ese régimen, no que le falte presupuesto.

En consecuencia, el alcance validado de este trabajo es $\tilde{z} = 1\lambda$. Cualquier afirmación sobre distancias mayores exigiría un procedimiento de optimización distinto y su propia campaña de validación.

4.4.11. Tiempo de inferencia frente a la referencia de propagación

Los alcances del Capítulo 1 comprometen un *benchmark* del tiempo de inferencia contra una referencia numérica de propagación, independiente de la comparación con FEM. Esa medición sí puede realizarse con los elementos disponibles y se reporta aquí.

La comparación se plantea a igualdad de salida: ambos métodos producen el mismo campo complejo en $\tilde{z} = 1\lambda$ sobre los mismos 1,024 puntos transversales, y se verificó que ambas salidas coinciden con una discrepancia relativa de 0.0475 % antes de cronometrar. El método de referencia calcula la transformada de Fourier de la pantalla, multiplica por el propagador $e^{ik_z\tilde{z}}$ y antitransforma, con coste $O(N \log N)$ por plano. La PINN evalúa la red en $\tilde{z}$, obtiene los 41 coeficientes modales y reconstruye el campo por suma modal.

Tabla 4.15. Tiempo de evaluación: PINN-SIREN modal frente al espectro angular.

Tarea	Espectro angular	PINN modal	Razón
Un plano ($\tilde{z} = 1\lambda$)	0.070 ms	0.905 ms	12.9× a favor del ASM
101 planos simultáneos	3.718 ms	2.276 ms	1.63× a favor de la PINN

Medias de 50 repeticiones (un plano) y 20 (múltiples planos), tras 10 iteraciones de calentamiento y con sincronización explícita de CUDA. Desviaciones estándar: 0.103 y 0.320 ms en el caso de un plano; 0.272 y 0.493 ms en el de 101. Para operaciones de esta duración el mínimo observado es más representativo que la media, porque la dispersión la domina la planificación del sistema operativo: los mínimos son 0.039 y 0.560 ms (un plano) y 3.365 y 1.766 ms (101 planos). GPU NVIDIA RTX 5050, PyTorch 2.11, CUDA 12.8. Fuente: `results/nb03_benchmark_inferencia.json`, generado por `scripts/experiments/nb03_benchmark_inferencia.py`.

El resultado no favorece a la red. Para un solo plano el método del espectro angular es aproximadamente un orden de magnitud más rápido: es una transformada rápida de Fourier sobre 1,024 puntos, difícil de superar. La PINN sólo aventaja al método de referencia cuando se evalúan muchos planos a la vez, porque resuelve los 101 valores de $\tilde{z}$ en un único paso por lotes mientras el espectro angular requiere una antitransformada por plano; incluso entonces la ventaja es de un

factor 1.63.

El costo de entrenamiento invierte cualquier lectura favorable. Como se señala en §4.4.12, el modelo es específico de su realización: los datos de Cauchy están incorporados a la arquitectura, de modo que cada pantalla nueva exige entrenar una red desde cero, lo que en este equipo requiere 351.9 s. Con un ahorro de 1.44 ms por evaluación de 101 planos, serían necesarias unas 2.4×10^5 evaluaciones *sobre la misma pantalla* para amortizar ese entrenamiento. Ningún uso realista del método alcanza esa cifra.

Se sigue de aquí que, frente a la referencia de propagación y con la formulación actual, **no se observa ganancia en tiempo de cómputo**. Este resultado cubre el alcance comprometido, pero no responde la hipótesis (ii), que se plantea frente a una implementación FEM: esa comparación requiere NB04 y queda pendiente. Debe anticiparse, no obstante, que el costo de entrenamiento por realización es independiente del método de referencia con el que se compare, y condicionará igualmente esa medición.

La aportación de la formulación modal debe valorarse por tanto en términos de precisión y de correcto planteamiento del problema —§4.4.1 y §4.4.2—, no de velocidad.

4.4.12. Limitaciones del método

La formulación modal obtiene su precisión a cambio de restricciones que conviene declarar de forma explícita:

- **Fronteras laterales periódicas.** El desarrollo de la ecuación (3.6) es exacto porque el dominio es periódico en $\tilde{x}$. Sin esa periodicidad no existe la serie de Fourier discreta que desacopla el problema, y toda la reducción modal deja de aplicarse. Un difusor físico real no es periódico.
- **Medio homogéneo.** El desacoplamiento de la ecuación (4.1) exige k constante. Con permitividad variable en el espacio los modos se acoplan y el sistema deja de ser un conjunto de ecuaciones independientes. Es una diferencia sustantiva frente a trabajos que sí tratan medios inhomogéneos, como Panagiotakopoulos et al. (2026).
- **El modelo es específico de cada realización.** Los datos de Cauchy $a_m(0)$ y $a'_m(0)$ están

incorporados a la arquitectura como constantes de la función de prueba (ecuación (4.4)). Cada pantalla nueva exige entrenar una red desde cero, del orden de 350 s en el equipo empleado. La red no es un sustituto entrenado que generalice a realizaciones no vistas, sino un solucionador de un problema dado. Esto condiciona directamente cómo debe plantearse el factor de aceleración frente a FEM: un cómputo que considere sólo la inferencia sería engañoso.

- **Una sola inicialización de red.** Las cinco pantallas varían la realización física, no la semilla de la red, fija en 42. La dispersión inter-semilla medida en NB02 (Tabla 4.4) es de un coeficiente de variación del 46 %, de modo que la robustez frente a la inicialización no está caracterizada en NB03.
- **Referencia semianalítica.** Según lo discutido en §4.4.5, la referencia comparte con el modelo la base modal y la ecuación diferencial, por lo que mide exactitud del solucionador y no acuerdo con un método numérico independiente.
- **Alcance en distancia.** Validado en $\tilde{z} = 1\lambda$; el ensayo a 2λ de §4.4.10 no supera el criterio.

4.5. Contexto en la literatura

La Tabla 4.16 sitúa los resultados de precisión de la PINN-SIREN propuesta junto al antecedente más cercano en la literatura.

El antecedente más cercano en arquitectura a este trabajo es Panagiotakopoulos et al. (2026), quienes resuelven la misma ecuación de Helmholtz 2D con campo complejo, usando también una red SIREN y la misma estrategia de optimización bifásica Adam seguido de L-BFGS. Se diferencia de este trabajo en tres aspectos: (i) validan cualitativamente la física del campo resultante (propagación, refracción, dispersión) en lugar de reportar un error L^2 cuantitativo contra una solución analítica; (ii) no calibran ω_0 respecto al número de onda k ; y (iii) su condición de frontera es una fuente puntual gaussiana con condición de radiación de Sommerfeld, en lugar de la fase aleatoria en $z = 0$ que da lugar al patrón de *speckle* en este trabajo. No aborda, por tanto, la generación de *speckle* ni su validación estadística contra los criterios de Goodman (2007).

Tabla 4.16. Error L^2 relativo: PINN-SIREN y antecedente de la literatura.

Método	Dimensión	Comparación	Error L^2 (%)
Schoder & Kraxberger (2024)	3D (acústica)	PINN vs. FEM (malla fina)	2.49 ^b
Zhang et al. (2025)	2D (EM)	PINN vs. simulación numérica	1.40–5.82
PINN-SIREN (este trabajo)	1D (óptica)	PINN vs. solución analítica	0.006
PINN-SIREN (este trabajo)	2D (óptica)	PINN vs. solución analítica	0.171
PINN-SIREN modal (este trabajo)	2D (óptica)	PINN vs. espectro angular	3.161^a

Los resultados no son directamente comparables entre sí: difieren en dimensionalidad, dominio físico (acústico/electromagnético vs. óptico) y tipo de solución de referencia (FEM/simulación numérica vs. analítica o semi-analítica). Se presentan como contexto de la literatura, no como línea base de comparación cuantitativa. Los resultados propios se validan contra el umbral fijo de la tesis ($L^2 < 5\%$), independiente de trabajos externos.

^b Schoder & Kraxberger (2024) reportan cuatro valores en esa columna según la nitidez de la fuente (0.9718, 0.0997, 0.0243 y 0.0249); se cita el correspondiente a la fuente más concentrada. No es un valor único del trabajo.

^a Valor de campo completo. Está dominado por la fracción evanescente de la referencia, irrepresentable por la base modal: el error sobre el subespacio propagante es de 0.042% en promedio (Sección 4.4.7). La comparación con los dos trabajos externos de esta tabla es además de distinta naturaleza, porque ambos contrastan contra un método numérico independiente y aquí la referencia es semianalítica (Sección 4.4.5).

4.6. Resumen de experimentos completados

La Tabla 4.17 sintetiza el estado de los experimentos planificados en los objetivos específicos.

Tabla 4.17. Estado de los experimentos planificados.

Experimento	Descripción	Estado	Métrica principal
NB01	Helmholtz 1D, validación analítica	Completo	$L^2 = 0.006\%$
NB02	Helmholtz 2D, campo complejo	Completo	$L^2 = 0.171\%$
NB02B	Arquitectura modal contra solución exacta	Completo	$L^2 = 0.0078\%$ (41 modos)
NB03-A	Speckle, referencia por espectro angular	Completo	$C = 0.9661$ (conjunto, 64 real.)
NB03-B	PINN-SIREN modal en $\tilde{z} = 1\lambda$	Completo	$L^2 = 3.161\%$ (5 pantallas)
NB03-C	Inferencia frente al espectro angular	Completo	Sin ganancia de tiempo
NB04	Benchmark FEM, factor de aceleración	Pendiente	$S = T_{\text{FEM}}/T_{\text{PINN}}$

Los estados se refieren al cierre de esta versión de la tesis. El contraste de NB03-A es el promedio del contraste de conjunto de las cinco pantallas, cada uno sobre 64 realizaciones en $\tilde{z} = 1\lambda$. NB04 permanece abierto para trabajo posterior y es el único objetivo específico sin evidencia asociada.

Los tres experimentos completados verifican la hipótesis de precisión. NB01 y NB02 cumplen el umbral $L^2 < 5\%$ con amplitud frente a soluciones analíticas. NB03 cumple el umbral en las cinco pantallas de fase independientes frente a la referencia por espectro angular, con la precisión adicional de que el error residual está dominado por la fracción evanescente del espectro y no por el ajuste de la red (Sección 4.4.7). Debe señalarse, no obstante, que la hipótesis (i) exige

para NB03 una referencia *numérica independiente*, y la empleada aquí es semianalítica (Sección 4.4.5): la verificación de esa hipótesis en su sentido estricto queda condicionada a NB04. La hipótesis estadística se cumple en los dos niveles definidos en Sección 4.4.9.

La hipótesis de velocidad ($S > 1$) permanece sin responder en sus propios términos, que la plantean frente a una implementación FEM: eso requiere NB04, que es además la única vía para disponer de una referencia numérica independiente del método (Sección 4.4.5). Sí se midió, en cambio, el tiempo frente a la referencia de propagación comprometido en los alcances, y el resultado es negativo: el espectro angular resulta un orden de magnitud más rápido para un plano, la ventaja de la red en evaluación por lotes es de un factor 1.63, y el costo de entrenamiento por realización exigiría del orden de 10^5 evaluaciones de la misma pantalla para amortizarse (Sección 4.4.11). La contribución de este trabajo reside por tanto en el planteamiento y la precisión, no en el tiempo de cómputo.

Bibliografía

- Alkhalifah, T., Song, C., Waheed, U. b., & Hao, Q. (2021). Wavefield solutions from machine learned functions constrained by the Helmholtz equation. *Artificial Intelligence in Geosciences*, 2, 11-19. <https://doi.org/10.1016/j.aiig.2021.08.002>
- Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(153), 1-43.
- Born, M., & Wolf, E. (1999). *Principles of Optics: Electromagnetic Theory of Propagation, Interference and Diffraction of Light* (7.^a ed.). Cambridge University Press.
- Chen, Y., Lu, L., Karniadakis, G. E., & Dal Negro, L. (2020). Physics-informed neural networks for inverse problems in nano-optics and metamaterials. *Optics Express*, 28(8), 11618-11633. <https://doi.org/10.1364/OE.384875>
- Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next. *Journal of Scientific Computing*, 92(3), 88. <https://doi.org/10.1007/s10915-022-01939-z>
- Fang, Z., & Zhan, J. (2020). Deep physical informed neural networks for metamaterial design. *IEEE Access*, 8, 24506-24513. <https://doi.org/10.1109/ACCESS.2019.2963375>
- Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Roberts & Company.
- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359-366. [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8)
- Jin, J.-M. (2014). *The Finite Element Method in Electromagnetics* (3.^a ed.). John Wiley & Sons.

- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440. <https://doi.org/10.1038/s42254-021-00314-5>
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization [Published at ICLR 2015].
- Krishnapriyan, A. S., Gholami, A., Zhe, S., Kirby, R. M., & Mahoney, M. W. (2021). Characterizing Possible Failure Modes in Physics-Informed Neural Networks [arXiv:2109.01050]. *Advances in Neural Information Processing Systems*, 34, 26548-26560.
- Lagaris, I. E., Likas, A., & Fotiadis, D. I. (1998). Artificial neural networks for solving ordinary and partial differential equations. *IEEE Transactions on Neural Networks*, 9(5), 987-1000. <https://doi.org/10.1109/72.712178>
- Lu, L., Meng, X., Mao, Z., & Karniadakis, G. E. (2021). DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1), 208-228. <https://doi.org/10.1137/19M1274067>
- McKay, M. D., Beckman, R. J., & Conover, W. J. (1979). A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2), 239-245. <https://doi.org/10.1080/00401706.1979.10489755>
- Moseley, B., Markham, A., & Nissen-Meyer, T. (2020). Solving the wave equation with physics-informed deep learning. <https://doi.org/10.48550/arXiv.2006.11894>
- Nguyen, H. T., Khoa, V. A., Minh, M. N., & Tran, T. (2016). Reconstruction of the electric field of the Helmholtz equation in 3D [Version v3 del 11 de marzo de 2016; investiga el metodo de truncamiento como regularizacion del problema de Cauchy para Helmholtz, con estimaciones de error en norma L2]. <https://doi.org/10.48550/arXiv.1408.1932>
- Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization* (2.^a ed.). Springer.
- Panagiotakopoulos, T., Velissaris, C., & Rapsomanikis, A. N. (2026). Physics-Informed Neural Network Solution of the 2D Helmholtz Equation with a Gaussian Source [Repository deposit, publicado el 9 de abril de 2026; aún no revisado por pares; sin DOI disponible]. <https://stars.library.ucf.edu/ucfscholar/1345>

- Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F., Bengio, Y., & Courville, A. (2019). On the spectral bias of neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 97, 5301-5310.
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- Schoder, S., & Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. <https://doi.org/10.48550/arXiv.2403.06623>
- Sitzmann, V., Martel, J. N. P., Bergman, A. W., Lindell, D. B., & Wetzstein, G. (2020). Implicit Neural Representations with Periodic Activation Functions. *Advances in Neural Information Processing Systems*, 33, 7462-7473.
- Sukumar, N., & Srivastava, A. (2022). Exact imposition of boundary conditions with distance functions in physics-informed deep neural networks [Preprint local: arXiv:2104.08426v2, 7 de noviembre de 2021]. *Computer Methods in Applied Mechanics and Engineering*, 389, 114333. <https://doi.org/10.1016/j.cma.2021.114333>
- Tancik, M., Srinivasan, P. P., Mildenhall, B., Fridovich-Keil, S., Raghavan, N., Singhal, U., Ramamoorthi, R., Barron, J. T., & Ng, R. (2020). Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains. *Advances in Neural Information Processing Systems*, 33, 7537-7547.
- Wang, S., Teng, Y., & Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5), A3055-A3081. <https://doi.org/10.1137/20M1318043>
- Wang, S., Yu, X., & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective [Preprint local: arXiv:2007.14527v1, 28 de julio de 2020]. *Journal of Computational Physics*, 449, 110768. <https://doi.org/10.1016/j.jcp.2021.110768>
- Zhang, H., Li, C., Xia, R., Chen, X., Xiao, T., Guo, X.-W., & Liu, J. (2025). FE-PIRBN: Feature-enhanced physics-informed radial basis neural networks for solving high-frequency electromagnetic scattering problems. *Journal of Computational Physics*, 527, 113798. <https://doi.org/10.1016/j.jcp.2025.113798>