



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



**DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN**

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINN'S)**

**TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN**

**PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA**

**BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO**

CUNDUACÁN, TABASCO, A: JUNIO 2026



UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE CIENCIAS Y TECNOLOGÍAS DE LA
INFORMACIÓN

**SIMULACIÓN ACELERADA DE SPECKLE ÓPTICO: UN ENFOQUE
BASADO REDES NEURONALES FÍSICAMENTE INFORMADAS
(PINN'S)**

TESIS PARA OBTENER EL GRADO DE:
MAESTRO EN CIENCIAS DE LA COMPUTACIÓN

PRESENTA:
ROBERTO HERNÁNDEZ ESTRADA

BAJO LA DIRECCIÓN DE:
DR. JOSÉ ADÁN HERNÁNDEZ NOLASCO

CUNDUACÁN, TABASCO, A: JUNIO 2026

Declaración de Autoría y Originalidad

En la Ciudad de Cunduacán el día Siete del mes de Junio del año 2026, el que suscribe **Roberto Hernández Estrada**, alumno del Programa de la **Maestría en Ciencias de la Computación** con número de matrícula **252H21004**, adscrito a la **División Académica de Ciencias y Tecnologías de la Información**, de la Universidad Juárez Autónoma de Tabasco, como autor de la Tesis presentada para la obtención del Grado de Maestría y titulada **Simulación acelerada de speckle óptico: Un enfoque basado redes neuronales físicamente informadas (PINN's)**, dirigida por el Dr. José Adán Hernández Nolasco.

DECLARO QUE: La Tesis es una obra original que no infringe los derechos de propiedad intelectual ni los derechos de propiedad industrial u otros, de acuerdo con el ordenamiento jurídico vigente, en particular, la LEY FEDERAL DEL DERECHO DE AUTOR (Decreto por el que se reforman y adicionan diversas disposiciones de la Ley Federal del Derecho de Autor del 01 de Julio de 2020 regularizando, aclarando y armonizando las disposiciones legales vigentes sobre la materia), en particular, las disposiciones referidas al derecho de cita. Del mismo modo, asumo frente a la Universidad cualquier responsabilidad que pudiera derivarse de la autoría o falta de originalidad o contenido de la Tesis presentada de conformidad con el ordenamiento jurídico vigente.


Cunduacán, Tabasco a 07 de Junio de 2026.

Estudiante: Roberto Hernández Estrada



UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO

"ESTUDIO EN LA DUDA. ACCIÓN EN LA FE"



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN



Cunduacán, Tabasco a 30 de septiembre de 2024

Oficio No. 1220/DACYTI/CP/2024

Asunto: Autorización de impresión de Tesis

C. Fernando Contreras Pérez

Egresado de la Maestría en Ciencias de la Computación

En virtud de que cumple satisfactoriamente los requisitos establecidos en el Reglamento General de Estudios de Posgrado vigente en la Universidad, informo a Usted que se autoriza la impresión del trabajo recepcional **"Identificación automática de vehículos empleando aprendizaje profundo"**, para presentar examen y obtener el Grado de Maestro en Ciencias de la Computación.

Sin otro particular, aprovecho la ocasión para enviarle un afectuoso saludo.

Atentamente

MTE. Óscar Alberto González González
Director

UNIVERSIDAD JUÁREZ
AUTÓNOMA DE TABASCO



DIVISIÓN ACADÉMICA DE
CIENCIAS Y TECNOLOGÍAS
DE LA INFORMACIÓN

C.c.p. Dr. Eddy Arquímedes García Alcocer. - Encargado del Despacho de la Coordinación de Posgrado DACYTI
Archivo.
Consecutivo.

M.T.E. OAGG/EAGA X

Carretera Cunduacán-Jalpa Km. 1, Colonia Esmeralda, C.P. 86690.
Cunduacán, Tabasco, México.
Tel: (993) 358 1500 ext. 6727; (914) 336 0616; Fax: (914) 336 0870
E-mail: direccion.dacyti@ujat.mx

Carta de Cesión de Derechos

Cunduacán, Tabasco a 07 de Junio de 2026.

Por medio de la presente manifiesto haber colaborado como AUTOR en la producción, creación y/o realización de la obra denominada: **Simulación acelerada de speckle óptico: Un enfoque basado redes neuronales físicamente informadas (PINN's)**.

Con fundamento en el artículo 83 de la Ley Federal del Derecho de Autor y toda vez que, la creación y/o realización de la obra antes mencionada se realizó bajo la comisión de la Universidad Juárez Autónoma de Tabasco; entendemos y aceptamos el alcance del artículo en mención de que tenemos el derecho al reconocimiento como autores de la obra, y a la Universidad Juárez Autónoma de Tabasco mantendrá en un 100 % la titularidad de los derechos patrimoniales por un período de 20 años sobre la obra en la que colaboramos, por lo anterior, cedemos el derecho patrimonial exclusivo en favor de la Universidad.

COLABORADOR

Estudiante: Roberto Hernández Estrada

TESTIGOS

Dr. José Adán Hernández Nolasco

Dr. Óscar Alberto Chávez Bosquez

Índice general

Índice de Figuras	IV
Índice de Tablas	V
Resumen	VI
Abstract	VII
1. Generalidades	1
1.1. Introducción	1
1.2. Planteamiento del problema	2
1.2.1. Definición del problema	2
1.2.2. Delimitación de la investigación	3
1.3. Preguntas de investigación e hipótesis	4
1.4. Objetivo general	4
1.5. Objetivos específicos	5
1.6. Justificación	5
1.7. Metodología	6
2. Marco Teórico	8
2.1. Conceptos y teorías fundamentales	8
2.1.1. Ecuación de onda de Helmholtz	8
2.1.2. Speckle óptico completamente desarrollado	9
2.1.3. Redes Neuronales Informadas por Física (PINNs)	9

2.1.4. Redes SIREN y sesgo espectral	10
2.1.5. Diferenciación automática	11
2.1.6. Muestreo Latino Hipercúbico (LHS)	11
2.1.7. Optimización híbrida Adam + L-BFGS	11
2.2. Literatura relacionada	12
2.3. Marco tecnológico	13
2.3.1. Infraestructura de hardware	13
2.3.2. Ecosistema de software	13
3. Modelo e implementación	14
3.1. Formulación del problema	14
3.1.1. Experimento 1 (NB01): Validación 1D	14
3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo	15
3.2. Arquitectura SIREN	15
3.3. Función de pérdida y calibración de pesos	16
3.4. Estrategia de muestreo	16
3.4.1. Puntos interiores (colocación)	16
3.4.2. Puntos de frontera	17
3.5. Estrategia de optimización	17
3.6. Métricas de validación	17
3.6.1. Error L^2 relativo (NB01 y NB02)	17
3.7. Implementación modular	18
4. Experimentos y Resultados	19
4.1. NB01: Validación 1D - Helmholtz con solución analítica	19
4.1.1. Configuración experimental	19
4.1.2. Resultados de precisión	19
4.1.3. Análisis y comparativa con el estado del arte	20
4.2. NB02: Validación 2D - Helmholtz con campo complejo	20
4.2.1. Configuración experimental	20
4.2.2. Resultados de precisión	22

4.2.3. Análisis de resultados	22
4.2.4. Reproducibilidad multi-semilla	24
4.3. Ablación del peso de física λ_{fis}	25
4.4. Comparativa con el estado del arte	25
4.5. Resumen de experimentos completados	26
Bibliografía	27

Índice de figuras

4.1. Validación PINN-SIREN para Helmholtz 1D. Panel izquierdo: comparación entre la predicción de la red y la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel derecho: error puntual $ \hat{E}(x) - E_{\text{exacta}}(x) $. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.	21
4.2. Métricas adicionales de entrenamiento NB01. De izquierda a derecha: curva de pérdida total durante las fases Adam y L-BFGS, distribución del error puntual y métricas de ajuste (R^2 , Pearson). La transición Adam $\rightarrow$ L-BFGS a la época 15,000 es visible como una caída abrupta en la curva de pérdida.	21
4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior: partes real e imaginaria de la solución analítica $E_{\text{exacta}} = e^{i(k_x x + k_y y)}$. Fila inferior: predicción PINN-SIREN correspondiente. La diferencia visual es indistinguible; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.2). Malla de evaluación 100×100 , SEED = 42.	23
4.4. Métricas adicionales de entrenamiento NB02. Panel izquierdo: curva de pérdida total mostrando la transición bifásica Adam $\rightarrow$ L-BFGS. Paneles central y derecho: mapas de error puntual $ E_{\text{real}} - \hat{E}_{\text{real}} $ y $ E_{\text{imag}} - \hat{E}_{\text{imag}} $ en la malla 100×100 . Los errores más altos se concentran en las esquinas del dominio.	24

Índice de tablas

3.1. Hiperparámetros de entrenamiento consolidados.	17
4.1. Métricas de precisión - PINN-SIREN 1D ($k = 2\pi$).	20
4.2. Métricas de precisión - PINN-SIREN 2D ($k = 2\pi, k_x = k_y = k/\sqrt{2}$).	22
4.3. Reproducibilidad multi-semilla - NB02 ($\lambda_{\text{fis}} = 0.1$).	24
4.4. Ablación del peso de física λ_{fis} - NB02.	25
4.5. Comparativa de error L^2 relativo - PINN-SIREN vs. estado del arte.	26
4.6. Estado de los experimentos ejecutados.	26

Resumen

Se presenta una implementación de Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la simulación acelerada del patrón de speckle óptico, mediante la resolución de la ecuación de Helmholtz bidimensional con campo eléctrico complejo y condición de frontera de fase aleatoria. La arquitectura SIREN propuesta (5×128 neuronas, $\omega_0 = 1.0$) alcanza errores L^2 de 0.006 % en el caso 1D y 0.171 % en el caso 2D respecto a soluciones analíticas, superando al estado del arte en factores de $\times 415$ y $\times 11.2$, respectivamente. El patrón de speckle se genera imponiendo una fase aleatoria $\phi(x) \sim \mathcal{U}(0, 2\pi)$ en la superficie iluminada y resolviendo la ecuación de Helmholtz libremente en el interior del dominio. La validación estadística sigue el criterio de Goodman: contraste $C = \sigma_I / \langle I \rangle = 1.0253$ y distribución de intensidades exponencial negativa, confirmando speckle completamente desarrollado. Una estrategia de optimización bifásica Adam + L-BFGS y el muestreo por hipercubo latino (LHS) son clave para la convergencia. La reproducibilidad del método fue verificada con tres semillas independientes, obteniendo un error L^2 promedio de 0.155 ± 0.020 %.

Palabras clave: Redes Neuronales Informadas por Física, SIREN, ecuación de Helmholtz, speckle óptico, activación sinusoidal, muestreo por hipercubo latino.

Abstract

Physics-Informed Neural Networks with sinusoidal activation functions (SIREN-PINNs) are applied to simulate optical speckle patterns by solving the 2D Helmholtz equation with a complex electric field and a random-phase boundary condition. The proposed SIREN architecture (5×128 , $\omega_0 = 1.0$) achieves relative L^2 errors of 0.006 % (1D) and 0.171 % (2D) against analytical solutions, outperforming the state-of-the-art by factors of $\times 415$ and $\times 11.2$, respectively. Speckle patterns are generated by imposing a random phase $\phi(x) \sim \mathcal{U}(0, 2\pi)$ on the illuminated surface and solving the Helmholtz equation freely in the interior domain. Statistical validation confirms fully developed speckle: contrast $C = 1.0253$ and negative-exponential intensity distribution consistent with Goodman's theory. A two-phase Adam + L-BFGS optimization strategy and Latin Hypercube Sampling (LHS) are key to convergence. Reproducibility was verified with three independent random seeds, yielding a mean L^2 error of 0.155 ± 0.020 %.

Keywords: Physics-Informed Neural Networks, SIREN, Helmholtz equation, optical speckle, sinusoidal activation, Latin Hypercube Sampling.

Capítulo 1

Generalidades

1.1. Introducción

La simulación de la propagación de la luz es una herramienta fundamental en la ciencia y la ingeniería, con aplicaciones que abarcan desde el diseño de sistemas de telecomunicaciones y la nanofotónica hasta el desarrollo de técnicas de imagenología médica. Un fenómeno de particular interés es el *speckle* óptico, un patrón de interferencia granular de alto contraste que surge cuando luz coherente, como la emitida por un láser, se dispersa sobre una superficie rugosa o un medio difusor.

Tradicionalmente, la simulación de estos fenómenos ondulatorios se aborda mediante métodos numéricos robustos como el Método de Elementos Finitos (*FEM*) o métodos estocásticos como el de Monte Carlo. Sin embargo, estos métodos presentan un cuello de botella computacional significativo: requieren una discretización extremadamente fina del dominio espacial para resolver las oscilaciones rápidas del campo de luz, lo que resulta en un consumo masivo de memoria y tiempos de cómputo que pueden extenderse por horas o días cuando se necesitan miles de realizaciones estadísticas (Goodman, 2007; Jin, 2014).

En paralelo, el campo de la inteligencia artificial ha experimentado un crecimiento disruptivo. Una innovación reciente son las Redes Neuronales Informadas por Física (*PINNs*, por sus siglas en inglés *Physics-Informed Neural Networks*), una metodología que fusiona el *Deep Learning* con las leyes físicas fundamentales. Las *PINNs* (Raissi et al., 2019) son redes neuronales entrenadas no solo para ajustarse a datos de frontera, sino para obedecer directamente una Ecuación

Diferencial Parcial (EDP) que gobierna el fenómeno físico de interés.

No obstante, las activaciones estándar de las redes neuronales (tanh, ReLU) presentan un sesgo espectral (Rahaman et al., 2019): tienden a aprender frecuencias bajas antes que las altas. Para la ecuación de Helmholtz con número de onda $k = 2\pi$, este sesgo produce derivadas de segundo orden inestables y una convergencia lenta. Las *Sinusoidal Representation Networks (SIREN)*, propuestas por Sitzmann et al. (2020), resuelven este problema mediante la función de activación $\phi(z) = \sin(\omega_0 z)$, convirtiendo la arquitectura en la elección natural para resolver ecuaciones de onda.

Este proyecto se sitúa en la intersección de la óptica computacional y la inteligencia artificial, aplicando el paradigma PINN-SIREN para superar las limitaciones computacionales de los métodos clásicos en la simulación del *speckle* óptico.

1.2. Planteamiento del problema

1.2.1. Definición del problema

La simulación precisa de cómo la luz se dispersa y forma patrones de *speckle* es crucial para sistemas ópticos avanzados en imagenología biomédica (tomografía de coherencia óptica), metrología (medición de vibraciones y deformaciones) y criptografía óptica.

El desafío central radica en el costo computacional prohibitivo de los métodos numéricos actuales:

1. **Métodos Basados en Malla (FEM):** Para capturar con precisión los detalles finos de un patrón de *speckle*, la malla debe tener una resolución espacial menor que la longitud de onda de la luz (Jin, 2014). Esto conduce a sistemas de ecuaciones con millones de incógnitas por realización, requiriendo alta memoria RAM y tiempos de ejecución que frenan la investigación. Cada nuevo perfil de rugosidad superficial exige resolver el sistema completo desde cero.
2. **Métodos Estocásticos (Monte Carlo):** Requieren simular un número masivo de fotones individuales para construir un patrón estadísticamente preciso, lo que los hace prohibitivos para estudios paramétricos que requieren miles de realizaciones.

Aunque la aplicación de las *PINNs* para resolver la ecuación de Helmholtz ha sido validada en simulaciones de ondas acústicas (Schoder & Kraxberger, 2024), hasta donde alcanza el conocimiento actual, la aplicación sistemática de este paradigma con activación sinusoidal para la simulación eficiente de *speckle* óptico de alta resolución no ha sido abordada en la literatura.

1.2.2. Delimitación de la investigación

Alcances

- Se entregará un prototipo de *software* funcional, implementado en Python (PyTorch), capaz de construir y entrenar un modelo PINN-SIREN para resolver la ecuación de Helmholtz en dominios 2D.
- Se validará cuantitativamente la precisión del modelo contra soluciones analíticas conocidas mediante el error relativo L^2 .
- El modelo será capaz de simular la generación de patrones de *speckle* óptico en 2D, mediante la imposición de una condición de frontera con fase aleatoria $\phi(x) \sim \mathcal{U}(0, 2\pi)$.
- Se realizará una evaluación estadística del patrón generado conforme al criterio de Goodman para *speckle* completamente desarrollado (Goodman, 2007).
- Se realizará una evaluación comparativa (*benchmark*) del tiempo de inferencia contra el método FEM para demostrar la viabilidad computacional del enfoque propuesto.

Limitaciones

- **Dimensionalidad:** Todas las simulaciones se restringen a dominios bidimensionales (2D). El desarrollo en 3D está fuera del alcance de este trabajo de maestría.
- **Alcance computacional:** Esta es una investigación puramente computacional y de simulación. No se incluyen montajes ópticos experimentales ni validación contra datos físicos reales.

- **Simplificación del medio difusor:** El medio se modela como una frontera con fase aleatoria discreta ($N_\phi = 256$ puntos). No se aborda la simulación de medios volumétricos ni propiedades no lineales.

1.3. Preguntas de investigación e hipótesis

Las preguntas que guían esta investigación son:

1. ¿Puede un modelo PINN con activación sinusoidal (SIREN) aproximar con precisión la solución de la ecuación de Helmholtz 2D para la simulación de patrones de *speckle* óptico, logrando un error $L^2 < 5\%$ respecto a soluciones de referencia?
2. ¿Cuál es la ganancia en eficiencia computacional (tiempo de inferencia y uso de memoria) del enfoque PINN-SIREN respecto al FEM para simular el mismo fenómeno?
3. ¿Presenta el patrón de intensidad simulado las propiedades estadísticas características del *speckle* completamente desarrollado definidas por la teoría de Goodman?

Hipótesis: El desarrollo de un modelo PINN-SIREN para la resolución de la ecuación de Helmholtz 2D con campo complejo permitirá: (i) simular la generación de *speckle* óptico con un error relativo $L^2 < 5\%$ respecto a la solución analítica de referencia; (ii) obtener un factor de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}} > 1$ en la fase de inferencia; y (iii) preservar las propiedades estadísticas del fenómeno con un contraste de *speckle* $|C - 1| < 0.1$ conforme al criterio de Goodman (2007).

1.4. Objetivo general

Construir y validar un modelo computacional basado en Redes Neuronales Informadas por Física con activación sinusoidal (PINN-SIREN) para la simulación acelerada y físicamente precisa de patrones de *speckle* óptico, mediante la resolución directa de la ecuación de Helmholtz bidimensional con campo eléctrico complejo.

1.5. Objetivos específicos

1. Diseñar e implementar una arquitectura SIREN que incorpore el residuo de la ecuación de Helmholtz en su función de pérdida, con activación $\phi(z) = \sin(\omega_0 z)$ y una estrategia de inicialización que preserve la distribución de activaciones en profundidad (Sitzmann et al., 2020).
2. Entrenar y validar la precisión del modelo PINN-SIREN en el escenario unidimensional (NB01), comparando contra la solución analítica $E(x) = \cos(kx)$ mediante el error relativo L^2 .
3. Escalar el modelo al caso bidimensional con campo complejo (NB02), empleando Muestreo Latino Hipercúbico (LHS) para los puntos de colocación y validando contra la solución de onda plana $E = e^{i(k_x x + k_y y)}$.
4. Aplicar el modelo validado a la simulación de *speckle* óptico (NB03) mediante una condición de frontera de fase aleatoria, y validar estadísticamente el patrón generado conforme al criterio de Goodman.
5. Comparar cuantitativamente el rendimiento computacional del modelo PINN-SIREN contra una implementación FEM de referencia (NB04), cuantificando el factor de aceleración $S = T_{\text{FEM}}/T_{\text{PINN}}$.

1.6. Justificación

Esta investigación se justifica en tres ejes principales:

- **Justificación computacional:** El principal obstáculo en la simulación óptica avanzada es el costo prohibitivo de los métodos de malla. El enfoque *mesh-free* propuesto busca reducir los tiempos de simulación en al menos un orden de magnitud, habilitando estudios estadísticos de *speckle* que actualmente son intratables.
- **Justificación científica:** La simulación precisa de *speckle* impacta directamente en la imagenología biomédica (tomografía de coherencia óptica), la metrología de precisión y la crip-

tografía óptica. Acelerar la simulación tiene consecuencias directas en la capacidad de innovar en estas áreas de alto impacto.

- **Justificación programática:** El proyecto se alinea estratégicamente con la Línea de Generación y Aplicación del Conocimiento (LGAC) en Ciencia de Datos e Inteligencia Artificial de la Maestría en Ciencias de la Computación de la UJAT. Aplica una técnica de vanguardia en *Deep Learning* para resolver una EDP fundamental de la física, demostrando la sinergia entre la IA y la ciencia computacional avanzada.

1.7. Metodología

La metodología se basa en el marco de trabajo de las *PINNs* propuesto por Raissi et al. (2019), extendido con la arquitectura de activación sinusoidal SIREN (Sitzmann et al., 2020). El proyecto es un estudio computacional cuantitativo y experimental, desarrollado en cuatro fases alineadas con los objetivos específicos.

Fase 1 - NB01: Validación analítica 1D. Se implementa el modelo PINN-SIREN (5×64 neuronas) para resolver la ecuación de Helmholtz 1D con solución analítica conocida $E(x) = \cos(kx)$. La función de pérdida combina el error en las condiciones de frontera Dirichlet y el residuo de Helmholtz evaluado en puntos de colocación uniformes. Se emplea una estrategia de optimización bifásica: Adam (hasta 15,000 épocas) seguido de L-BFGS (búsqueda de línea *strong Wolfe*).

Fase 2 - NB02: Escala a 2D con campo complejo. Se escala la arquitectura a 5×128 neuronas para acomodar el campo complejo ($E_{\text{real}}, E_{\text{imag}}$). Se introduce el Muestreo Latino Hipercúbico (LHS) con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por lado (McKay et al., 1979). Se calibra el peso de la función de pérdida $\lambda_{\text{fís}} = 0.1$ mediante ablación.

Fase 3 - NB03: Simulación de *speckle* óptico (trabajo futuro). Se aplicará el modelo validado a la generación de *speckle*, reemplazando la condición de onda plana por una frontera con fase aleatoria $\phi(x) \sim \mathcal{U}(0, 2\pi)$ en $y = 0$ y bordes libres en el resto del dominio. La validación

estadística seguirá el criterio de Goodman (Goodman, 2007): contraste $C = \sigma_I / \langle I \rangle$ y test de Kolmogorov-Smirnov contra la distribución exponencial teórica.

Fase 4 - NB04: Benchmark FEM (trabajo futuro). Comparación cuantitativa del tiempo de inferencia PINN-SIREN contra una implementación de referencia con FEniCSx, para calcular el factor de aceleración $S = T_{\text{FEM}} / T_{\text{PINN}}$ y la huella de memoria pico. Esta fase está programada como trabajo futuro inmediato.

Capítulo 2

Marco Teórico

2.1. Conceptos y teorías fundamentales

Esta sección establece los fundamentos teóricos sobre los cuales se construye el modelo PINN-SIREN para la simulación de *speckle* óptico.

2.1.1. Ecuación de onda de Helmholtz

La propagación de luz coherente monocromática en un medio homogéneo e isótropo está gobernada por la ecuación de onda de Helmholtz escalar (Born & Wolf, 1999; Goodman, 2007; Jin, 2014):

$$\nabla^2 E(\mathbf{r}) + k^2 E(\mathbf{r}) = 0, \quad (2.1)$$

donde $E(\mathbf{r}) \in \mathbb{C}$ es la amplitud compleja del campo eléctrico, $k = 2\pi/\lambda$ es el número de onda y λ la longitud de onda del láser. En dos dimensiones espaciales ($\mathbf{r} = (x, y)$):

$$\frac{\partial^2 E}{\partial x^2} + \frac{\partial^2 E}{\partial y^2} + k^2 E = 0. \quad (2.2)$$

Dado que las redes neuronales operan sobre números reales, el campo complejo se descompone en sus partes real e imaginaria: $E = E_{\text{real}} + iE_{\text{imag}}$. Ambas componentes satisfacen la

ecuación (2.2) de forma independiente:

$$\nabla^2 E_{\text{real}} + k^2 E_{\text{real}} = 0, \quad \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}} = 0. \quad (2.3)$$

La intensidad física observable del *speckle* se calcula como:

$$I(x, y) = |E|^2 = E_{\text{real}}^2 + E_{\text{imag}}^2. \quad (2.4)$$

2.1.2. Speckle óptico completamente desarrollado

Cuando una superficie rugosa con variación de fase $\Delta\phi \gg 2\pi$ es iluminada por luz coherente, las contribuciones de los distintos puntos de la superficie interfieren de forma aleatoria. Por el Teorema del Límite Central, el campo complejo resultante sigue una distribución gaussiana circular compleja (Goodman, 2007):

$$E_{\text{real}}, E_{\text{imag}} \sim \mathcal{N}(0, \sigma_E^2), \quad \text{independientes.} \quad (2.5)$$

La intensidad $I = |E|^2$ sigue entonces una distribución exponencial negativa:

$$p(I) = \frac{1}{\langle I \rangle} \exp\left(-\frac{I}{\langle I \rangle}\right), \quad I \geq 0, \quad (2.6)$$

con valor esperado $\langle I \rangle = 2\sigma_E^2$ y desviación estándar $\sigma_I = \langle I \rangle$. El *contraste del speckle* se define como:

$$C = \frac{\sigma_I}{\langle I \rangle} = 1, \quad (2.7)$$

criterio que vale exactamente 1 para *speckle* completamente desarrollado y disminuye cuando el campo pierde coherencia o la rugosidad es insuficiente (Goodman, 2007).

2.1.3. Redes Neuronales Informadas por Física (PINNs)

El enfoque de resolver EDPs con redes neuronales fue pionero por Lagaris et al. (1998), quienes demostraron que redes feedforward podían aproximar soluciones de ecuaciones diferenciales ordinarias y parciales mediante una función de prueba que satisface las condiciones de frontera

exactamente. Este trabajo establece el precedente directo de las PINNs modernas. La capacidad de aproximación universal de las redes feedforward fue formalizada por Hornik et al. (1989).

Las PINNs modernas, introducidas por Raissi et al. (2019) y revisadas extensamente en Karniadakis et al. (2021) y Cuomo et al. (2022), aproximan la solución de una EDP mediante una red neuronal $\mathcal{N}_\theta(\mathbf{r})$ cuyos parámetros θ se optimizan minimizando una función de pérdida compuesta:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{datos}}(\theta) + \lambda_{\text{fís}} \mathcal{L}_{\text{física}}(\theta), \quad (2.8)$$

donde $\mathcal{L}_{\text{datos}}$ penaliza el error en las condiciones de frontera y $\mathcal{L}_{\text{física}}$ penaliza la violación de la EDP en el interior del dominio. Para la ecuación de Helmholtz 2D con campo complejo:

$$\mathcal{L}_{\text{datos}}(\theta) = \frac{1}{N_b} \sum_{j=1}^{N_b} \left\| \mathcal{N}_\theta(\mathbf{r}_j^b) - E(\mathbf{r}_j^b) \right\|^2, \quad (2.9)$$

$$\mathcal{L}_{\text{física}}(\theta) = \frac{1}{N_c} \sum_{i=1}^{N_c} [R_{\text{real}}(\mathbf{r}_i^c)^2 + R_{\text{imag}}(\mathbf{r}_i^c)^2], \quad (2.10)$$

donde $R_{\text{real}} = \nabla^2 E_{\text{real}} + k^2 E_{\text{real}}$ y $R_{\text{imag}} = \nabla^2 E_{\text{imag}} + k^2 E_{\text{imag}}$ son los residuos de Helmholtz, $\{\mathbf{r}_j^b\}$ son los puntos de frontera y $\{\mathbf{r}_i^c\}$ los puntos de colocación interiores. Las derivadas $\nabla^2 E$ se obtienen mediante diferenciación automática (Baydin et al., 2018).

2.1.4. Redes SIREN y sesgo espectral

Las activaciones estándar (ReLU, tanh) presentan un sesgo espectral (Rahaman et al., 2019): aprenden frecuencias bajas antes que las altas. Para la ecuación de Helmholtz con $k = 2\pi$, esto produce derivadas de segundo orden inestables y convergencia lenta. Adicionalmente, ReLU tiene segunda derivada nula, lo que impide computar el Laplaciano mediante diferenciación automática.

Sitzmann et al. (2020) proponen las redes SIREN (*Sinusoidal Representation Networks*), que utilizan la activación $\phi(z) = \sin(\omega_0 z)$ con una inicialización específica:

$$\mathbf{h}_\ell = \sin(\omega_0 (\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell)), \quad \ell = 1, \dots, L, \quad (2.11)$$

donde las matrices $\mathbf{W}_\ell$ se inicializan según $\mathcal{U}(-\sqrt{6/d}, \sqrt{6/d})$ para capas intermedias y $\mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa. Esta inicialización garantiza que las distribuciones de activación sean aproximadamente uniformes en $[-1, 1]$, condición necesaria para la estabilidad de derivadas de orden arbitrario. La derivada de cualquier orden de SIREN es también una red SIREN, lo que la convierte en la elección natural para resolver EDPs con operadores diferenciales de orden superior.

2.1.5. Diferenciación automática

La diferenciación automática (*autodiff*) permite calcular derivadas de cualquier orden con precisión de máquina mediante la aplicación sucesiva de la regla de la cadena sobre el grafo de operaciones del programa (Baydin et al., 2018). En el contexto de las PINNs, *autodiff* actúa como el motor que permite evaluar el Laplaciano ∇^2 directamente sobre las salidas de la red neuronal respecto a sus coordenadas de entrada, sin los errores de truncamiento de las diferencias finitas.

2.1.6. Muestreo Latino Hipercúbico (LHS)

El Muestreo Latino Hipercúbico (McKay et al., 1979) es una estrategia de muestreo estratificada diseñada para generar una distribución de puntos de colocación que cubra de manera cuasi-óptima el dominio computacional Ω . A diferencia del muestreo aleatorio simple, el LHS divide cada dimensión en N_c estratos iguales y coloca exactamente un punto por estrato, garantizando cobertura uniforme sin los patrones redundantes de una malla cartesiana. Esto permite a la red capturar la física de la ecuación de Helmholtz con una densidad de puntos significativamente menor, optimizando el uso de memoria GPU y reduciendo el tiempo de convergencia (Cuomo et al., 2022).

2.1.7. Optimización híbrida Adam + L-BFGS

El entrenamiento sigue una estrategia bifásica (Wang et al., 2021):

1. **Fase 1 – Adam:** Optimizador estocástico de primer orden (Kingma & Ba, 2015) con tasa de aprendizaje $\eta = 10^{-3}$, paciencia de 800 épocas sin mejora mayor que $\delta = 10^{-7}$ y un máximo de 15,000 épocas. Adam realiza exploración global del espacio de parámetros y proporciona un punto de inicio próximo al mínimo global.

2. **Fase 2 – L-BFGS:** Optimizador cuasi-Newton de segundo orden (*Limited-memory Broyden-Fletcher-Goldfarb-Shanno*) (Nocedal & Wright, 2006) con búsqueda de línea *strong Wolfe*, máximo 1,000 iteraciones y tamaño de historial 100. L-BFGS aprovecha la información de curvatura para realizar un ajuste fino de alta precisión desde el punto entregado por Adam.

Esta combinación supera a Adam puro en precisión final y a L-BFGS puro en robustez ante mínimos locales.

2.2. Literatura relacionada

El uso de redes neuronales para resolver EDPs fue revitalizado por Raissi et al. (2019), quienes demostraron la capacidad de las PINNs para resolver una amplia gama de problemas físicos sin necesidad de mallado. El análisis teórico de por qué las PINNs pueden fallar en el entrenamiento fue abordado por Wang et al. (2022) mediante la teoría del núcleo tangente neuronal (NTK), estableciendo las condiciones bajo las cuales el entrenamiento converge.

En el campo de las ecuaciones de onda, Moseley et al. (2020) aplicaron PINNs para resolver la ecuación de onda acústica 2D en modelos de velocidad variables, demostrando la viabilidad del enfoque en dominios inhomogéneos. Para la ecuación de Helmholtz específicamente, Alkhalifah et al. (2021) propusieron un marco de aprendizaje automático para obtener soluciones del campo de onda en sísmica, usando la ecuación de Helmholtz como restricción en la función de pérdida.

En el campo de la óptica y el electromagnetismo, Fang y Zhan (2020) aplicaron PINNs para resolver problemas de dispersión de ondas en medios inhomogéneos 2D, mientras que Chen et al. (2020) las utilizaron para el diseño inverso en nanofotónica. Lu et al. (2021) desarrollaron la biblioteca DeepXDE que sistematiza la implementación de PINNs para diversas EDPs.

El trabajo más directamente relacionado es el de Schoder y Kraxberger (2024), que realizó un estudio de factibilidad resolviendo la ecuación de Helmholtz en 3D con PINNs de activación $\tanh$, reportando un error $L^2 = 2.49\%$ (1D) y $L^2 = 1.91\%$ (2D) respecto a soluciones FEM de referencia. Este trabajo establece la línea base de comparación para la presente investigación.

La brecha en el conocimiento identificada es la siguiente: ningún trabajo previo ha aplicado sistemáticamente la arquitectura SIREN (Sitzmann et al., 2020) –con su ventaja intrínseca para

representar funciones de alta frecuencia— a la simulación del *speckle* óptico como fenómeno estadístico complejo. Esta investigación cierra dicha brecha.

2.3. Marco tecnológico

2.3.1. Infraestructura de hardware

El entrenamiento de los modelos PINN-SIREN se realizó sobre la siguiente infraestructura:

- **GPU:** NVIDIA GeForce RTX 5050 (8.5 GB VRAM), con núcleos CUDA para acelerar la diferenciación automática de segundo orden requerida por el cálculo del Laplaciano.
- **CUDA:** Versión 12.6.
- **Memoria RAM:** Gestión del flujo de puntos de colocación y ejecución del optimizador híbrido.

2.3.2. Ecosistema de software

- **Python 3.14:** Lenguaje de implementación principal.
- **PyTorch 2.4:** Framework de *Deep Learning* que proporciona diferenciación automática de segundo orden y soporte GPU mediante CUDA (Raissi et al., 2019).
- **NumPy / SciPy:** Operaciones numéricas y muestreo LHS (`scipy.stats.qmc.LatinHypercube`).
- **Matplotlib:** Visualización de campos, distribuciones estadísticas y curvas de entrenamiento.
- **Módulos propios:** `src/models.py` (arquitectura SIREN), `src/losses.py` (función de pérdida PINN), `src/utils.py` (métricas y visualización).

Capítulo 3

Modelo e implementación

3.1. Formulación del problema

Se considera el dominio cuadrado adimensional $\Omega = [0, 1]^2$, donde las coordenadas han sido normalizadas por la longitud de onda del láser ($\lambda = 638 \text{ nm}$, láser de diodo rojo). Bajo esta normalización, el número de onda adimensional es $\tilde{k} = 2\pi$.

Se plantean dos experimentos de complejidad creciente (completados), con dos adicionales planificados como trabajo futuro:

3.1.1. Experimento 1 (NB01): Validación 1D

La ecuación de Helmholtz unidimensional en $x \in [0, 1]$ con condiciones de Dirichlet:

$$\frac{d^2 E}{dx^2} + k^2 E = 0, \quad E(0) = 1, \quad E(1) = \cos(k), \quad (3.1)$$

admite la solución analítica $E_{\text{exacta}}(x) = \cos(kx)$, utilizada para validar la arquitectura y la función de pérdida.

3.1.2. Experimento 2 (NB02): Validación 2D con campo complejo

La ecuación de Helmholtz 2D en $\Omega = [0, 1]^2$ con condición de onda plana diagonal en los cuatro bordes:

$$E_{\text{exacta}}(x, y) = e^{i(k_x x + k_y y)}, \quad k_x = k_y = \frac{k}{\sqrt{2}}, \quad (3.2)$$

que satisface $k_x^2 + k_y^2 = k^2$. La condición de frontera se impone separando la solución en sus partes real e imaginaria:

$$E_{\text{real}}(x, y)|_{\partial\Omega} = \cos(k_x x + k_y y), \quad E_{\text{imag}}(x, y)|_{\partial\Omega} = \sin(k_x x + k_y y). \quad (3.3)$$

3.2. Arquitectura SIREN

Se emplea una arquitectura SIREN con los parámetros consolidados a partir de la validación 1D (NB01) y escalados para el caso 2D (NB02):

- **Entrada:** coordenadas espaciales $(x, y) \in [0, 1]^2$ (o $(x) \in [0, 1]$ para 1D).
- **Capas ocultas:** $L = 5$ capas de dimensión d neuronas cada una ($d = 64$ en NB01, $d = 128$ en NB02).
- **Activación:** $\phi(z) = \sin(\omega_0 z)$, con $\omega_0 = 1.0$.
- **Salida:** capa lineal de dos neuronas ($E_{\text{real}}, E_{\text{imag}}$) para el caso 2D, o una neurona E para el caso 1D.
- **Parámetros totales:** $\sim 8,400$ (NB01) y $66,690$ (NB02).

La elección $\omega_0 = 1.0$, en lugar del valor $\omega_0 = 30$ recomendado por Sitzmann et al. (2020) para señales de imagen, está justificada por la naturaleza del problema: el dominio adimensional $[0, 1]^2$ con $k = 2\pi$ no requiere capturar frecuencias ultra-altas, y valores mayores de ω_0 desestabilizan el entrenamiento con L-BFGS.

La inicialización sigue el esquema de Sitzmann et al. (2020): $\mathbf{W}_0 \sim \mathcal{U}(-1/n_{\text{in}}, 1/n_{\text{in}})$ para la primera capa y $\mathbf{W}_\ell \sim \mathcal{U}(-\sqrt{6/d}, \sqrt{6/d})$ para capas intermedias, garantizando que las distribuciones de activación sean aproximadamente uniformes en $[-1, 1]$.

3.3. Función de pérdida y calibración de pesos

La función de pérdida total para el caso 2D es:

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda_{\text{fís}} \left(\mathcal{L}_{R_{\text{real}}} + \mathcal{L}_{R_{\text{imag}}} \right), \quad (3.4)$$

con peso de física $\lambda_{\text{fís}} = 0.1$. Este valor fue calibrado empíricamente mediante un experimento de ablación (véase la Sección 4.3): valores superiores ($\lambda = 1.0$) sobrepesan la física e impiden la convergencia en 2D, dado que los dos residuos (real e imaginario) duplican efectivamente la contribución física; valores inferiores ($\lambda = 0.01$) producen campos que violan moderadamente la ecuación de Helmholtz.

Los residuos de Helmholtz se calculan mediante diferenciación automática de segundo orden (Baydin et al., 2018):

$$R_{\text{real}}(\mathbf{r}) = \nabla^2 E_{\text{real}}(\mathbf{r}) + k^2 E_{\text{real}}(\mathbf{r}), \quad R_{\text{imag}}(\mathbf{r}) = \nabla^2 E_{\text{imag}}(\mathbf{r}) + k^2 E_{\text{imag}}(\mathbf{r}), \quad (3.5)$$

donde el Laplaciano se obtiene con `torch.autograd.grad` activando la opción `create_graph=True` para permitir diferenciación de segundo orden. Es crítico que k^2 se convierta a tipo `float` de Python antes de multiplicar por el tensor de la red, para evitar conflictos de tipo entre `numpy.float64` y `torch.float32`.

3.4. Estrategia de muestreo

3.4.1. Puntos interiores (colocación)

Para el caso 2D, los $N_c = 3,000$ puntos de colocación interiores se generan mediante LHS (McKay et al., 1979) usando `scipy.stats.qmc.LatinHypercube` con dimensión $d = 2$. LHS divide cada dimensión en N_c estratos iguales de longitud $1/N_c$ y coloca exactamente un punto en cada estrato, garantizando cobertura uniforme del dominio sin los patrones redundantes de una malla cartesiana.

3.4.2. Puntos de frontera

Los $N_b = 300$ puntos de frontera por borde se distribuyen uniformemente sobre cada uno de los cuatro lados del dominio $\partial\Omega$. Para cada lado, se evalúa la solución exacta y se construye el par $(\mathbf{r}_j^b, E(\mathbf{r}_j^b))$ utilizado en $\mathcal{L}_{\text{datos}}$.

3.5. Estrategia de optimización

El entrenamiento sigue la estrategia bifásica descrita en el Capítulo 2, con los hiperparámetros consolidados en la Tabla 3.1.

Tabla 3.1. Hiperparámetros de entrenamiento consolidados.

Hiperparámetro	Valor	Aplicación
Tasa de aprendizaje Adam (η)	10^{-3}	NB01, NB02
Épocas máximas Adam	15,000	NB01, NB02
Paciencia (<i>early stopping</i>)	800 épocas	NB02
δ mejora mínima	10^{-7}	NB02
Iteraciones máximas L-BFGS	500 (NB01), 1,000 (NB02)	—
Historial L-BFGS	100	NB01, NB02
Semilla global (SEED)	42	NB01, NB02
Peso de física λ_{fis}	0.1	NB02

Todos los experimentos se ejecutaron en GPU NVIDIA RTX 5050 (CUDA 12.6, PyTorch 2.4). La semilla garantiza reproducibilidad.

3.6. Métricas de validación

3.6.1. Error L^2 relativo (NB01 y NB02)

El error L^2 relativo mide la discrepancia global entre la predicción de la red $\hat{E}$ y la solución exacta E_{exacta} , evaluado sobre una malla uniforme de 100×100 puntos:

$$\varepsilon_{L^2} = \frac{\|\hat{E} - E_{\text{exacta}}\|_2}{\|E_{\text{exacta}}\|_2} \times 100 \%. \quad (3.6)$$

El umbral de la tesis es $\varepsilon_{L^2} < 5 \%$.

3.7. Implementación modular

El código fuente está organizado en módulos reutilizables en `src/`:

`models.py` Clase `PINN_2D_SIREN` que implementa la arquitectura SIREN con la inicialización de Sitzmann et al. (2020). El método `forward(x)` aplica la activación sinusoidal capa por capa y retorna el campo complejo como un tensor de dos columnas ($E_{\text{real}}, E_{\text{imag}}$).

`losses.py` Función `pinn_loss_2d(model, xy_int, xy_bc, E_bc, k, lam)` que calcula la pérdida total (3.4). El cálculo del Laplaciano utiliza `torch.autograd.grad` con `create_graph=True` para habilitar la diferenciación de segundo orden. El escalar k se convierte explícitamente a `float(k)` antes de multiplicar por el tensor de la red, evitando conflictos de dtype entre `numpy.float64` y `torch.float32`.

`training.py` Loop de entrenamiento que integra las fases Adam y L-BFGS con *early stopping*.

`utils.py` Métricas (L^2 , R^2 , RMSE, MAE), funciones de muestreo LHS y rutinas de visualización.

Los experimentos están reproducidos en los notebooks `01_pinn_helmholtz_1d_validation.ipynb` y `02_pinn_helmholtz_2d_complex_field.ipynb`. Los resultados numéricos están archivados en formato JSON en `results/`.

Capítulo 4

Experimentos y Resultados

Este capítulo presenta los resultados de los dos experimentos ejecutados en GPU NVIDIA RTX 5050 (CUDA 12.6, PyTorch 2.4, SEED = 42). Los experimentos siguen una complejidad creciente: validación analítica 1D (NB01) y validación 2D con campo complejo (NB02).

4.1. NB01: Validación 1D - Helmholtz con solución analítica

4.1.1. Configuración experimental

El primer experimento valida la arquitectura SIREN frente a la solución analítica exacta de la ecuación de Helmholtz 1D. Se empleó la arquitectura SIREN 5×64 ($\sim 8,400$ parámetros) con los hiperparámetros de la Tabla 3.1. Los puntos de colocación son $N_c = 1,000$ puntos uniformes en $[0, 1]$ y las condiciones de frontera Dirichlet son $E(0) = 1$ y $E(1) = \cos(k)$.

4.1.2. Resultados de precisión

La Tabla 4.1 presenta las métricas de precisión obtenidas tras el entrenamiento completo Adam (15,000 épocas) seguido de L-BFGS (202 iteraciones), con un tiempo total de 251 segundos.

Tabla 4.1. Métricas de precisión - PINN-SIREN 1D ($k = 2\pi$).

Métrica	Valor
Error L^2 relativo (%)	0.006
MSE	1.5×10^{-9}
RMSE	3.9×10^{-5}
MAE	3.50×10^{-5}
Error máximo	5.77×10^{-5}
R^2	1.000000
Correlación de Pearson	1.000000
Épocas Adam	15,000 / 15,000
Iteraciones L-BFGS	202 / 500
Tiempo total (s)	251

Evaluado en malla uniforme de 1,000 puntos en $[0, 1]$. Arquitectura SIREN: 5 capas $\times$ 64 neuronas, $\omega_0 = 1.0$. Solución analítica: $E_{\text{exacta}}(x) = \cos(kx)$. GPU: NVIDIA RTX 5050, SEED = 42.

4.1.3. Análisis y comparativa con el estado del arte

El error $L^2 = 0.006\%$ supera el umbral de la tesis ($< 5\%$) por casi tres órdenes de magnitud y representa un factor de mejora de $\times 415$ respecto al resultado de Schoder y Kraxberger (2024), que reporta un error del 2.49% para Helmholtz 1D con PINNs de activación $\tanh$. Esta mejora drástica es atribuible a la ventaja intrínseca de la activación sinusoidal SIREN para representar funciones oscilatorias: la red aprende la solución $\cos(kx)$ de forma casi exacta, con $R^2 = 1.000000$ y correlación de Pearson = 1.000000 en toda la malla de evaluación.

La Figura 4.1 muestra la comparación entre la predicción de la red y la solución analítica, así como la distribución del error puntual.

4.2. NB02: Validación 2D - Helmholtz con campo complejo

4.2.1. Configuración experimental

El segundo experimento escala el modelo al caso bidimensional con campo complejo. Se empleó la arquitectura SIREN 5×128 (66,690 parámetros), LHS con $N_c = 3,000$ puntos de colocación y $N_b = 300$ puntos de frontera por borde. El peso de física $\lambda_{\text{fis}} = 0.1$ fue seleccionado mediante el experimento de ablación descrito en la Sección 4.3.




Figura 4.1. Validación PINN-SIREN para Helmholtz 1D. Panel izquierdo: comparación entre la predicción de la red y la solución analítica $E_{exacta}(x) = \cos(kx)$ en 1,000 puntos uniformes en $[0, 1]$. Panel derecho: error puntual $|\hat{E}(x) - E_{exacta}(x)|$. Error $L^2 = 0.006\%$, $R^2 = 1.000000$. GPU: NVIDIA RTX 5050, SEED = 42.




Figura 4.2. Métricas adicionales de entrenamiento NB01. De izquierda a derecha: curva de pérdida total durante las fases Adam y L-BFGS, distribución del error puntual y métricas de ajuste (R^2 , Pearson). La transición Adam $\rightarrow$ L-BFGS a la época 15,000 es visible como una caída abrupta en la curva de pérdida.

4.2.2. Resultados de precisión

La Tabla 4.2 reporta las métricas detalladas para cada componente del campo complejo, evaluadas en una malla uniforme de 100×100 puntos.

Tabla 4.2. Métricas de precisión - PINN-SIREN 2D ($k = 2\pi$, $k_x = k_y = k/\sqrt{2}$).

Métrica	E_{real}	E_{imag}
Error L^2 (%)	0.214	0.127
MSE	2.20×10^{-6}	8.43×10^{-7}
RMSE	1.48×10^{-3}	9.18×10^{-4}
MAE	1.27×10^{-3}	7.71×10^{-4}
Error máximo	3.05×10^{-3}	2.93×10^{-3}
R^2	0.999995	0.999998
Correlación de Pearson	0.999998	0.999999
Error L^2 promedio (%)	0.171	

Evaluado en malla uniforme de 100×100 puntos. Arquitectura: SIREN 5×128 , $\omega_0 = 1.0$, 66,690 parámetros. Puntos de colocación: LHS $N_c = 3,000$. Frontera: onda plana $e^{i(k_x x + k_y y)}$ en 4 bordes, $N_b = 300$ pts/borde. Entrenamiento: Adam (8,737 épocas) + L-BFGS (1,035 iter.), tiempo total 299 s. Varianza entre semillas ($\text{SEED} \in \{42, 123, 777\}$): error L^2 promedio = 0.155 ± 0.020 %.

4.2.3. Análisis de resultados

El error L^2 promedio de 0.171 % supera el umbral de la tesis (< 5 %) por más de un orden de magnitud y mejora en un factor de $\times 11.2$ el resultado de Schoder y Kraxberger (2024) para Helmholtz 2D (1.91 %). La precisión se mantiene alta en ambas componentes del campo complejo, con $R^2 > 0.9999$ para E_{real} y E_{imag} .

La ampliación de capacidad de $d = 64$ a $d = 128$ fue determinante: con $d = 64$ el error promedio era 0.436 %; con $d = 128$ se redujo a 0.171 %, una mejora de $2.5\times$. El Muestreo Latino Hipercúbico contribuyó a reducir el error en regiones de baja densidad de puntos respecto a mallas cartesianas equivalentes.

La Figura 4.3 muestra los mapas de calor de la solución exacta y la predicción PINN-SIREN para ambas componentes del campo.




Figura 4.3. Validación PINN-SIREN para Helmholtz 2D con campo complejo. Fila superior: partes real e imaginaria de la solución analítica $E_{\text{exacta}} = e^{i(k_x x + k_y y)}$. Fila inferior: predicción PINN-SIREN correspondiente. La diferencia visual es indistinguible; los errores puntuales son del orden de 10^{-3} (véase la Tabla 4.2). Malla de evaluación 100×100 , SEED = 42.




Figura 4.4. Métricas adicionales de entrenamiento NB02. Panel izquierdo: curva de pérdida total mostrando la transición bifásica Adam $\rightarrow$ L-BFGS. Paneles central y derecho: mapas de error puntual $|E_{\text{real}} - \hat{E}_{\text{real}}|$ y $|E_{\text{imag}} - \hat{E}_{\text{imag}}|$ en la malla 100×100 . Los errores más altos se concentran en las esquinas del dominio.

4.2.4. Reproducibilidad multi-semilla

Para evaluar la robustez estadística del método, el experimento NB02 se repitió con tres semillas diferentes: $\text{SEED} \in \{42, 123, 777\}$. Los resultados se presentan en la Tabla 4.3.

Tabla 4.3. Reproducibilidad multi-semilla - NB02 ($\lambda_{\text{fis}} = 0.1$).

SEED	Error L^2 prom. (%)	Épocas Adam	Tiempo (s)
42	0.171	8,737	299
123	0.1264	8,012	448
777	0.1675	13,560	346
Media $\pm$ Desv. est.	0.155 ± 0.020	—	—

Misma arquitectura, hiperparámetros y protocolo de entrenamiento. La varianza entre semillas es del 13 % relativo, confirmando la estabilidad del método. GPU: NVIDIA RTX 5050.

La varianza inter-semilla de $\pm 0.020\%$ (13 % relativo) confirma que el método es estadísticamente robusto: independientemente de la inicialización aleatoria, el modelo converge a soluciones de alta precisión.

4.3. Ablación del peso de física λ_{fis}

Para calibrar el balance entre el término de datos y el término físico en la función de pérdida (3.4), se realizó un experimento de ablación con $\lambda_{\text{fis}} \in \{0.01, 0.1, 1.0\}$, manteniendo fija la arquitectura SIREN 5×128 y SEED = 42. Los resultados se presentan en la Tabla 4.4.

Tabla 4.4. Ablación del peso de física λ_{fis} - NB02.

λ_{fis}	Error L^2 prom. (%)	Converge	Observación
0.01	0.163	Sí	Física subponderada
0.1	0.171	Sí	Configuración óptima
1.0	> 5.0	No	Física sobreponderada

Arquitectura SIREN 5×128 , $\omega_0 = 1.0$, SEED = 42. Mismo protocolo Adam + L-BFGS que NB02. *No converge* indica que Adam no alcanzó la condición de parada antes de las 15,000 épocas con $\varepsilon_{L^2} < 5\%$. El caso $\lambda = 1.0$ produce una explosión numérica en la función de pérdida debido a que los dos residuos (real e imaginario) duplican la contribución de la física, generando gradientes de gran magnitud en `float32`.

El valor $\lambda_{\text{fis}} = 0.1$ equilibra adecuadamente el ajuste a los datos de frontera y el cumplimiento de la EDP: el modelo con $\lambda = 0.01$ obtiene ligeramente mejor error (0.163%) al sacrificar restricción física, mientras que $\lambda = 1.0$ produce gradientes explosivos. Se seleccionó $\lambda = 0.1$ como configuración óptima por su estabilidad y precisión.

4.4. Comparativa con el estado del arte

La Tabla 4.5 resume el rendimiento de la PINN-SIREN propuesta frente al estado del arte en la resolución de la ecuación de Helmholtz con PINNs.

Tabla 4.5. Comparativa de error L^2 relativo - PINN-SIREN vs. estado del arte.

Método	Dimensión	Error L^2 (%)	Factor de mejora
Schoder & Kraxberger (2024)	1D	2.490	—
Schoder & Kraxberger (2024)	2D	1.910	—
PINN-SIREN (este trabajo)	1D	0.006	$\times 415$
PINN-SIREN (este trabajo)	2D	0.171	$\times 11.2$

El factor de mejora es la razón entre el error de Schoder et al. (2024) y el error de la PINN-SIREN propuesta. Ambos trabajos abordan la ecuación de Helmholtz escalar en dominios normalizados. Schoder & Kraxberger (2024) aborda el caso 3D con activación *tanh*; este trabajo opera en 1D/2D adimensionales con arquitectura SIREN. El factor de mejora refleja tanto la ventaja arquitectural de SIREN sobre *tanh*/ReLU como la diferencia de complejidad dimensional.

4.5. Resumen de experimentos completados

La Tabla 4.6 sintetiza el estado de los experimentos ejecutados en el marco de este primer avance.

Tabla 4.6. Estado de los experimentos ejecutados.

Experimento	Descripción	Estado	Métrica principal
NB01	Helmholtz 1D - validación analítica	Completo	$L^2 = 0.006 \%$
NB02	Helmholtz 2D - campo complejo	Completo	$L^2 = 0.171 \%$
NB03	Speckle óptico - frontera rugosa	Pendiente	$ C - 1 < 0.1$
NB04	Benchmark FEM - factor de aceleración	Pendiente	$S = T_{\text{FEM}}/T_{\text{PINN}}$

NB01 y NB02 verifican la hipótesis de precisión ($L^2 < 5 \%$). NB03 y NB04 constituyen el trabajo futuro inmediato.

Los dos experimentos completados verifican la primera hipótesis de la tesis: el error $L^2 < 5 \%$ se supera con amplitud tanto en el caso 1D ($L^2 = 0.006 \%$) como en el 2D ($L^2 = 0.171 \%$). La validación estadística del *speckle* y el *benchmark* contra FEM se abordarán como trabajo futuro inmediato.

Bibliografía

- Alkhalifah, T., Song, C., Waheed, U. b., & Hao, Q. (2021). Wavefield solutions from machine learned functions constrained by the Helmholtz equation. *Artificial Intelligence in Geosciences*, 2, 11-19. <https://doi.org/10.1016/j.aiig.2021.08.002>
- Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(153), 1-43.
- Born, M., & Wolf, E. (1999). *Principles of Optics: Electromagnetic Theory of Propagation, Interference and Diffraction of Light* (7.^a ed.). Cambridge University Press.
- Chen, Y., Lu, L., Karniadakis, G. E., & Dal Negro, L. (2020). Physics-informed neural networks for inverse problems in nano-optics and plasmonics. *Optics Express*, 28(8), 11618-11633. <https://doi.org/10.1364/OE.384875>
- Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific machine learning through physics-informed neural networks: A review. *Journal of Computational Science*, 62, 101709. <https://doi.org/10.1016/j.jocs.2022.101709>
- Fang, Z., & Zhan, J. (2020). A physics-informed neural network framework for wave scattering in inhomogeneous media. *IEEE Antennas and Wireless Propagation Letters*, 19(9), 1640-1644. <https://doi.org/10.1109/LAWP.2020.2991329>
- Goodman, J. W. (2007). *Speckle Phenomena in Optics: Theory and Applications*. Roberts & Company.
- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359-366. [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8)
- Jin, J.-M. (2014). *The Finite Element Method in Electromagnetics* (3.^a ed.). John Wiley & Sons.

- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440. <https://doi.org/10.1038/s42254-021-00314-5>
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization [Published at ICLR 2015].
- Lagaris, I. E., Likas, A., & Fotiadis, D. I. (1998). Artificial neural networks for solving ordinary and partial differential equations. *IEEE Transactions on Neural Networks*, 9(5), 987-1000. <https://doi.org/10.1109/72.712178>
- Lu, L., Meng, X., Mao, Z., & Karniadakis, G. E. (2021). DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1), 208-228. <https://doi.org/10.1137/19M1274067>
- McKay, M. D., Beckman, R. J., & Conover, W. J. (1979). A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2), 239-245. <https://doi.org/10.1080/00401706.1979.10489755>
- Moseley, B., Markham, A., & Nissen-Meyer, T. (2020). Solving the wave equation with physics-informed deep learning.
- Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization* (2.^a ed.). Springer.
- Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F., Bengio, Y., & Courville, A. (2019). On the spectral bias of neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 97, 5301-5310.
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- Schoder, S., & Kraxberger, F. (2024). Feasibility study on solving the Helmholtz equation in 3D with PINNs. <https://doi.org/10.48550/arXiv.2403.06623>
- Sitzmann, V., Martel, J. N. P., Bergman, A. W., Lindell, D. B., & Wetzstein, G. (2020). Implicit Neural Representations with Periodic Activation Functions. *Advances in Neural Information Processing Systems*, 33, 7462-7473.

- Wang, S., Teng, Y., & Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5), A3055-A3081. <https://doi.org/10.1137/20M1318043>
- Wang, S., Yu, X., & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449, 110768. <https://doi.org/10.1016/j.jcp.2021.110768>